



دانشگاه صنعتی شریف

دانشکده مهندسی برق

پایان نامه کارشناسی ارشد

گرایش سیستم های الکترونیک دیجیتال

# پیاده سازی یک پلتفرم MLOps به صورت GPU ابری روی GPU

نگارنده

ابوالفضل یاریان

استاد راهنما

دکتر متین هاشمی

خردادماه ۱۴۰۳



## توجه

این پروژه بر اساس قرارداد شماره (.....) از حمایت مالی  
مرکز تحقیقات مخابرات ایران برخوردار شده است.

بسمه تعالی

دانشگاه صنعتی شریف  
دانشکده مهندسی برق

پایاننامه کارشناسی ارشد

عنوان: مدلسازی نهان نگاری تصویربر اساس تئوری اطلاعات  
نگارش: «نام و نام خانوادگی دانشجو»

اعضا هیات داوران:

..... امضاء: ..... دکتر ...  
..... امضاء: ..... دکتر ...

تاریخ: ۶ شهریور ۱۳۸۴

## تقدیم و قدردانی

در این صفحه از کسانی که مایلید تشکر می‌کنید.

## چکیده:

در دنیای دیجیتال امروزه، نهان نگاری مقاوم تصویر که در آن یک سیگنال حامل داده به صورت نامرئی و مقاوم در برابر حملات در تصویر تعییه می‌شود، به عنوان یک راهکار برای حل مساله حفاظت از حق تالیف محصولات تصویری معرفی شده است. برای این منظور تاکنون جهت نهان نگاری روش‌های متعددی به کار گرفته شده است که از آن جمله می‌توان به استفاده از مدل‌های بینایی جهت یافتن میزان بیشینه انرژی نهان نگاره برای تعییه در تصویر و استفاده از حوزه‌های مقاوم در برابر حملات، اشاره نمود. در همین راستا در این پایان نامه به استفاده از مفاهیم حوزه‌تئوری اطلاعات به عنوان یک راهنمای توسعه الگوریتم‌های موجود، جهت قرار دادن بهینه نهان نگاره پرداخته شده است. همچنین در ساختار پیشنهادی که برای افزایش مقاومت در حوزه تبدیل تصویر پیاده می‌شود، از تبدیلات چنددقیقی مانند تبدیل موجک گسته و تبدیل MR-SVD که به سیستم بینایی انسان نزدیکترند، استفاده می‌شود. به طوریکه در حوزه تبدیل موجک، با استفاده از آنتروپی و تاثیر پدیده پوشش آنتروپی به اصلاح مدل‌های بینایی مرتبط با این حوزه پرداخته و بدین ترتیب نهان نگاره با قدرت و مقاومت بالاتر در تصویر تعییه نموده و همچنین کیفیت بهتر برای تصویر نهان نگاری شده بدست آمد. همچنین در حوزه تبدیل MR-SVD ابتدا این تبدیل که تاکنون برای نهان نگاری استفاده نشده بود، جهت نهان نگاری بکار گرفته شد و سپس مشابه ساختار پیشنهادی مبتنی بر آنتروپی در حوزه تبدیل موجک، در حوزه این تبدیل نیز بکار رفت و نتایج شبیه‌سازیها مقاوم‌تر بودن ساختار پیشنهادی و کیفیت بالاتر تصویر نهان نگاری شده در این حوزه را نتیجه داد.

## کلمات کلیدی:

- ۱- نهان نگاری تصویر
  - ۲- تبدیل چنددقیقی
  - ۳- سیستم بینایی انسان
  - ۴- تبدیل موجک
  - ۵- تجزیه مقادیر تکین
  - ۶- آنتروپی
  - ۷- پوشش آنتروپی
- . Image Watermarking
  - . Multi-Resolution Transform
  - . Human Visual System (HVS)
  - . Wavelet Transform
  - . Singular Value Decomposition (SVD)
  - . Entropy
  - . Entropy Masking

# فهرست مطالب

۱	۱	مقدمه
۲	۲	مرور مفاهیم پایه
۲	۱-۲	DevOps
۲	۱-۱-۲	تعريف
۳	۲-۱-۲	چرخه کاری DevOps
۴	۳-۱-۲	خط لوله CI/CD
۷	۴-۱-۲	مزایای متداول‌تری DevOps
۹	۲-۲	مجازی سازی و کاتینیرها
۹	۱-۲-۲	مجازی سازی
۱۱	۲-۲-۲	کاتینیرها
۱۳	۳-۲-۲	هماهنگ سازی کاتینیرها (کوبرنتیز)
۱۶	۳	MLOps
۱۶	۱-۳	مقدمه
۱۶	۲-۳	تعريف مفاهیم اولیه
۱۷	۱-۲-۳	اصول
۱۹	۲-۲-۳	اجزاء
۲۵	۳-۲-۳	نقش‌ها
۲۶	۳-۳	معماری جامع
۳۴	۴	طراحی یک پلتفرم MLOps

۳۴	.....	مقدمه .. . . . .	۱-۴
۳۴	.....	سیستم مدیریت پلتفرم .. . . .	۲-۴
۳۴	.....	۱-۲-۴ مدیریت پیکربندی و فراهم سازی زیرساخت .. . . .	
۳۶	.....	خط لوله CI/CD .. . . .	۲-۲-۴
۳۸	.....	مخزن کد منبع .. . . .	۳-۲-۴
۳۹	.....	مخزن مؤلفه ها .. . . .	۴-۲-۴
۴۰	.....	معماری خوش کوبرنتیز .. . . .	۳-۴
۴۱	.....	۱-۳-۴ مدیریت داده .. . . .	
۴۴	.....	شبکه .. . . .	۲-۳-۴
۴۷	.....	۳-۳-۴ مدیریت کاربران و چندمستاجری .. . . .	
۴۹	.....	۴-۳-۴ نظارت .. . . .	
۵۰	.....	۵-۳-۴ استقرار مدل .. . . .	

## ۵ پیاده سازی و نتایج

۵۱	.....	مقدمه .. . . . .	۱-۵
۵۱	.....	۲-۵ پیاده سازی پلتفرم .. . . . .	
۵۱	.....	۱-۲-۵ سیستم مدیریت .. . . . .	
۵۴	.....	۲-۲-۵ خوش کوبرنتیز .. . . . .	
۵۷	.....	۳-۵ حل مسئله و نتایج .. . . . .	
۵۸	.....	۱-۳-۵ مسئله تشخیص ارقام .. . . . .	
۶۲	.....	۲-۳-۵ مسئله تحلیل احساسات در بازار سهام .. . . . .	

## ۶ نتیجه گیری و پیشنهادات

# فهرست جداول

۱-۲	نمونه هایی از ابزار برای مراحل خاص اتوماسیون خط لوله CI/CD	5
۱-۵	مشخصات سخت افزاری ماشین های مدیریت	۵۲
۲-۵	مشخصات سخت افزاری ماشین های خوش کوبرنتیز	۵۴
۳-۵	زمان اجرا چرخه یادگیری ماشین در مسئله تشخیص ارقام	۵۹
۴-۵	تست استنتاج مدل مسئله تشخیص ارقام	۶۰
۵-۵	زمان اجرا خط لوله ها CI/CD و چرخه یادگیری ماشین در مسئله تحلیل احساسات در بازار سهام	۶۶
۶-۵	تست استنتاج مدل مسئله تحلیل احساسات در بازار سهام	۶۶

# فهرست تصاویر

۴	.....	مراحل DevOps	۱-۲
۱۰	.....	انواع هایپروایزر [۱]	۲-۲
۱۱	.....	تفاوت ماشین مجازی و کانتینر	۳-۲
۱۳	.....	معماری لایه ای تصویر داکر	۴-۲
۱۴	.....	مولفه های یک خوشه کوبرنتیز	۵-۲
۲۰	.....	خط لوله در Apache Airflow	۱-۳
۲۱	.....	انباره ویژگی	۲-۳
۲۵	.....	نقش ها و اشتراکات آنها در پارادایم MLOps	۳-۳
۲۶	.....	معماری جامع MLOps	۴-۳
۳۵	.....	معماری Ansible	۱-۴
۳۷	.....	استقرار مبتنی بر Pull	۲-۴
۳۷	.....	استقرار مبتنی بر Push	۳-۴
۴۲	.....	نحوه کار PVC و PVC در خوشه کوبرنتیز	۴-۴
۴۳	.....	معماری MinIO	۵-۴
۴۶	.....	معماری Istio	۶-۴
۴۸	.....	رونده احراز هویت	۷-۴
۵۳	.....	مخازن مولفه در Nexus	۱-۵
۵۳	.....	خط لوله ها در CI/CD Jenkins	۲-۵
۵۴	.....	مخازن کد در Gitlab	۳-۵
۵۶	.....	وضعیت مولفه ها در خوشه کوبرنتیز	۴-۵
۵۷	.....	میزان مصرف منابع سخت افزاری پلتفرم بدون بار	۵-۵
۵۷	.....	داشبورد پلتفرم MLOps	۶-۵
۵۸	.....	نمونه داده مجموعه دادگان MNIST	۷-۵
۶۰	.....	گراف استنتاج مدل در مسئله تشخیص ارقام (Grafana داشبورد)	۸-۵
۶۱	.....	زمان چرخه های یادگیری ماشین در مسئله تشخیص ارقام	۹-۵
۶۱	.....	زمان استنتاج مدل در مسئله تشخیص ارقام	۱۰-۵

۶۲	.....	۱۱-۵
۶۲	.....	۱۲-۵
۶۳	.....	۱۳-۵
۶۴	.....	۱۴-۵
۶۵	.....	۱۵-۵
۶۶	.....	۱۶-۵
۶۷	.....	۱۷-۵

گراف نظارت بر پردازنده گرافیکی در مسئله تشخیص ارقام (داشبورد Grafana)

مجموعه داده احساسات در بازار سهام

خط لوله آموزش مسئله تحلیل احساسات در بازار سهام

چرخه کاری آموزش مسئله تحلیل احساسات در بازار سهام

خط لوله استقرار مدل در مسئله تحلیل احساسات در بازار سهام (داشبورد Grafana)

زمان استنتاج مدل در مسئله تحلیل احساسات در بازار سهام

# فهرست کلمات اختصاری

2D-DWT	2-Dimensional Discrete Wavelet Transform
CPD	Cycle Per Degree
CSF	Contrast Sensitivity Function
:	:

## فصل اول

### مقدمه

گسترش روز افزون شبکه جهانی اینترنت و توسعه فناوری اطلاعات، نیاز فزاینده‌ای را به استفاده از سرویس‌های چندرسانه‌ای دیجیتال، در پی داشته به طوریکه کاربردهای دیجیتال شاهد رشد شکری در طول دهه گذشته بوده است که نتیجه آن ایجاد سیستمهای کارآمد در ذخیره، انتقال و بازیابی اطلاعات است. مزایای فراوان فناوری دیجیتال، باعث محبوبیت و کاربرد هر چه بیشتر آن توسط اشخاص شده تا جاییکه حتی وسائل ضبط و پخش صدا و تصویر آنالوگ خانگی هم به سرعت با نمونه‌های دیجیتال جایگزین شده‌اند. اما این موضوع مسائل حاشیه‌ای دیگری برای بشر ایجاد نموده است. به طوریکه امکان تهیه کپی‌های متعدد از روی نسخه اصلی بدون کاهش کیفیت آن و یا سادگی جعل و تغییر محتوای اطلاعاتی نسخه اصلی، باعث شده که مالکیت معنوی<sup>۱</sup> صاحبان اثر به خطر افتاده و در نتیجه بسیاری از ارائه دهنده‌گان سرویس‌های چندرسانه‌ای (از جمله شرکتهای فیلم‌سازی) از ارائه نمونه دیجیتال محصولاتشان خودداری نمایند. لذا برطرف نمودن این مشکلات، یکی از زمینه‌های پژوهشی مهم در عرصه مخابرات و بخصوص پردازش سیگنال است.

---

Intellectual Property<sup>۱</sup>

## فصل ۲

# مرور مفاهیم پایه

DevOps ۱-۲

### ۱-۱-۲ تعریف

دواپس که از اتحاد واژگان Operation و Development به وجود آمده است؛ ترکیبی از ابزارها، کنش‌ها و فرهنگ کاری است که تیم‌های توسعه<sup>۱</sup> و عملیات<sup>۲</sup> را به همکاری موثرتر نزدیک می‌کند و کسب و کارها با استفاده از می‌توانند اپلیکیشن‌ها و سرویس‌هایشان را با سرعت بالاتری نسبت به روش‌های سنتی تحویل دهند. همین سریع‌تر شدن سرعت توسعه و انتشار نرم‌افزار، سازمان‌ها را قادر می‌سازد تا در مقایسه با کسب‌وکارهایی که هنوز از روش‌های سنتی توسعه نرم‌افزار استفاده می‌کنند خدمات بهتری به مشتریانشان ارائه دهند. در واقع دواپس سعی دارد تا مشکل جدایی تیم‌های مختلف را رفع کرده و یک فرهنگ سازمانی یکپارچه را میان تیم‌های مختلفی که در حال توسعه یک نرم‌افزار هستند ایجاد کند. از این جهت بسیاری از کارها می‌توانند به صورت خودکار پیش رفته و در نهایت همه چیز با سرعت بیشتری صورت بگیرد [۲، ۳]. این خودکارسازی با استفاده از خط لوله CI/CD از منبع کد شروع می‌شود و تا مانیتورینگ محصول ادامه می‌باید [۴].

تا قبل از تشکیل دواپس، تیم‌های توسعه نرم‌افزار یا تیم عملیاتی در محیط‌های جداگانه کار می‌کردند. هدف تیم توسعه تولید محصول جدید و یا افزودن ویژگی‌های جدیدی روی محصولات قبلی بود. هدف تیم عملیاتی نیز ثابت نگه داشتن وضعیت موجود سرویس‌ها برای پایداری بیشتر بود. به مرور زمان در فرآیند توسعه نرم‌افزار، روش‌های چابک<sup>۳</sup> ایجاد شد تا با مشتری تعامل بهتری برقرار شود و نیازهایی که دارد به محصول اضافه شود [۵]. جدایی دو تیم توسعه و عملیات از هم باعث

Development<sup>۱</sup>  
Operation<sup>۲</sup>  
Agile<sup>۳</sup>

می شد که در فرآیند تولید محصول و استقرار<sup>۴</sup> آن، اتلاف وقت ایجاد شود و محصول دیرتر به دست مشتری برسد [۶].

## ۲-۱-۲ چرخه کاری DevOps

همانطور که در شکل ۱-۲ مشاهده می کنید، DevOps قصد دارد از ابزار و جریان های کاری<sup>۵</sup> برای خودکارسازی یک یا چند مورد از موارد زیر استفاده کند:

۱. کدنویسی: شامل توسعه، بازبینی کد و ابزارهای کنترل نسخه است. مثلا، یک تیم تصمیم می گیرد از گیت<sup>۶</sup> به عنوان ابزار کنترل نسخه و از گیت هاب<sup>۷</sup> نیز به عنوان یک مخزن راه دور استفاده کند. این تیم مجموعه ای از دستورالعمل های سبک کدنویسی را با استفاده از ابزاری نظیر Linter به همراه حداقل درصد پوشش تست تعریف کرده و با تعیین استراتژی انشعاب اصلی<sup>۸</sup> بر تنه<sup>۹</sup> تغییرات خود را به منظور بازبینی برای ادغام با انشعاب اصلی<sup>۹</sup> برای توسعه دهنده ارشد ارسال می کند [۷].

۲. ساخت: شامل ایجاد و ذخیره خودکار مولفه<sup>۱۰</sup> ها می باشد. به طور مثال یک تیم تصمیم می گیرد یک Container قابل اجرا از محصول خود ایجاد کند.

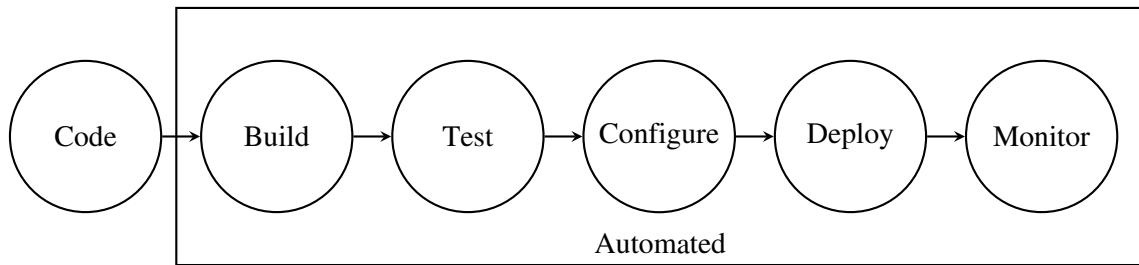
۳. تست: شامل ابزارهایی برای تست محصول می باشد. تیم محیطی را به منظور تست هر تغییر جدید راه اندازی می کند که در آن مجموعه ای از آزمایش ها مانند آزمون واحد<sup>۱۱</sup>، آزمون یکپارچگی<sup>۱۲</sup> و ... به طور خودکار در برابر هر ویرایش کد اجرا می شود. ادغام و تست کد به طور مکرر، به تیم های توسعه کمک می کند تا از کیفیت کدشان اطمینان حاصل کرده و جلوی خطاهای احتمالی را بگیرند.

۴. پیکربندی: شامل پیکربندی و مدیریت خودکار زیرساخت می باشد. این مورد شامل مجموعه ای از اسکریپت هایی برای باز تولید محیط در حال اجرا و زیرساخت نرم افزاری شامل سیستم عامل تا پایگاه داده و سرویس های خاص و پیکربندی شبکه آنها می باشد [۸، ۹].

۵. استقرار: این مرحله شامل استراتژی استقرار است. به طور مثال تیم می تواند تصمیم بگیرد که یک محصول به طور

---

Deploy <sup>۴</sup>
Workflow <sup>۵</sup>
Git <sup>۶</sup>
Github <sup>۷</sup>
Trunk-Based <sup>۸</sup>
Merge request <sup>۹</sup>
Artifact <sup>۱۰</sup>
Unit test <sup>۱۱</sup>
Integration test <sup>۱۲</sup>



شکل ۱-۲: مراحل DevOps

مستقیم منتشر شود یا ابتدا در یک محیط آزمایشی مورد ارزیابی قرار گیرد. هم چنین در مواقعي که مشکلی در استقرار وجود دارد چه کاری انجام دهن و استراتژی بازگشت<sup>۱۳</sup> خود را پیاده سازی کنند.

۶. نظارت: از عملکرد محصول تا نظارت بر تجربه کاربر نهایی را شامل می شود. به عنوان مثال، می تواند مدت زمان درخواست های پایگاه داده یا بارگذاری وبسایت یا تعداد کاربرانی که از ویژگی های خاص محصول استفاده می کنند یا تعداد بازدیدکنندگان از یک وبسایت که به ثبت نام ختم می شود یا تعداد کاربران جدید در یک مجموعه زمانی خاص را پوشش دهد. مرحله نظارت هم چنین شامل هشدار خودکار خرابی ها نیز می باشد (به عنوان مثال، آستانه استفاده از [۱۰]). درنهایت نظارت بر محیط تولید به منظور اطمینان از صحت کارکرد صحیح محصول ضروری است.

### ۳-۱-۲ خط لوله CI/CD

در دنیای توسعه نرم افزار دستیابی به بهرهوری بالا، کیفیت مطلوب محصول و رضایت مشتری از اهداف اصلی هر سازمانی است. در متداول‌ترین DevOps و رویکردهای مرتبط با آن مانند ادغام مداوم<sup>۱۴</sup>، تحويل مداوم<sup>۱۵</sup> و استقرار مداوم<sup>۱۶</sup> به طور فزاینده‌ای محبوب شده‌اند زیرا به سازمان‌ها کمک می‌کنند تا با سرعت و کارآمدی بیشتری به این اهداف دست یابند [۶]. ادغام مداوم به فرآیندی اطلاق می‌شود که در آن توسعه‌دهندگان برنامه‌های خود را به طور مداوم (معمولًاً چندین بار در روز) در یک مخزن مشترک ادغام می‌کنند. به محض ادغام کد، یک سری از تست‌های خودکار اجرا می‌شود تا اطمینان حاصل شود که این تغییرات جدید باعث بروز مشکل در نرم افزار نشده‌اند [۱۱]. این تست‌ها شامل تست‌های واحد، تست‌های یکپارچگی و تست‌های کارکردی می‌باشند. از آنجایی که برنامه‌های کاربردی پیشرفته کنونی در چندین پلتفرم و ابزار های مختلف اقدام به توسعه می‌کنند، لذا نیاز به مکانیزمی برای ادغام و تایید تغییرات مختلف، اهمیت بالاتری پیدا می‌کند.

Rollback<sup>۱۳</sup>  
Continuous Integration (CI)<sup>۱۴</sup>  
Continuos Delivery (CD)<sup>۱۵</sup>  
Continuous Deployment (CD)<sup>۱۶</sup>

جدول ۲-۱: نمونه هایی از ابزار برای مراحل خاص اتوماسیون خط لوله CI/CD

Phase	Tools
Build	Gradle, Bazel, Docker
Test	Selenium, pytest
Configure	Ansible, Terraform
Deploy	ArgoCD, Jenkins
Monitor	Prometheus, Sentry

تحویل مداوم ادامه ای بر ادغام مداوم است و به تیم ها این امکان را می دهد تا نرم افزار را پس هر تغییر مهم در کد به مرحله تولید برسانند. در این مدل، هر خروجی که از فرایند CI عبور کرده و تست های لازم را با موفقیت پشت سر گذاشته باشد، به صورت خودکار آماده انتشار می شود [۱۱]. به عبارتی دیگر، هدف از تحویل مداوم، داشتن پایگاه کدی است که همیشه آماده استقرار در محیط تولید باشد. این فرایند ممکن است شامل تست های اضافی برای ارزیابی عملکرد، امنیت و سازگاری با محیط های تولید نیز باشد.

استقرار مداوم که گاهی با تحویل مداوم اشتباه گرفته می شود، به فرآیندی اطلاق می شود که در آن هر تغییر در کد که تمام مراحل تست و تأیید را با موفقیت پشت سر می گذارد، به صورت خودکار در محیط تولید قرار می گیرد [۱۱]. این به معنای آن است که نسخه های جدید نرم افزار می توانند به طور مداوم و بدون دخالت دستی به کاربران نهایی تحویل داده شوند. این رویکرد به تیم ها کمک می کند تا سریعتر به بازخوردها پاسخ دهند و بهبودهای مستمری را در محصول خود اعمال کنند، اما نیازمند یک فرآیند آزمایشی بسیار قوی و اطمینان از کیفیت کد است.

فرآیند کامل CI/CD که در شکل ۲-۱ هم به عنوان بخشی از چرخه کاری توضیح داده شد [۶]، با یک فرآیند ساخت شروع می شود. در این مرحله کد توسط ابزارهای مرتبط که در جدول ۲-۱ ذکر شده است، تبدیل به نرم افزار قابل اجرا می شوند. پس از این مرحله، تست های خودکار که شامل تست های واحد، تست های یکپارچه سازی و تست های رابط کاربری هستند، اجرا می شوند تا اطمینان حاصل شود که تغییرات جدید باعث بروز خطا در نرم افزار نمی شوند. در صورت موفقیت آمیز بودن تست ها، یک نسخه قابل اجرا از کد نسخه گذاری شده و در مخازنی همانند Nexus نگه داری می شوند. در مرحله پیکربندی تنظیم محیط لازم برای نصب و استفاده از نرم افزار انجام می شود. دو رویکرد اصلی برای این کار وجود دارد: مرحله به مرحله <sup>۱۷</sup> و اعلامی <sup>۱۸</sup>. در رویکرد اول، پیش نیازها به ترتیب آماده سازی می شوند و شکست در هر مرحله می تواند به عدم انجام دادن مراحل بعدی منجر شود. این رویکرد، که اغلب با استفاده از ابزارهایی مانند Ansible پیاده سازی می شود، زمانی مفید است که نیاز به اعمال تغییرات جزئی بر محیط باشد. در مقابل، رویکرد اعلامی به طور همزمان کل محیط را بر اساس یک حالت نهایی

Procedural<sup>۱۷</sup>  
Declarative<sup>۱۸</sup>

تعریف شده آماده می‌کند. این رویکرد باعث می‌شود که در صورت بروز خطا در یک بخش، سایر بخش‌ها تحت تأثیر قرار نگیرند. برای اجرای این رویکرد، می‌توان از ابزارهایی مثل Terraform استفاده کرد<sup>[۱۲]</sup>. پس از این، مرحله‌ی استقرار آغاز می‌شود که در آن نرم‌افزار به محیط‌های تست، توسعه یا تولید منتقل می‌شود. این فرایند اغلب شامل مکانیزم‌هایی برای پشتیبانی و بازگرداندن نسخه‌های قبلی در صورت بروز مشکل است. یکی از قسمت‌های فرآیند کامل این خط لوله نیز با استفاده از ابزاری مانند CI، CircleCI، Gitlab Jenkins می‌تواند انجام گردد. در آخر نیز مرحله نظارت انجام می‌شود. ابزارهای نظارتی نظیر Prometheus و Grafana معمولاً شامل نمودارها، گزارش‌ها، و آمارهایی هستند که به شما اطلاعاتی در مورد وضعیت فعلی خط لوله و عملکرد برنامه‌های آزمایشی و انتشارات را ارائه می‌دهند. هم چنین اطلاعاتی مانند زمان طول کشیده برای هر مرحله، تعداد خطوط و متوسط زمان بین خرابی‌ها<sup>[۱۹]</sup> از جمله آمارهایی هستند که ممکن است در این مرحله نمایش داده شوند. لازم به ذکر است که می‌توان به منظور بررسی سبک کدنویسی و اعمال استاندارد های تیم توسعه در ابتدا خط لوله بخشی را قرار داد تا از استاندارد بودن کد اطمینان یابد. در این بخش می‌توان از Linter ها یا pre-commit hooks استفاده کرد. معروف ترین ابزار برای هر مرحله را در جدول ۲-۱ نیز مشاهده می‌کنید.

به هنگام طراحی و پیاده سازی یک خط لوله CI/CD باید به نکات زیر توجه کرد [۱۱، ۱۲، ۶] :

- قابلیت بازگشت به حالت قبل<sup>۲۰</sup>

- قابلیت مشاهده<sup>۲۱</sup> و هشداردادن<sup>۲۲</sup>

- امنیت

- مدت زمان اجرای خط لوله

برای هر نسخه از کد باید یک استراتژی بازگشت وجود داشته باشد تا اگر مشکلی پیش آمد، به نسخه قبلی بازگردانده شود. یک راه حل آسان برای بازگشت می‌تواند اجرای نسخه قدیمی تراز طریق همان خط لوله CI/CD باشد. بازگشت به ورژن قبلی همیشه ساده نیست، چراکه اگر سرویس در حال اجرا قابل بازگشت باشد، باید به بازگرداندن داده‌ها قبلی و زمان توقف هنگام استقرار نسخه جدید نیز توجه کرد.

هر انتشار باید شفاف باشد که چه تغییراتی اعمال شده و چه کسی تغییرات را تأیید کرده است. هم چنین تیم توسعه باید بداند که استقرار موفقیت‌آمیز بوده و چه زمانی انجام شده است. درنهایت باید هشدارهای واضحی از کد خراب در خط لوله و

---

Mean time between failures (MTBF)<sup>[۱۹]</sup>

Rollback<sup>[۲۰]</sup>

Observability<sup>[۲۱]</sup>

Alerting<sup>[۲۲]</sup>

خطای احتمالی در انتشار وجود داشته باشد. اگر مشکلی در استقرار پیش آید و هیچ سابقه واضحی از تغییرات وجود نداشته باشد، بازگشت به حالت قبل دشوار خواهد بود. علاوه بر این دلیل بروز این مشکل در استقرار نیز برای تیم نامعلوم است. تصور کنید که یک توسعه‌دهنده به صورت دستی به یک ماشین محیط تولید دسترسی پیدا کرده و به طور تصادفی یک فایل کلیدی را حذف می‌کند که پس از چند روز باعث خرابی‌های سیستم می‌شود. هیچ ردی از این تغییرات وجود ندارد، هیچکس نمی‌داند کجا را باید به حالت قبلی برگرداند و حتی بازگشت به کد قبلی ممکن است کمکی نکند زیرا فایل گمشده ممکن است در ورژن قبلی بازتولید نشود.

توجه به امنیت در فرآیندهای CI/CD بسیار حیاتی است تا سلامت و امنیت فرآیندهای توسعه و ارسال نرم‌افزار حفظ شود. اجرای کنترل دسترسی بر اساس نقش<sup>۲۳</sup> ضروری است تا فقط افراد معجاز بتوانند تغییراتی در فرآیند CI/CD اعمال کرده و کد را ارسال کنند. این شامل کنترل دسترسی به ابزارهای Jenkins CI/CD نظیر و همچنین به هر سیستم مرکز مانند API، مخازن کد منبع است. هم چنین مدیریت اسرار<sup>۲۴</sup> جنبه اساسی امنیت خط لوله است. اسراری مانند کلیدهای HashiCorp Vault رمزعبورها و گواهی‌نامه‌ها باید به طور امن ذخیره و دسترسی‌پذیر باشند. استفاده از ابزارهایی مانند می‌تواند به مدیریت امنیت اسرار کمک کند.

مدت زمان اجرای کامل یک خط لوله از ساخت تا استقرار برای حفظ چابکی بسیار مهم است. تست‌ها و ساخت‌های طولانی مدت می‌توانند منجر به تداخل با خط لوله‌های دیگر باشند. بهبود و بهینه‌سازی این فرآیند از طریق اجرای موازی تست‌ها، بهبود قابلیت مقیاس‌پذیری زیرساخت و بهینه‌سازی کد می‌تواند به کاهش زمان مورد نیاز برای تست و ساخت و بهبود جریان کار توسعه کمک کند.

در محصولاتی که از یادگیری ماشین استفاده می‌کنند نیز مراحل خط لوله برای رسیدگی به چرخه عمر مدل و داده‌ها افزایش می‌یابد، اما عناصر، مزایا و اهداف یکسان هستند.

## ۴-۱-۲ مزایای متداول‌تر DevOps

این متداول‌تری یک رویکرد نوآورانه در توسعه نرم‌افزار و عملیات است که مزایای بسیاری برای بهبود عملکرد سازمانی<sup>۲۵</sup> ارائه می‌دهد [۱۳]. ادغام این روش‌ها می‌تواند نحوه مواجهه تیم‌ها با چالش‌های پژوهه و تعامل با فناوری را تغییر داده و منجر به افزایش کارایی، قابلیت اطمینان و رضایت شود [۳].

### ۱. افزایش سرعت و کارایی: با خودکارسازی فرآیند انتشار نرم‌افزار از طریق CI/CD، تیم‌ها می‌توانند فرکانس و سرعت

Role-Based Access Control (RBAC)<sup>۲۳</sup>

Secrets<sup>۲۴</sup>

Organization performance<sup>۲۵</sup>

انتشارها را افزایش داده که منجر افزایش سرعت پاسخ دهی به مشتری شده و مزیت رقابتی ایجاد می کند [۴].

۲. ایجاد محیط‌های عملیاتی پایدارتر: تضمین قابلیت اطمینان بروزرسانی‌های برنامه و تغییرات زیرساخت یکی از مزایای مهم این متداول‌زی می باشد. از طریق خط لوله CI/CD، هر تغییری برای اطمینان از کارایی و اینمنی ادغام با محیط تولید آزمایش می شود تا از انتشار نسخه‌های معیوب جلوگیری کند. یکی از شاخص‌های اصلی پایداری، انتشارهای متناوب و مکرر است. با استفاده از این متداول‌زی توسعه‌دهنگان می توانند خطاهای را سریع‌تر شناسایی و رفع کنند. این موضوع باعث کاهش شاخص MTTR<sup>26</sup> می شود. این شاخص مدت زمان برگشت به وضعیت پایدار بعد از وقوع خطا یا اشکال را نشان می دهد و هرچه مقدار آن کمتر باشد، پایداری سیستم بیشتر است [۶]. علاوه بر انتشار پیوسته و مستمر، نرم‌افزارهای مانیتورینگ هم با پایش مداوم نرم‌افزار و سرورها و ایجاد دسترسی به اطلاعات حیاتی نرم‌افزار و محیط عملیاتی برای مهندسان، نقش مهمی در شناسایی و رفع خطاهای در نتیجه حفظ پایداری دارند.

۳. مقیاس پذیری: تسهیل کننده مدیریت مقیاس‌پذیر زیرساخت‌ها و فرآیندهای توسعه است. تکنیک‌هایی مانند زیرساخت به عنوان کد<sup>27</sup> مدیریت محیط‌های توسعه، آزمایش و تولید را به شکلی تکرارپذیر و کارآمد ساده‌سازی می کنند [۳].

۴. صرفه‌جویی در هزینه‌ها و منابع: علاوه بر مدیریت بهتر عملکرد و ارتباطات، هزینه‌ها و منابع را هم به نسبت روش‌های قدیمی کاهش می دهد. با استفاده از این متداول‌زی و خط لوله CI/CD طول چرخه‌ها کوتاه‌تر و نتایج کمی و کیفی بهتر می شوند و در نتیجه هزینه‌ها نیز کاهش پیدا می کنند. این فرآیند حتی نیاز به منابع سخت‌افزاری و منابع انسانی را هم کاهش می دهد. با استفاده از معماری ماژولار، اجزا و منابع به خوبی دسته‌بندی شده و سازمان‌ها می توانند به راحتی از فضا و رایانش ابری برای انجام کارها استفاده کنند. چاکری در این متداول‌زی اهمیت زیادی دارد لذا فناوری ابری نیز این چاکری را به تیم‌ها ارائه و سرعت و هماهنگی بین تیم‌ها را افزایش می دهد. با کمک این فناوری، حتی اگر در فرآیند توسعه و عملیات نیاز به منابع جدید و بیشتر بود، با ثبت یک درخواست ساده در عرض چند دقیقه منابع جدید در اختیار سازمان قرار می گیرد. از مزایای دیگر استفاده از رایانش ابری می توان به حداقل شدن هزینه‌های شروع و عملیاتی پروژه، بهبود امنیت، افزایش مشارکت و بهبود دسترسی و کاربری داده‌ها اشاره کرد.

۵. تجزیه ایزووله گرایی: در بسیاری از سازمان‌ها، به دلایل امنیتی و مدیریتی، اطلاعات در تیم‌ها به طور جداگانه نگهداری می شوند و این باعث ایجاد سیلوهای سازمانی شده که مانع از گردش منظم داده و اطلاعات در سازمان می شود. با این حال، با بهره‌گیری از این متداول‌زی وجود همکاری فعال در تیم‌ها، ارتباطات بهبود می یابد. این امر باعث می شود که

Mean Time To Recover<sup>26</sup>  
infrastructure as a code<sup>27</sup>

اطلاعات به طور موثرتر جریان یابد، کارایی تیم‌ها افزایش یابد و در نتیجه، کارایی کلی سازمان بهبود پیدا کند.

## ۲-۲ مجازی سازی و کانتینرها

### ۱-۲-۲ مجازی سازی

تکنولوژی مجازی سازی<sup>۲۸</sup> به روشی اشاره دارد که در آن منابع سخت‌افزاری یک سیستم فیزیکی به چندین محیط مجازی تقسیم می‌شوند. این تکنولوژی به سازمان‌ها این امکان را می‌دهد تا منابع خود را به شیوه‌ای کارآمدتر استفاده کنند، زیرا می‌توانند چندین سیستم عامل و برنامه را روی یک سرور فیزیکی اجرا کنند. مجازی‌سازی انواع مختلفی دارد، از جمله مجازی‌سازی سرور، نرم‌افزار و شبکه، که هر کدام کاربردهای خاص خود را دارند [۱، ۱۴].

مجازی‌سازی سرور یکی از تکنولوژی‌های کلیدی در مدیریت و بهره‌برداری از داده‌ها و منابع سخت‌افزاری در مراکز داده است. این فناوری امکان تقسیم یک سرور فیزیکی<sup>۲۹</sup> به چندین سرور مجازی را می‌دهد، به طوری که هر سرور مجازی می‌تواند به صورت مستقل عمل کرده و سیستم عامل و برنامه‌های کاربردی خود را اجرا کند. مجازی‌سازی سرور معمولاً شامل سه جزء اصلی است [۱]:

- هایپروایزر<sup>۳۰</sup>

- ماشین مجازی

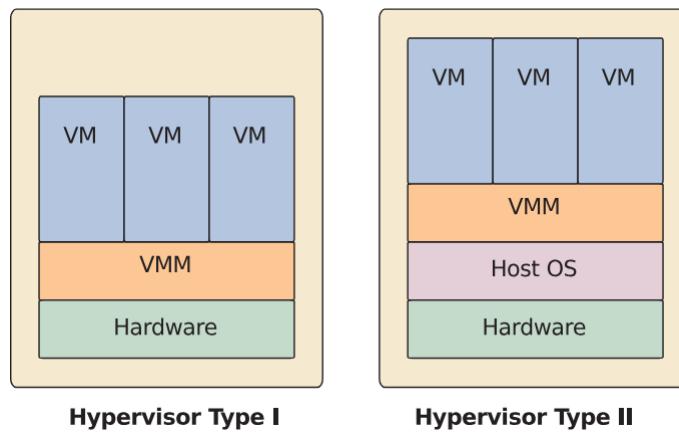
- سیستم مدیریت مرکزی

هایپروایزر، که گاهی اوقات به عنوان مدیر ماشین مجازی<sup>۳۱</sup> شناخته می‌شود، نقش محوری در مجازی‌سازی سرور دارد. این نرم‌افزار بر روی سخت‌افزار سرور نصب می‌شود و وظیفه آن تقسیم منابع سرور فیزیکی، مانند CPU، حافظه، فضای دیسک و شبکه به چندین ماشین مجازی است. هایپروایزرهای دو دسته تقسیم می‌شوند.

هایپروایزر نوع<sup>۳۲</sup>۱ مستقیماً بر روی سخت‌افزار نصب می‌شود و به طور مستقل از سیستم عامل فیزیکی عمل می‌کند. می‌توان از هایپروایزرهای نوع ۱ معروف به Microsoft Hyper-V، VMware ESXi و KVM اشاره کرد که برای بهینه‌سازی عملکرد و امنیت طراحی شده‌اند.

---

Virtualization <sup>۲۸</sup>
Bare-metal <sup>۲۹</sup>
Hypervisor <sup>۳۰</sup>
Virtual Machine Manager (VMM) <sup>۳۱</sup>
Bare-metal <sup>۳۲</sup>



شکل ۲-۲: انواع هایپروایزر [۱]

هایپروایزر نوع ۳۳۲ روی یک سیستم عامل میزبان نصب می‌شود و به عنوان یک برنامه درون سیستم عامل عمل می‌کند.

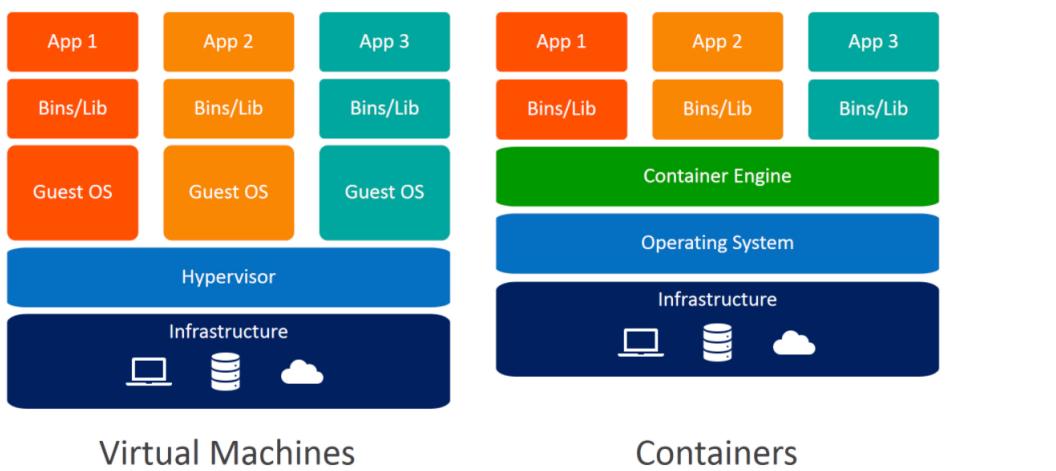
از هایپروایزر نوع ۲ نیز می‌توان به VMware Workstation و Oracle VirtualBox اشاره کرد. این هایپروایزرها اغلب برای تست و توسعه مورد استفاده قرار می‌گیرند. در شکل ۲-۲ ساختار آن را مشاهده می‌کنید.

هایپروایزرها به لحاظ انعطاف پذیری و امکان پیکربندی متنوع، قابلیت‌های قدرتمندی را برای مدیریت سرورهای مجازی فراهم می‌کنند. آنها می‌توانند به طور خودکار منابع را بین ماشین‌های مجازی تخصیص دهند و امکاناتی مانند تکثیر<sup>۳۴</sup> و بازیابی فاجعه<sup>۳۵</sup> را ارائه دهند.

ماشین مجازی<sup>۳۶</sup> واحدی از منابع مجازی است که شبیه‌سازی یک سرور فیزیکی را انجام می‌دهد. هر VM می‌تواند سیستم عامل خود را داشته باشد و مستقل از دیگر VM‌ها عمل کند. این امر به کاربران اجازه می‌دهد که برنامه‌های متعدد را بدون تداخل با یکدیگر اجرا کنند. VM‌ها از منابع سخت افزاری تخصیص داده شده توسط هایپروایزر استفاده می‌کنند و می‌توانند به راحتی از یک سرور فیزیکی به دیگری با استفاده از تکنیک هایی نظیر Snapshot منتقل شوند. استفاده از تکنولوژی مجازی‌سازی نقش بسیار مهمی در فرآیندهای DevOps دارد. با امکان ایجاد و حذف سریع ماشین‌های مجازی، مجازی‌سازی به تیم‌های توسعه این امکان را می‌دهد که به سرعت محیط‌های نرم‌افزاری مورد نیاز خود را راه‌اندازی و پس از اتمام کار، آن‌ها را به راحتی حذف کنند، که این امر منجر به صرفه‌جویی در هزینه‌ها و منابع می‌شود. علاوه بر این، مجازی‌سازی ریسک‌های مرتبط با استقرار نهایی در محیط تولید را کاهش داده و با ایجاد محیط‌های شبیه‌سازی شده برای آزمایش‌های پیش از استقرار، اطمینان حاصل می‌کند که نرم‌افزار قبل از راه‌اندازی به درستی کار می‌کند.

---

Hosted<sup>۳۳</sup>  
Replication<sup>۳۴</sup>  
Disaster Recovery<sup>۳۵</sup>  
Virtual Machine (VM)<sup>۳۶</sup>



شکل ۲-۳: تفاوت ماشین‌مجازی و کانتینر

## ۲-۲-۲ کانتینرها

کانتینرها محیط‌هایی هستند که به برنامه‌های نرم‌افزاری امکان می‌دهند تا با تمام وابستگی‌های خود در یک بسته واحد جمع‌آوری شوند. آن‌ها همانند برنامه‌های نرم‌افزاری سنتی که به شما اجازه می‌دهند مستقل از نرم‌افزارهای دیگر و خود سیستم عامل کار کنید، نصب نمی‌شوند. مهمترین دغدغه کانتینرها این است که چگونه محیطی فراهم کنند تا نرم‌افزارهایی که در یک محیط پردازشی اجرا می‌شوند با منتقال به محیط دیگر، بدون ایراد و مشکل اجرا شوند. این تکنولوژی از معماری میزبان بهره می‌برد تا از منابع سخت‌افزاری مشترک استفاده کند، اما اجرای برنامه‌ها را در یک محیط ایزوله و مستقل فراهم می‌کند. تمام اجزای ضروری مورد نیاز یک برنامه به صورت یک Image بسته‌بندی می‌شود. Image مربوطه در یک محیط ایزوله اجرا شده و فضای حافظه، CPU و فضای ذخیره سازی خود را با سیستم عامل به اشتراک نخواهد گذاشت. این عمل موجب می‌شود که فرآیندهای موجود در کانتینر، قادر به مشاهده سایر فرآیندها در خارج از آن نباشند.

کانتینرها و ماشین‌های مجازی هر دو ابزارهایی برای ایزوله‌سازی منابع نرم‌افزاری هستند، اما تفاوت‌های اساسی در معماری و کاربرد آن‌ها وجود دارد که در شکل ۲-۳ نشان داده شده است. ماشین‌های مجازی با ایجاد یک لایه انتزاعی کامل بر روی سخت‌افزار فیزیکی کار می‌کنند که به آن‌ها اجازه می‌دهد سیستم‌عامل‌های مستقل را بر روی هر VM اجرا کنند. این امر به هر ماشین مجازی امکان می‌دهد منابع سخت‌افزاری را به صورت مجزا استفاده کند، اما باعث می‌شود VM‌ها نسبت به کانتینرها سنگین‌تر و کم استفاده تر باشند. در مقابل، کانتینرها به جای سیستم‌عامل‌های کامل، تنها برنامه‌ها و وابستگی‌های خود را ایزوله می‌کنند و همگی بر روی هسته سیستم‌عامل میزبان اشتراکی اجرا می‌شوند، که این امر باعث سبک‌تر، سریع‌تر و مقیاس‌پذیرتر شدن کانتینرها نسبت به ماشین‌های مجازی باشند. از این‌رو، کانتینرها برای محیط‌هایی که نیازمند راه‌اندازی

سریع و مدیریت منابع مانند میکروسرویس‌ها و برنامه‌های کاربردی مبتنی بر Cloud هستند ایده‌آل می‌باشند [۱۵]. در کنار مزایای فراوان کانتینرها، برخلاف ماشین‌های مجازی در امنیت و ایزو لاسیون داده‌ها محدودیت‌هایی دارند و ممکن است نیازمند ابزارهای پیچیده‌تر برای مدیریت لاغ‌ها و نظارت باشند، که می‌تواند پیاده‌سازی و نگهداری آنها را چالش برانگیز سازد. تکنولوژی کانتینر ریشه در مفهوم چارچوب‌های Unix مانند chroot دارد که در دهه ۱۹۷۰ معرفی شد. اما، پیشرفت‌های اصلی در این زمینه با ظهور Docker در سال ۲۰۱۳ آغاز شد. داکر یک پلتفرم متن باز است که استانداردسازی ایجاد، اجرا و مدیریت کانتینرها را فراهم کرد و به سرعت به یکی از مهم‌ترین ابزارها در این حوزه تبدیل شد.

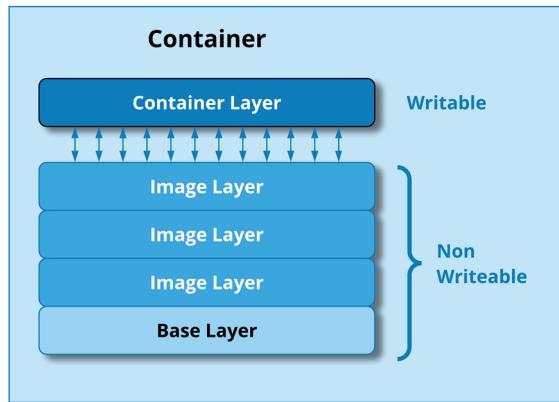
اجزای کلیدی مورد استفاده در پیاده‌سازی کانتینرها شامل موارد زیر است [۱۶]:

- موتورهای کانتینر<sup>۳۷</sup>

- هماهنگ‌سازی کانتینر<sup>۳۸</sup>

موتورهای کانتینری مانند Containerd و Docker Engine ابزارهایی هستند که کانتینرها را ایجاد، اجرا و مدیریت می‌کنند. این موتورها از فناوری‌های موجود در هسته لینوکس مانند Namespaces و Control groups (cgroups) برای ایزو له‌سازی کانتینرها استفاده می‌کنند و به آن‌ها امکان می‌دهند که فرایندها و منابع سیستمی را به صورت مستقل از یکدیگر مدیریت کنند. بخشی از هسته لینوکس که امکان جداسازی عناصری مثل شبکه، فرایندها و فضای فایل سیستم را فراهم می‌کند. هر کانتینر در یک namespace جداگانه اجرا می‌شود که استقلال آن را نسبت به دیگر برنامه‌ها تضمین می‌کند. هر کانتینر در یک cgroups نیز به مدیریت استفاده از منابع سخت‌افزاری مانند CPU و حافظه توسط فرایندها کمک می‌کند. این فناوری امکان اختصاص دقیق منابع به کانتینرها را می‌دهد و از مصرف بیش از حد منابع توسط یک کانتینر جلوگیری می‌کند.

برای مدیریت و مقیاس‌بندی کانتینرها در محیط‌های تولید، ابزارهای هماهنگ‌سازی مانند Docker و Kubernetes Swarm کاربرد دارند. این ابزارها به توسعه‌دهندگان این امکان را می‌دهند که خوشه<sup>۳۹</sup> های بزرگ کانتینری را مدیریت کنند و برنامه‌ها را با انعطاف‌پذیری و دقت بالا مقیاس‌بندی نمایند. راجع به این موضوع در قسمت بعدی بیشتر صحبت خواهد شد. Docker Image به عنوان اساسی‌ترین بخش در اکوسیستم داکر نقش کلیدی در پیاده‌سازی و توزیع برنامه‌های نرم‌افزاری دارد. تصاویر داکر از یک معماری لایه‌ای بهره می‌برند. معماری لایه این امکان را فراهم می‌کند که تغییرات نسبت به یک تصویر پایه به صورت دیفرانسیلی اعمال شود. هر لایه در تصویر داکر، تغییراتی را نسبت به لایه قبلی اضافه می‌کند. این رویکرد باعث می‌شود که بازسازی و بهروزرسانی تصاویر کانتینری فقط بر روی لایه‌هایی که تغییر کرده‌اند انجام شود، که به



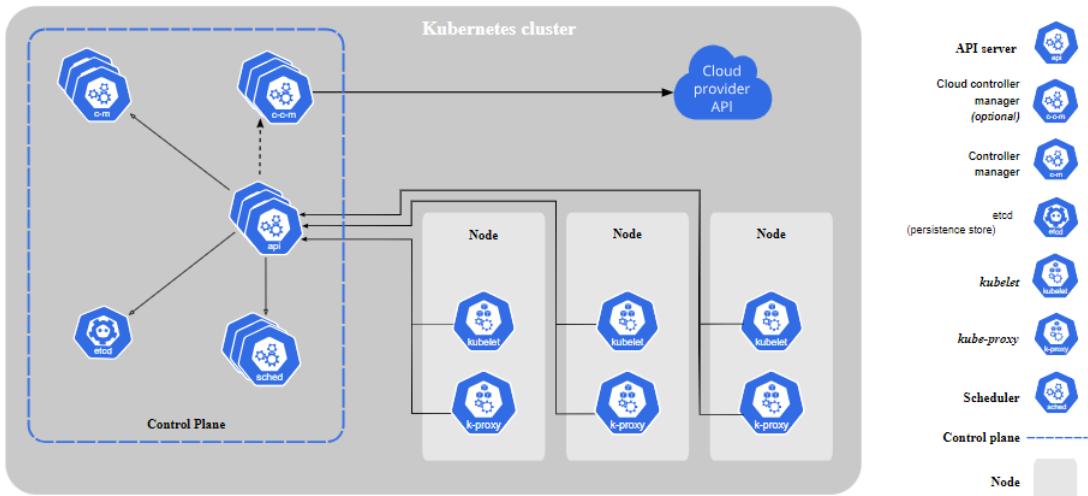
شکل ۴-۲: معماری لایه ای تصویر داکر

نوبه خود باعث کاهش حجم داده های مورد نیاز برای ذخیره سازی و انتقال می شود. زمانی که Dockerfile نوشته می شود، هر دستور (مانند RUN، COPY و FROM) یک لایه جدید در تصویر داکر ایجاد می کند. این لایه ها به ترتیبی که در داکرفایل آمده اند، روی هم اضافه می شوند. داکر از یک فایل سیستم Union استفاده می کند که به آن این اجازه را می دهد تا لایه های مختلف را به گونه ای ترکیب کند که به نظر یک فایل سیستم یکپارچه است [۱۷]. ساختار لایه ای تصویر داکر را در شکل ۴-۲ مشاهده می کنید.

### ۳-۲-۲ هماهنگ سازی کانتینرها (کوبرنیتیز)

در دنیای توسعه نرم افزار، استفاده از معماری های مبتنی بر میکروسرویس ها و کانتینرها افزایش یافته است که هر دو نیازمند مدیریت دقیق و خودکار سرویس ها در محیط های تولید هستند. در محیط های پویا و با مقیاس بزرگ که دستگاه ها و خدمات به طور مکرر تغییر می کنند، تقریباً غیر ممکن است که با نیروی کار دستی، سرویسی با دسترسی بالا ارائه داد. در چنین شرایطی، ابزارهای هماهنگ سازی نقش حیاتی ایفا می کنند. آنها به خودکار سازی مدیریت کانتینرها، مدیریت شبکه و نظارت بر سلامت سیستم کمک می کنند. بدون هماهنگ سازی تیم های توسعه و عملیات با چالش های عدیده ای از جمله کنترل ناموفق بر پیکربندی ها، مشکلات مربوط به برقراری ارتباط بین سرویس ها، دشواری های مربوط به مقیاس پذیری و برقراری تعادل بار مواجه می شوند. در میان ابزارهای هماهنگ سازی Kubernetes به عنوان یکی از پیشروان بازار شناخته می شود که امکان مدیریت خودکار مجموعه های بزرگی از کانتینرها را فراهم می آورد. کوبرنیتیز یک پلتفرم هماهنگ سازی کانتینر است که فرایند زمان بندی<sup>۴</sup>، خودکار سازی استقرار، مدیریت و مقیاس گذاری اپلیکیشن های کانتینری را تسهیل می کند.

Scheduling<sup>۴</sup>



شکل ۵-۲: مولفه های یک خوشه کوبرتیز

### معماری کوبرتیز

یک سیستم کوبرتیز با تمام اجزای آن را یک خوشه<sup>۴۱</sup> می گویند. هر خوشه شامل یک یا چند گره<sup>۴۲</sup> است که می توانند فیزیکی<sup>۴۳</sup> یا مجازی باشند. این گره ها به دو دسته اصلی یا همان سطح کنترل<sup>۴۴</sup> و کارگر<sup>۴۵</sup> تقسیم می شوند. گره اصلی به عنوان مغز متفکر کوبرتیز عمل می کند و وظایف مدیریتی خوشه را بر عهده دارد. این گره شامل مولفه های اصلی زیر است:

- API Server: نقطه اصلی دریافت فرمان های کوبرتیز به صورت REST<sup>۴۶</sup> است و آن را پردازش می کند. این سرور

مسئول اعتبارسنجی درخواست ها و اجرای آن ها بر روی خوشه است. همچنین، این مولفه به عنوان بخشی از مولفه های دیگر گره اصلی عمل می کند تا اطمینان حاصل شود که دستورات به درستی اجرا می شوند.

- Scheduler: مولفه ای است که تصمیم می گیرد کدام پادها بر روی کدام گره های کاری قرار گیرند. این فرایند بر اساس

منابع موجود و الزامات مشخص شده برای پادها صورت می گیرد. علاوه بر این، به طور مداوم وضعیت خوشه را رصد می کند تا بهترین تصمیم ها را برای مکان یابی پادها بگیرد.

- Controller Managers: مجموعه ای از فرآیندهایی است که حلقه های نظارتی را اجرا می کنند. این کنترل کننده ها

وضعیت خوشه را با حالت مطلوب مطابقت می دهند. به عنوان مثال، اگر یک پاد از کار افتاده باشد، یک کنترل کننده وظیفه دارد تا یک پاد جدید را برای جایگزینی ایجاد کند.

Cluster<sup>۴۱</sup>

Node<sup>۴۲</sup>

Bare-metal<sup>۴۳</sup>

Control plane<sup>۴۴</sup>

Worker<sup>۴۵</sup>

Representational State Transfer<sup>۴۶</sup>

• etcd: یک پایگاه داده توزیع شده است که تمام داده های مهم از جمله وضعیت خوش در هر لحظه، پیکربندی خوش،

اطلاعات مربوط به هر گره و کانتینرهای درون آن را در خود ذخیره می کند.

گره های کاری نیز پادهای اپلیکیشن های کاربر را برعهده دارند. این نودها شامل مولفه های زیر هستند:

• Kubelet: این مولفه وظیه مدیریت سلامت پادها را برعهده دارد. علاوه بر این اطمینان حاصل می کند که کانتینرها در

پادها بر اساس تنظیمات مشخص شده اجرا شوند و با API Server ارتباط برقرار کند تا وضعیت را به روز رسانی کند.

• Kube-proxy: وظیقه مدیریت ترافیک شبکه درون خوشه را برعهده دارند. این مولفه ارتباطات شبکه بین کانتینرها را

تسهیل می کند و از قوانین IPTables برای مسیر یابی ترافیک استفاده می کند.

در کوبرنتیز، چندین روش و نوع ذخیره سازی داده وجود دارد که می تواند بر اساس نیازهای برنامه و محیط اجرایی انتخاب شود. Volumes یکی از روش های اصلی برای ذخیره سازی داده ها در کوبرنتیز است. هر Volume به یک پاد متصل می شود و از طول عمر آن با پاد مرتبط است. انواع Volumes شامل:

Volumes یکی از روش های اصلی برای ذخیره سازی داده ها در کوبرنتیز است. هر Volume به یک Pod متصل

می شود و از طول عمر آن Pod پیروی می کند. انواع Volumes شامل:

emptyDir: یک Volume خالی که با شروع Pod ایجاد می شود و با حذف Pod نیز حذف می شود. مناسب برای

ذخیره سازی داده های موقت. hostPath: دسترسی به فایل ها و دایرکتوری های موجود در نود میزبان. این روش می تواند مشکلات امنیتی به همراه داشته باشد. nfs: استفاده از System File Network برای اشتراک گذاری فایل ها بین هر یک Pod.

Volume Persistent (PVC): persistentVolumeClaim استفاده می کند و برای ذخیره سازی

پایدار و دائمی مناسب است.

## فصل ۳

# MLOps

### ۱-۳ مقدمه

در حالی که مدل‌های یادگیری ماشین به طور گستردۀ توسعه یافته‌اند، انتقال آن‌ها از مفهوم آزمایشی به محیط تولید اغلب با شکست مواجه می‌شود. این فاصله بیشتر به خاطر این است که تاکنون توجه اصلی روی ساخت مدل‌ها بوده است، نه روی تولید محصولات یادگیری ماشین که قابلیت استفاده در محیط تولید را دارند. علاوه بر آن، مدیریت بخش‌ها و زیرساخت‌های پیچیده‌ای که برای یک استقرار موثر ضروری هستند نیز در این امر مغفول مانده‌اند. برای رفع این مسئله، مفهوم عملیات یادگیری ماشین یا MLOps معرفی شده است. MLOps بر روی خودکارسازی و عملیاتی کردن فرآیندهای یادگیری ماشین تمرکز دارد تا انتقال پروژه‌های یادگیری ماشین از مفهوم به تولید را تسهیل کند. این رویکرد شامل دیدگاه جامعی از طراحی سیستم، هماهنگی اجزا، تعریف نقش‌ها و مسئولیت‌ها می‌باشد. هدف کاهش خطأ به منظور افزایش قابلیت اطمینان و کارایی سیستم‌های یادگیری ماشین در کاربردهای واقعی می‌باشد. این فصل به بررسی تعریف، اصول، ابزار و معماری جامعی از یک پلتفرم MLOps پرداخته و در نهایت، محصولات و رقبا این حوزه را بررسی می‌کنیم.

### ۲-۳ تعریف مفاهیم اولیه

MLOps یا عملیات یادگیری ماشین به مجموعه‌ای از فرایندها، ابزارها و شیوه‌ها جهت مدیریت چرخه توسعه مدل‌های یادگیری ماشین در یک محیط عملیاتی اشاره دارد. همچنین این چرخه شامل همکاری بین دانشمندان داده و مهندسان DevOps است به گونه‌ای که این اطمینان حاصل شود که مدل‌ها به طور مؤثر توسعه، استقرار، پایش و بهروزرسانی می‌شوند. هدف MLOps افزایش سرعت، قابلیت اطمینان و مقیاس پذیری مدل‌های یادگیری ماشین و فرایند توسعه این مدل‌ها در تولید است؛

در حالی که خطرات ناشی از ریسک عدم موفقیت را نیز کاهش می‌دهد. همچنین به کارگیری MLOps فرایند مدیریت را ساده‌تر کرده، کیفیت را افزایش می‌دهد و استقرار مدل‌های یادگیری عمیق و یادگیری ماشین در محیط‌های تولید با مقیاس بزرگ را خودکار می‌کند. لذا می‌توان گفت یکی از اهداف MLOps، بهبود خودکارسازی و ارتقای کیفیت مدل‌های تولید و در عین حال توجه به الزامات تجاری و نظارتی است.

استقرار مدل‌های یادگیری ماشین روی محیط عملیاتی در MLOps اهمیت زیادی دارد، زیرا به سازمان‌ها کمک می‌کند تا مطمئن شوند که مدل‌هایشان در طول زمان دقیق، قابل اعتماد و کارآمد هستند. به طورکلی، MLOps با خودکار کردن بسیاری از مراحل مربوط به استقرار و مدیریت مدل‌های یادگیری ماشین، به دانشمندان و مهندسان داده اجازه می‌دهد تا با همکاری یکدیگر به ارائه سریع‌تر و کارآمدتر مدل‌های یادگیری ماشین دست یابند.

### ۱-۲-۳ اصول

برای تسهیل در رسیدن به اهداف فوق، تیم‌های MLOps از اصول زیر استفاده می‌کنند:

۱. خط لوله خودکار CI/CD و هماهنگ سازی جریان کار<sup>۱</sup>: خودکارسازی CI/CD شامل مراحل ساخت، آزمایش، تحویل و استقرار است که به توسعه‌دهندگان نسبت به موفقیت یا شکست مراحل مختلف بازخورد سریعی را ارائه داده و بهره‌وری کلی را افزایش می‌دهد [۱۸]. در همین حال، هماهنگ سازی جریان کاری وظایف یک خط لوله یادگیری ماشین را با استفاده از گراف‌های بدون حلقه‌ی جهت دار<sup>۲</sup> هماهنگ می‌کند، که ترتیب اجرای وظایف را با توجه به روابط و وابستگی‌ها تعیین می‌کند. ترکیب این دو رویکرد می‌تواند به بهبود عملکرد و کارایی تیم‌های توسعه و داده‌کاوی کمک کند [۱۹، ۲۰].

۲. کنترل نسخه مدل‌های یادگیری ماشین، مجموعه‌داده‌ها و کد منبع: با استفاده از نسخه‌بندی مدل، داده و کد منبع، می‌توان هر تغییر و اصلاحی را در طول زمان دنبال کرد، که این امر به توسعه‌دهندگان و محققان اجازه می‌دهد تا به راحتی به نسخه‌های قبلی بازگردند و نتایج را بازبینی کنند. این قابلیت برای حفظ یکپارچگی و شفافیت در پروژه‌های نرم‌افزاری و علمی بسیار حیاتی است [۱۸].

۳. نظارت و آموزش مدل یادگیری ماشین: آموزش مداوم<sup>۳</sup> در یادگیری ماشین به معنای آموزش دوره‌ای مدل‌های یادگیری ماشین بر اساس داده‌های جدید است. این فرآیند همیشه شامل یک مرحله ارزیابی برای سنجش تغییرات

---

Workflow<sup>۱</sup>  
Directed Acyclic Graph (DAG)<sup>۲</sup>  
Continuous Training (CT)<sup>۳</sup>

کیفیت مدل است [۲۱]. نظارت مداوم به معنای ارزیابی دوره‌ای داده‌ها، مدل‌ها (مانند دقت پیش‌بینی)، کد منبع و متابع زیرساختی است تا خطاهای یا تغییرات احتمالی که بر کیفیت محصول تاثیر می‌گذارند، شناسایی شوند. این فرآیند به توسعه‌دهنگان امکان می‌دهد تا به سرعت مشکلات را شناسایی و بطرف کنند و از افت عملکرد مدل جلوگیری کنند. یکی از دلایل لزوم آموزش مداوم، رانش داده یا مدل<sup>۴</sup> است، که به تغییرات تدریجی در داده‌ها یا عملکرد مدل در طول زمان اشاره دارد و می‌تواند باعث کاهش دقت پیش‌بینی‌ها شود [۲۲]. این اصل در MLOps برای اطمینان از عملکرد بهینه مدل‌ها و واکنش سریع به تغییرات محیطی و داده‌ها ضروری است. این فرآیند بهره‌وری را افزایش می‌دهد و کیفیت کلی سیستم‌های یادگیری ماشین را بهبود می‌بخشد. در نهایت، ترکیب آموزش و نظارت مداوم به توسعه‌دهنگان کمک می‌کند تا مدل‌ها را به روز نگه داشته و از تاثیرات منفی رانش داده یا مدل جلوگیری کنند [۲۳].

۴. ثبت فراداده<sup>۵</sup> یادگیری ماشین: ثبت فراداده برای هر مرحله در جریان کار یادگیری ماشین شامل ثبت جزئیات هر دوره آموزش مدل، مانند تاریخ و زمان آموزش، مدت زمان، پارامترهای استفاده شده و معیارهای عملکرد مدل می‌باشد [۲۰]. علاوه بر این، جزئیات مدل که شامل داده‌ها و کدهای استفاده شده است، باید ثبت شود تا قابلیت پیگیری کامل آزمایشات فراهم گردد. این امر به توسعه‌دهنگان کمک می‌کند تا تغییرات و نتایج را به دقت مستند کرده و در صورت نیاز به نسخه‌های قبلی بازگردند [۲۴].

۵. حلقه‌های بازخورد<sup>۶</sup>: حلقه‌های بازخورد به توسعه‌دهنگان اجازه می‌دهند تا به طور مداوم مدل‌ها را بهبود بخشنند، مشکلات را شناسایی و رفع کنند و از افت کیفیت جلوگیری کنند. این رویکرد به تضمین کیفیت و کارایی مدل‌های یادگیری ماشین کمک می‌کند و فرآیند توسعه را به یک چرخه تکراری و قابل بهبود تبدیل می‌کند که به سرعت به تغییرات و نیازهای جدید پاسخ می‌دهد [۲۴]. به عنوان مثال، یک حلقه بازخورد از مرحله مهندسی مدل آزمایشی به مرحله قبلی مهندسی ویژگی می‌تواند بسیار مفید باشد.

می‌توان اضافه کرد که یکی از اصول مهم که کمتر جنبه فنی دارد و در روح فرهنگی DevOps نیز جایگاه ویژه‌ای دارد، اصل همکاری<sup>۷</sup> است. این اصل بر امکان همکاری مسترک افراد بر روی داده‌ها، مدل‌ها و کدها تاکید دارد. علاوه بر جنبه‌های فنی، اصل همکاری به ایجاد فرهنگ کاری مشارکتی توجه دارد که هدف آن کاهش ایزوله سازی های حوزه‌ای بین نقش‌های مختلف است. چنین رویکردی باعث می‌شود تا افراد با تخصص‌های گوناگون به طور هم‌افزا با یکدیگر کار کنند، دانش خود را به اشتراک بگذارند و از هم بیاموزند.

Data or Model Drift<sup>۴</sup>Metadata<sup>۵</sup>feedback loops<sup>۶</sup>Collaboration<sup>۷</sup>

٣-٢-٢-اجزاء

پس از شناسایی اصولی که در قسمت قبل صحبت کردیم، اکنون اجزای دقیق یک معماری MLOps را توضیح داده و ارتباط هرکدام با اصول گفته شده را بیان می کنیم. ارجاعات داخل پرانتز به اصولی اشاره دارد که اجزای فنی در حال پیاده سازی هستند.

سازآرایی جریان کاری

سازآرایی جریان کاری<sup>۸</sup> به عنوان یکی از اجزای حیاتی در مدیریت و خودکارسازی جریان‌های کاری پیچیده در حوزه‌های مختلف از جمله یادگیری ماشین و مهندسی داده، نقش مهمی ایفا می‌کنند. این سیستم‌ها مانند شکل ۱-۳ از گراف‌های بدون حلقه جهت دار برای نمایش ترتیب اجرای وظایف استفاده می‌کنند. هر مرحله از این جریان کاری ممکن است شامل استخراج داده، آموزش مدل یا استنتاج باشد. این سیستم‌ها نه تنها ترتیب اجرای وظایف را مدیریت می‌کنند، بلکه وابستگی‌های متقابل بین وظایف را نیز مورد توجه قرار می‌دهند. هم چنین این ابزارها به کاربران امکان می‌دهند تا جریان‌های کاری را به صورت خودکار و مقیاس پذیر اجرا کنند. این امر به ویژه در محیط‌های بزرگ با داده‌های کلان اهمیت دارد [۲۰].

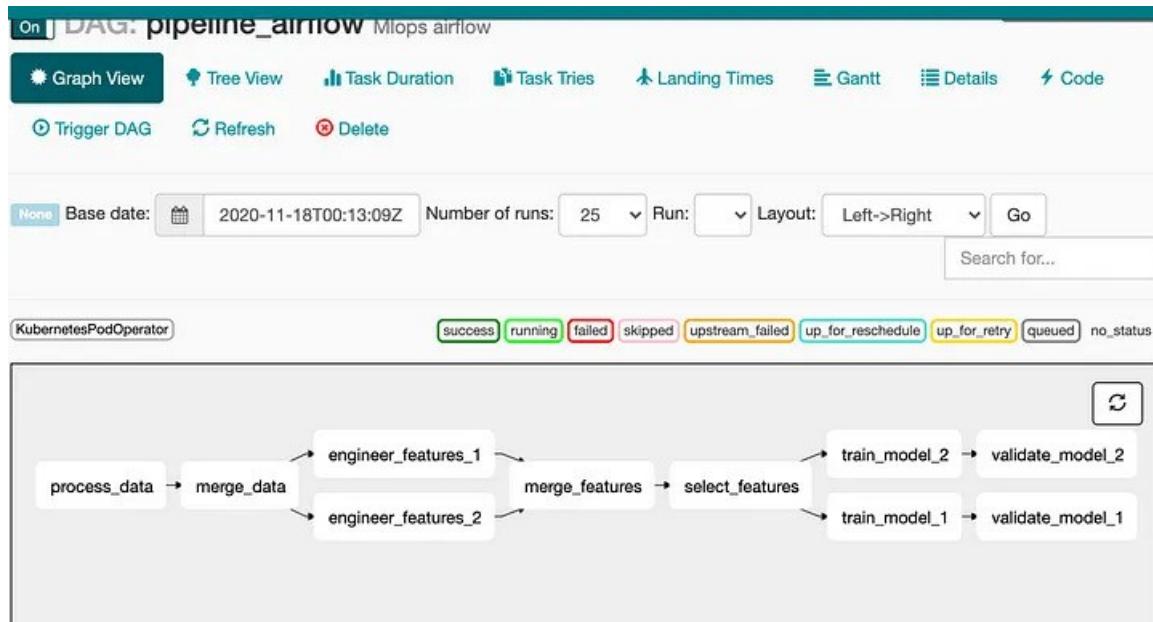
ابزارهای متن باز معروف در زمینه یادگیری ماشین Apache Airflow pipeline [۲۵] و Kubeflow pipeline [۲۶] می‌باشند. از Apache Airflow نیز Kubeflow Pipelines [۲۷] بیشتر برای استخراج، تبدیل و بارگذاری<sup>۹</sup> داده‌های بزرگ استفاده می‌کنند. بهخشی از پلتفرم Kubeflow [۲۶] است که برای اجرای جریان‌های کاری یادگیری ماشین بر روی کوبربنتیز طراحی شده است. از این ابزار به طور خاص برای توسعه و استقرار مدل‌های یادگیری ماشین در محیط‌های ابری مناسب است که در فصل های بعدی با آن بیشتر آشنا خواهیم شد.

انبار ویژگی

انباره ویژگی<sup>۱۰</sup> یک سیستم مدیریت داده است که به منظور ذخیره‌سازی، مدیریت و اشتراک‌گذاری ویژگی‌های مورد استفاده در مدل‌های پادگیری ماشین طراحی شده است. این سیستم (شکل ۲-۳) دو بخش اصلی است: پایگاه داده آنلاین و پایگاه داده آفلاین. هر یک از این پایگاه‌های داده نقش خاصی در فرآیند مدیریت و استفاده از ویژگی‌ها ایفا می‌کند.

پایگاه داده آفلاین برای ذخیره سازی و مدیریت ویژگی هایی استفاده می شود که در فرآیندهای آزمایش و تحلیل به کار می روند. این پایگاه داده معمولاً با تأخیر نسبتاً پیشتری نسبت به پایگاه داده آنلاین استفاده می شود و برای مواردی مناسب است

Workflow Orchestration<sup>A</sup>  
Extract, Transform, Load (ETL)<sup>B</sup>  
Feature Store<sup>C</sup>

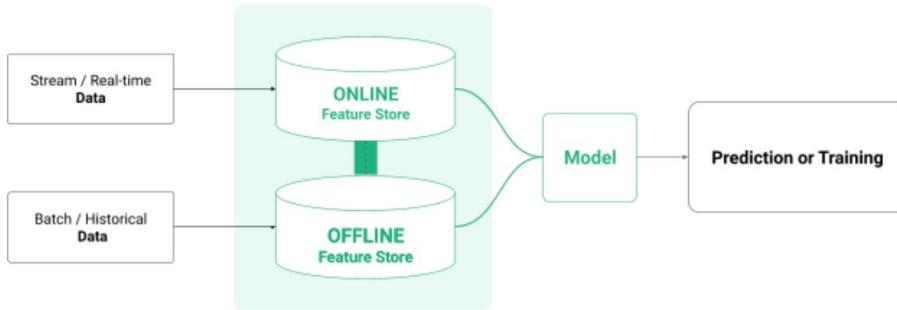


شکل ۱-۳: خط لوله در Apache Airflow

که نیاز به پردازش حجم زیادی از داده‌ها در مدت زمان طولانی تر دارند. ویژگی‌هایی که در این پایگاه داده ذخیره می‌شوند، اغلب در فرآیندهای آموزش مدل‌های یادگیری ماشین مورد استفاده قرار می‌گیرند.

پایگاه داده آنلاین برای ارائه ویژگی‌ها به صورت بلاذرنگ استفاده می‌شود و تأخیر کمی دارد. این پایگاه داده‌ها برای سیستم‌هایی مناسب هستند که نیاز به پاسخگویی سریع دارند. زمانی که یک مدل یادگیری ماشین نیاز به استفاده از ویژگی‌ها برای انجام پیش‌بینی‌های فوری دارد، داده‌ها از این پایگاه داده آنلاین بازیابی می‌شوند. این نوع پایگاه داده‌ها باید توانایی پشتیبانی از حجم بالای درخواست‌ها را داشته باشند تا بتوانند عملکرد مطلوبی را در شرایط عملیاتی فراهم کنند. ویژگی‌هایی که در این پایگاه داده ذخیره می‌شوند، اغلب در فرآیندهای استنتاج مدل‌های یادگیری ماشین مورد استفاده قرار می‌گیرند.

با استفاده از انباره ویژگی توسعه‌دهنگان می‌توانند ویژگی‌های از پیش پردازش شده را به صورت مرکز ذخیره کرده و به راحتی در پروژه‌های مختلف به اشتراک بگذارند، که این امر به تسريع فرآیند توسعه مدل‌ها و بهبود دقت پیش‌بینی‌ها کمک می‌کند. این سیستم‌ها معمولاً بر روی زیرساخت‌های ابری اجرا می‌شوند تا مقیاس‌پذیری بالا و کارایی مورد نیاز برای پردازش داده‌های کلان را فراهم کنند [۲۳]. از ابزار معروف متن باز برای می‌توان به [۲۸]Feast اشاره نمود.



شکل ۲-۳: انباره ویژگی

### بانک مدل

بانک مدل<sup>۱۱</sup> یکی از ابزارهای بسیار مهم در مدیریت مدل‌های یادگیری ماشین است که به تیم‌ها کمک می‌کنند تا مدل‌های خود را به صورت سازماندهی شده ذخیره، مدیریت و رده‌بافی کنند. هم چنین اطلاعات مربوط به هر مدل را از جمله نسخه، تاریخ آخرین آموزش، معیارهای ارزیابی و مستندات مربوطه را نگهداری می‌کند. این امر به تیم‌ها کمک می‌کند تا با استفاده از نسخه‌های مختلف مدل‌ها، آزمایش‌های مختلفی انجام دهند و بهترین مدل را انتخاب کنند. هم چنین به هنگام بروز مشکل در مدل‌های جدید، می‌توان از مدل‌های قابل قبول قبلی برای محیط عملیاتی استفاده کرد [۲۹]. از ابزار معرفی متن باز می‌توان به اشاره کرد.

### انبار فراداده

انبار فراداده یادگیری ماشین<sup>۱۲</sup> برای پیگیری و ذخیره‌سازی اطلاعات مربوط به هر مرحله از جریان کاری یادگیری ماشین استفاده می‌شوند. فراداده‌ها می‌توانند شامل جزئیاتی نظیر تاریخ و زمان آموزش مدل، مدت زمان هر مرحله از آموزش، پارامترهای استفاده شده، معیارهای عملکرد مدل، و سلسله‌مراتب مدل (مثل داده‌ها و کدهای استفاده شده) باشند. یکی از کاربردهای اصلی انبار فراداده‌ها، مدیریت کارآمد پروژه‌های پیچیده یادگیری ماشین است [۲۴]. به عنوان مثال، در پروژه‌های بزرگ که شامل آزمایش‌ها و مدل‌های متعددی هستند، پیگیری دقیق و منظم فراداده‌ها می‌تواند به تیم‌ها کمک کند تا نتایج قبلی را به راحتی بازبینی کنند، مشکلات را شناسایی کنند و بهینه‌سازی‌های لازم را انجام دهند. MLflow یک ابزار معروف برای یک سیستم پیشرفته مدیریت فراداده است که همراه با بانک مدل امکان مدیریت یکپارچه مدل‌ها و فراداده‌ها را فراهم می‌کند.

Model Registry<sup>۱۱</sup>  
ML Metadata Store<sup>۱۲</sup>

## استقرار مدل

استقرار کردن مدل<sup>۱۳</sup> به فرآیندی اشاره دارد که در آن مدل‌های یادگیری ماشین آماده برای استفاده، به کار گرفته می‌شوند تا به صورت عملیاتی به پیش‌بینی‌ها و استنتاج‌ها بپردازند. این فرآیند برای تبدیل مدل‌های آموزشی به ابزارهای قابل استفاده در محیط‌های تولیدی ضروری است و می‌تواند به صورت آنلاین برای پیش‌بینی‌های بلاذرنگ یا به صورت دسته‌ای<sup>۱۴</sup> برای پردازش حجم بالای داده‌ها پیاده‌سازی شود. در محیط‌های عملیاتی، فرآیند استقرار مدل به سه شکل اصلی بلاذرنگ، دسته‌ای و بدون سرور پیاده‌سازی می‌شود [۲۹].

در استنتاج بلاذرنگ<sup>۱۵</sup>، مدل‌های یادگیری ماشین به گونه‌ای پیاده‌سازی می‌شوند که بتوانند به سرعت و با کمترین تأخیر ممکن پیش‌بینی‌ها را انجام دهنند. این نوع استنتاج برای کاربردهایی نظیر سیستم‌های توصیه‌گر، تحلیل داده‌های حسگرها و برنامه‌های کاربردی که نیاز به پاسخ‌های سریع دارند، مناسب است. به عنوان مثال، در سیستم‌های پیشنهاددهی محتوا مانند نتفلیکس یا آمازون، مدل‌ها باید به صورت بلاذرنگ تحلیل کنند و پیشنهادهای شخصی‌سازی شده را ارائه دهند. تکنولوژی‌های مانند RESTful APIs و gRPC معمولاً برای پیاده‌سازی این نوع سرویس‌دهی استفاده می‌شوند.

استنتاج دسته‌ای<sup>۱۶</sup> برای پردازش حجم وسیعی از داده‌ها به کار می‌رود که معمولاً به صورت زمان‌بندی شده انجام می‌شود. این روش برای تحلیل داده‌های کلان و پردازش‌های بزرگ مناسب است. به عنوان مثال، در تجزیه و تحلیل رفتار مشتریان یک فروشگاه آنلاین، داده‌های خریدهای گذشته می‌تواند به صورت دسته‌ای پردازش شود تا الگوهای مختلف شناسایی شود. ابزارهایی مانند Apache Hadoop MapReduce و Hadoop Spark معمولاً برای پیاده‌سازی استنتاج دسته‌ای استفاده می‌شوند.

در استنتاج بدون سرور<sup>۱۷</sup>، مدل‌ها به صورت پویا و بر اساس تقاضا اجرا می‌شوند که هزینه و مقیاس‌بندیری را بهینه می‌کند. این نوع استنتاج زمانی مورد استفاده قرار می‌گیرد که نیاز به سرویس‌دهی مقیاس‌بندیر و مقرن به صرفه باشد. در استنتاج بدون سرور، مدل‌ها فقط زمانی که لازم است اجرا می‌شوند و بنابراین منابع بهینه‌سازی می‌شوند. سرویس‌های ابری مانند AWS Lambda و Google Cloud Functions معمولاً برای پیاده‌سازی این نوع استنتاج استفاده می‌شوند. از ابزارهای معروف متن باز برای استقرار مدل می‌توان به Knative [۳۲] اشاره کرد.

Model Serving<sup>۱۳</sup>

Batch<sup>۱۴</sup>

Real-time Inference<sup>۱۵</sup>

Batch Inference<sup>۱۶</sup>

Serverless Inference<sup>۱۷</sup>

## ناظارت

ناظارت<sup>۱۸</sup> در یادگیری ماشین یکی از مولفه‌های حیاتی برای تضمین عملکرد بهینه مدل‌ها و زیرساخت‌های مرتبط است. ناظارت مداوم بر مدل‌های یادگیری ماشین به دلایلی از جمله اطمینان از دقت پیش‌بینی‌ها، شناسایی ناهنجاری‌ها و بهبود مداوم عملکرد مدل‌ها ضروری است [۳۳]. ابزارهایی مانند TensorBoard، Kubeflow و MLflow نیز نقش مهمی در ناظارت بر مدل‌های یادگیری ماشین ایفا می‌کنند. TensorBoard به ویژه برای مصورسازی و تحلیل مراحل مختلف آموزش مدل‌ها مفید است.

ناظارت در یادگیری ماشین تنها به مدل‌ها محدود نمی‌شود؛ بلکه زیرساخت‌های مرتبط با یادگیری ماشین نیز نیاز به ناظارت دارند. این ناظارت شامل ناظارت بر فرآیندهای CI/CD، هماهنگی سرویس‌ها، خوش‌های عملیاتی کوبرنتیز و گره‌های محاسباتی می‌شود [۲۴]. یکی از ابزارهای رایج برای ناظارت، Prometheus است که به همراه Grafana برای مصورسازی داده‌ها استفاده می‌شود. علاوه بر این پشته ELK (Kibana, Logstash, Elasticsearch) نیز یک مجموعه قدرتمند برای جستجو، تحلیل و مصورسازی لاگ‌های سیستم است که می‌تواند به شناسایی و رفع سریع مشکلات کمک کند. ابزارهای ناظارتی به مهندسان اجازه می‌دهند تا هر گونه ناهنجاری در زیرساخت‌ها را به سرعت شناسایی و رفع کنند، که این امر موجب کاهش زمان از کار افتادگی سیستم و افزایش بهره‌وری می‌شود.

## زیرساخت آموزش و استقرار مدل

این زیرساخت شامل منابع محاسباتی اصلی مانند واحد پردازش مرکزی، حافظه واحد پردازش گرافیکی<sup>۱۹</sup> است که برای پردازش داده‌ها و اجرای الگوریتم‌های پیچیده می‌باشد. زیرساخت‌ها می‌توانند به دو شکل توزیع شده<sup>۲۰</sup> و غیرتوزیع شده پیاده‌سازی شوند. زیرساخت‌های غیرتوزیع شده معمولاً شامل ماشین‌های محلی هستند که با وجود سادگی در پیاده‌سازی، محدودیت‌هایی در مقیاس‌پذیری دارند. از سوی دیگر، زیرساخت‌های توزیع شده که معمولاً در بستر محاسبات ابری اجرا می‌شوند، امکان توزیع بار کاری بین چندین گره محاسباتی را فراهم می‌کنند و از این طریق مقیاس‌پذیری و کارایی بالاتری ارائه می‌دهند. یکی از ابزار محبوب برای مدیریت و سازآرایی محاسبات توزیع شده، کوبرنتیز است که امکان مدیریت کانتینرها و توزیع بار کاری بین گره‌ها را فراهم می‌کند. هم چنین، Red Hat OpenShift نیز به عنوان یک پلتفرم دیگر شناخته می‌شود که قابلیت‌های مشابهی ارائه می‌دهد [۲۹].

برای بهینه‌سازی عملکرد مدل‌های یادگیری عمیق، استفاده از واحد پردازش گرافیکی که برای ضرب ماتریسی

Monitoring<sup>۱۸</sup>

GPU<sup>۱۹</sup>

Distributed<sup>۲۰</sup>

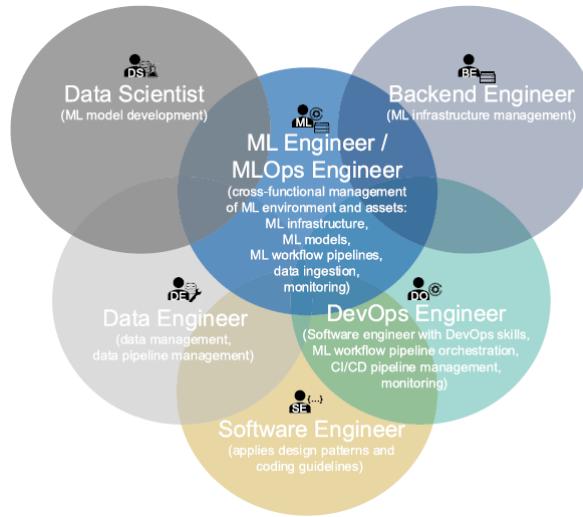
بهینه‌سازی شده‌اند، استفاده می‌شوند. در دستگاه‌های لبه<sup>۲۱</sup> به دلیل محدودیت‌های فضای توان محاسباتی و مصرف انرژی، اجرای مدل‌های یادگیری عمیق پیچیده به چالش‌های خاصی مواجه است. برای غلبه بر این محدودیت‌ها و بهینه‌سازی عملکرد مدل‌ها در این دستگاه‌ها، تکنیک‌های مختلفی مورد استفاده قرار می‌گیرد. یکی از این تکنیک‌ها، استفاده از شبکه‌های عصبی کوانتیز شده است. در کوانتیزاسیون، وزن‌ها و محاسبات شبکه عصبی از دقت کامل (به عنوان مثال، اعداد با دقت ۳۲ بیت) به اعداد با دقت پایین‌تر (مانند ۸ بیت یا حتی کمتر) کاهش می‌یابند. این کاهش دقت باعث کاهش حجم مدل و کاهش نیاز به منابع محاسباتی می‌شود. علاوه بر این، با استفاده از عملیات نقطه شناور کم‌دقت، می‌توان محاسبات را سریع‌تر و با مصرف انرژی کمتری انجام داد. تکنیک دیگر، هرس کردن<sup>۲۲</sup> است که شامل حذف اتصالات غیرضروری و وزن‌های کوچک در شبکه عصبی می‌شود. این فرآیند باعث کاهش تعداد پارامترهای مدل می‌شود، بدون آنکه تاثیر قابل توجهی بر دقت مدل بگذارد. هرس کردن مدل را سبک‌تر و اجرای آن را سریع‌تر می‌کند، که این امر برای دستگاه‌های لبه با منابع محدود بسیار مفید است.

### مخزن کد منبع

مخزن کد منبع به عنوان یک نقطه مشترک برای نگهداری و مدیریت کدهای مربوط به مدل‌های یادگیری ماشین یک سازمان عمل می‌کند. با استفاده از سیستم‌های مدیریت نسخه مانند گیت، تیم‌ها می‌توانند به راحتی تغییرات کد را پیگیری کرده و در صورت لزوم به نسخه‌های قبلی کد بازگردند. این مخزن همچنین به خودکارسازی فرآیند CI/CD کمک می‌کند، به طوری که هرگونه تغییر در کد به طور خودکار خط لوله را فعال کرده و تغییرات تست، ارزیابی و در محیط‌های مختلف مستقر می‌شوند. می‌توان از ابزار متن باز برای پیاده‌سازی آن به GitLab<sup>۳۴</sup> و Jenkins<sup>۳۵</sup> اشاره نمود.

### خط لوله CI/CD

همان طور که در گذشته نیز راجع به آن صحبت کردیم، خط لوله CI/CD به تیم‌ها اجازه می‌دهند تا کدهای مدل و داده‌ها را به صورت مداوم تست، تأیید و استقرار دهند. در این فرآیند، مدل‌ها به طور خودکار بازآموزی و بهبود می‌یابند و در محیط‌های مختلف (توسعه، تست، تولید) به صورت پیوسته بروزرسانی می‌شوند. این کار نه تنها باعث افزایش کیفیت و دقت مدل‌ها می‌شود بلکه زمان توسعه و عرضه را نیز به طرز قابل توجهی کاهش می‌دهد. در MLOps این خط لوله‌ها در مراحل مختلف از جمله آموزش مدل، ارزیابی، استقرار و نظارت بر عملکرد مدل‌ها و هم‌چنین داده‌ها استفاده می‌شوند [۲۴]. از ابزارهای مناسب برای این کار می‌توان به Jenkins<sup>۳۶</sup> و GitLab CI<sup>۳۴</sup> نام برد.



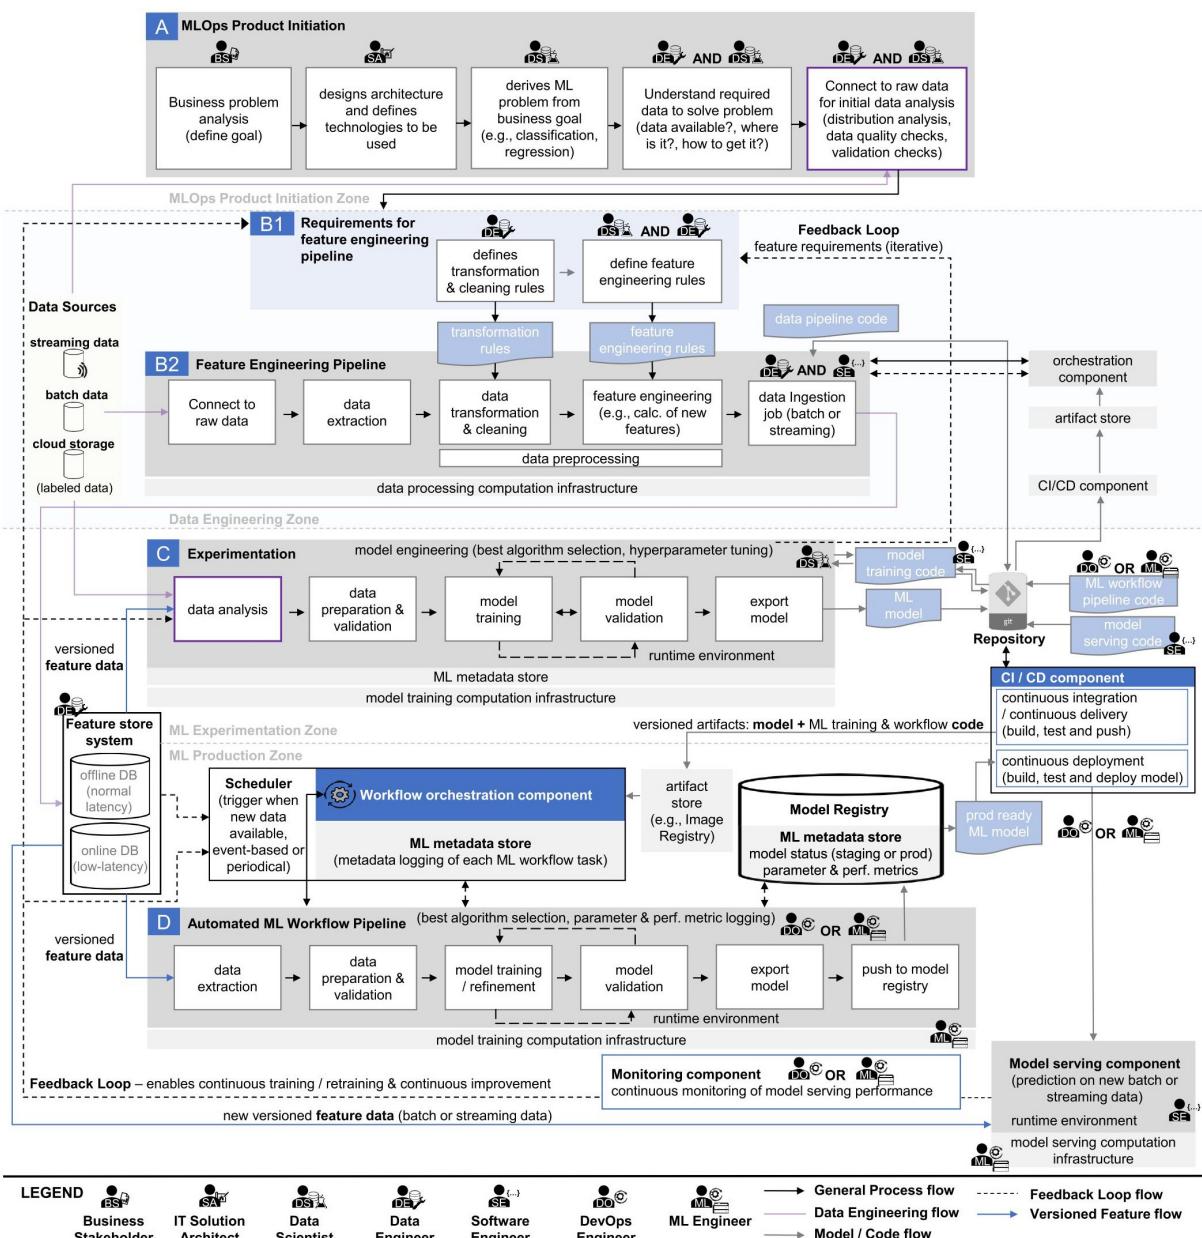
شکل ۳-۳: نقش ها و اشتراکات آنها در پارادایم MLOps

### ۳-۲-۳ نقش ها

در تولید یک پلتفرم MLOps، نقش های متعددی وجود دارد که همکاری آنها برای طراحی، مدیریت، اتوماسیون و بهره برداری از سیستم های یادگیری ماشین در محیط تولید بسیار حیاتی است. در ابتدا سهام دار کسب و کار<sup>۲۳</sup> وظیفه تعیین اهداف کسب و کار و استراتژی بازگشت سرمایه محصول یادگیری ماشین را بر عهده دارد. معمار، معماری سیستم را طراحی کرده و فناوری های مناسب را انتخاب می کند. دانشمند داده مسئله کسب و کار را به مسئله یادگیری ماشین ترجمه کرده و مدل ها را مهندسی می کند. مهندس داده خط لوله های داده و ویژگی را ایجاد و مدیریت می کند و داده ها را به درستی به سیستم های پایگاه داده و انبار ویژگی ها تزریق می کند. مهندس نرم افزار با استفاده از الگوهای طراحی، مسئله یادگیری ماشین را به یک محصول مهندسی شده تبدیل می کند. مهندس DevOps خودکارسازی CI/CD، سازآرایی جریان کاری یادگیری ماشین و استقرار مدل در تولید را تضمین می کند. در نهایت، مهندس MLOps نقش ترکیبی از مهارت های چندگانه را دارد و زیرساخت یادگیری ماشین را ایجاد و مدیریت کرده، خط لوله های جریان کاری را خودکار می کند و مدل ها و زیرساخت را در تولید نظارت می کند. این نقش ها که در شکل ۳-۳ نشان داده شده است، با همکاری و هماهنگی نزدیک می توانند MLOps را به شکلی مؤثر و کارآمد پیاده سازی کنند، که نتیجه آن یک سیستم یادگیری ماشین پایدار و قابل اعتماد در محیط تولید خواهد بود. همکاری میان این نقش ها تضمین می کند که تمام جنبه های مربوط به توسعه، استقرار و نگهداری مدل های یادگیری ماشین به درستی مدیریت شود و به اهداف کسب و کار دست یابند.

### ۳-۳ معماری جامع

بر اساس اصول، اجزا و نقش‌های بیان شده، یک معماری جامع از یک پلتفرم MLOps طراحی شده است. این معماری که در شکل ۴-۳ نشان داده شده جریان‌کارها و ترتیب وظایف در مراحل مختلف را ترسیم می‌کند. این معماری به‌گونه‌ای طراحی شده که کاربران می‌توانند مناسب‌ترین فناوری‌ها و چارچوب‌ها را بر اساس نیازهای خود انتخاب کنند. این انعطاف‌پذیری به کاربران این امکان را می‌دهد که پلتفرم MLOps را با استفاده از ترکیبی از ابزارهای متan باز، استفاده از سرویس‌های ابری یا



شکل ۴-۳: معماری جامع MLOps

رویکردهای ترکیبی پیاده‌سازی کنند. نرم‌افزارهای سازمانی و خدمات ابری اغلب از طریق API‌ها با ابزارهای متن‌باز یکپارچه می‌شوند و امکان ترکیب بی‌دردسر فناوری‌های مختلف را فراهم می‌کنند. این معماری یک معماری جامع بوده و هر سازمان می‌تواند بر حسب نیاز و هدف خود در حل مسئله یادگیری ماشین، این معماری را شخصی سازی کرده و از پیاده‌سازی قسمت هایی از آن صرف نظر کند.

### مرحله اولیه

در فرآیند شروع محصول MLOps، اولین مرحله با تحلیل کسب‌وکار آغاز می‌شود. کارشناس مربوط وظیفه دارد تا مشکلاتی را شناسایی کند که با استفاده از یادگیری ماشین قابل حل باشند. پس از شناسایی مشکل، معمار وارد عمل می‌شود. او طراحی معماری کلی سیستم یادگیری ماشین را تعریف کرده و پس از ارزیابی دقیق، تکنولوژی‌های مورد نیاز را انتخاب می‌کند. در مرحله بعدی، دانشمند داده باید از هدف کسب‌وکار، یک مسئله یادگیری ماشین استخراج کند. این مسئله بسته به ماهیت مشکل کسب‌وکار می‌تواند شامل طبقه‌بندی، رگرسیون یا دیگر روش‌های یادگیری ماشین باشد. برای این منظور، دانشمند داده با همکاری مهندس داده باید داده‌های موجود را تجزیه و تحلیل کند تا بهترین رویکرد برای حل مسئله را انتخاب کند. این مرحله نیازمند دانش عمیق از روش‌های مختلف یادگیری ماشین و توانایی تطبیق آن‌ها با نیازهای خاص پژوهه است. نکته مهم در این فرآیند، نیاز به داده‌های برچسب‌گذاری شده است که برای الگوریتم‌های نظارت شده ضروری هستند. در این معماری منابع داده از قبل دارای داده‌های برچسب‌گذاری شده بوده‌اند، زیرا فرآیند برچسب‌گذاری در مراحل قبلی انجام شده است.

### خط لوله مهندسی ویژگی

در فرآیند توسعه مدل‌های یادگیری ماشین، مهندسی ویژگی‌ها<sup>۲۴</sup> به عنوان یکی از گام‌های حیاتی شناخته می‌شود که مستلزم تعیین نیازمندی‌های اساسی و پیاده‌سازی خط لوله مهندسی ویژگی‌ها است. این مرحله شامل تعریف و پیاده‌سازی قواعد تبدیل و پاک‌سازی داده‌ها، و همچنین ایجاد ویژگی‌های جدید و پیشرفته بر اساس ویژگی‌های موجود است. ابتدا نیازمندی‌های مهندسی ویژگی‌ها توسط متخصص داده و مهندس داده تعریف می‌شوند. در این مرحله، قواعد تبدیل داده‌ها<sup>۲۵</sup> مانند نرمال‌سازی و تجمعی، و همچنین قواعد پاک‌سازی داده‌ها<sup>۲۶</sup> تعیین می‌شوند تا داده‌ها به فرمت قابل استفاده تبدیل شوند. این قواعد اولیه، به صورت تکراری و بر اساس بازخوردهای حاصل از مراحل آزمایشی مهندسی مدل و یا از طریق نظارت بر

Feature Engineering<sup>۲۴</sup>

Data Transformation<sup>۲۵</sup>

Data Cleaning<sup>۲۶</sup>

عملکرد مدل، تنظیم و بهبود می‌یابند.

با تعریف نیازمندی‌های اولیه، مهندس داده و مهندس نرم‌افزار اقدام به ساخت نمونه اولیه خط لوله تولید ویژگی‌ها می‌کنند. این خط لوله باید به صورت مدام و بر اساس بازخورددهای دریافتی از مراحل مختلف، به روزرسانی و بهبود یابد. مراحل کلیدی پیاده‌سازی خط لوله تولید ویژگی‌ها به صورت زیر است:

- اتصال به داده‌های خام: اولین مرحله در پیاده‌سازی خط لوله تولید ویژگی‌ها، اتصال به منابع داده خام است. این داده‌ها می‌توانند از منابع مختلفی مانند داده‌های جریانی<sup>۲۷</sup>، داده‌های دسته‌ای<sup>۲۸</sup> یا داده‌های ذخیره شده در ابر<sup>۲۹</sup> باشند. داده‌های جریانی به صورت پیوسته و بلاذرنگ دریافت می‌شوند، داده‌های دسته‌ای ثابت به صورت دوره‌ای و در حجم بالا جمع‌آوری و پردازش می‌شوند و داده‌های ذخیره شده در ابر از طریق سیستم‌های ابری مقیاس پذیر و انعطاف پذیر ذخیره می‌شوند. اتصال به منابع داده باید به گونه‌ای انجام شود که داده‌ها به راحتی قابل استخراج و پردازش باشند.
- استخراج داده‌ها: پس از اتصال به منابع داده، مرحله بعدی استخراج داده‌ها از این منابع است. این مرحله شامل خواندن داده‌ها از پایگاه‌های داده، فایل‌های CSV یا دیگر منابع داده است.
- پیش‌پردازش داده‌ها: در این مرحله، داده‌های استخراج شده برای تبدیل به فرم قابل استفاده، پیش‌پردازش می‌شوند. پیش‌پردازش شامل مراحل مختلفی مانند پاکسازی داده‌ها، مدیریت مقادیر مفقود، حذف نویز، و نرمال‌سازی مقادیر است. هدف اصلی این مرحله، آماده‌سازی داده‌ها به گونه‌ای است که بتوانند به عنوان ورودی‌های مدل یادگیری ماشین استفاده شوند.
- استخراج ویژگی‌های جدید و پیشرفت: یکی از مهم‌ترین مراحل در خط لوله تولید ویژگی‌ها، استخراج ویژگی‌های جدید و پیشرفت است. این ویژگی‌ها بر اساس ویژگی‌های موجود و با استفاده از تکنیک‌های مختلفی مانند ترکیب ویژگی‌ها، اعمال توابع ریاضی، و بهره‌گیری از روش‌های آماری ایجاد می‌شوند. این مرحله به مدل یادگیری ماشین کمک می‌کند تا الگوهای پیچیده‌تری را در داده‌ها شناسایی کند و دقیق پیش‌بینی‌های خود را افزایش دهد.
- انتقال ویژگی‌ها به انبار ویژگی‌ها: در نهایت، داده‌های پردازش شده و ویژگی‌های محاسبه شده به انبار ویژگی‌ها وارد می‌شوند. این انبار می‌تواند شامل پایگاه‌های داده آنلاین یا آفلاین باشد. این بارگذاری باید به گونه‌ای انجام شود که دسترسی سریع و کارآمد به داده‌ها برای مراحل بعدی آموزش مدل فراهم شود.

Streaming Data<sup>۲۷</sup>

batch data<sup>۲۸</sup>

Cloud Storage<sup>۲۹</sup>

در خط تولید ویژگی‌ها، مهندس نرم افزار به کمک مهندس داده کدهای مورد نیاز برای CI/CD و سازآرایی را تعریف می‌کند تا وظایف خط تولید ویژگی‌ها به درستی هماهنگ شوند. این نقش شامل تنظیم منابع زیرساختی برای اطمینان از مقیاس پذیری و عملکرد بهینه خط تولید است. با این تنظیمات، خط تولید ویژگی‌ها می‌تواند به طور مداوم به روزرسانی شده و بر اساس بازخوردها بهبود یابد، که این امر بهبود عملکرد مدل‌های یادگیری ماشین را تضمین می‌کند.

برای پیاده‌سازی خطوط تولید ویژگی‌ها، از ابزارها و فناوری‌های مختلفی استفاده می‌شود. برخی از این ابزارها شامل Apache Airflow و ابزارهای ETL مانند Apache Kafka، Apache Spark وApache Spark می‌باشند. این ابزارها می‌توانند آن در پردازش موازی و تحلیل داده‌های بزرگ بسیار محبوب است. به عنوان مثال، در یک پروژه پردازش زبان طبیعی<sup>۳۷</sup> با استفاده از اسپارک، داده‌های متنه بزرگ پردازش و ویژگی‌های متنه جدید محاسبه شدند [۳۷]. در پروژه دیگری در یک موسسه مالی، داده‌های اعتباری مشتریان با استفاده از اسپارک پردازش و ویژگی‌های مرتبط برای مدل ریسک اعتباری ایجاد شدند [۳۸]. Apache Kafka نیز برای بارگذاری داده‌های جریانی بلاذرنگ به کار گرفته می‌شود. هم چنین از Feast به همراه پایگاه داده‌های معروف مانند PostgreSQL و Redis نیز برای انبار ویژگی‌ها استفاده می‌شود.

## بررسی و آزمایش

مرحله آزمایش مدل در فرآیند یادگیری ماشین یک بخش حیاتی است که بیشتر توسط دانشمند داده به همراه مهندس نرم افزار انجام می‌شود. قبل از شروع به کار، مهندس داده به همراه مهندس نرم افزار برای اطمینان از عملکرد درست ابزار و منابع، محیط و سخت افزار را پیکربندی می‌کنند. حال فرآیند آزمایش مدل شروع می‌شود:

- اتصال به انبار ویژگی: دانشمند داده به سیستم انبار ویژگی‌ها متصل می‌شود تا داده‌ها را برای تجزیه و تحلیل دریافت کند. در صورت نیاز، داده خام نیز می‌تواند برای تحلیل‌های اولیه مورد استفاده قرار گیرد. اگر تغییراتی در داده‌ها لازم باشد، این تغییرات به تیم مهندسی داده گزارش می‌شود، که نتیجه آن می‌تواند منجر به تغییر قواعد تبدیل، پاک‌سازی داده‌ها و خط تولید ویژگی‌ها شود.

- آماده‌سازی و اعتبارسنجی داده‌ها: داده‌ها از سیستم انبار ویژگی‌ها جمع‌آوری و اعتبارسنجی می‌شوند. این مرحله شامل آماده‌سازی داده‌ها و تقسیم آنها به مجموعه‌های آموزش و تست و ارزیابی است تا مدل‌ها بتوانند به طور موثری آموزش داده شوند.

- آموزش و اعتبارسنجی مدل: در این مرحله، دانشمند داده الگوریتم‌های مختلف و پارامترهای آنها را ارزیابی می‌کند تا

بهترین ترکیب را پیدا کند. آموزش مدل با استفاده از داده‌های آموزشی شروع می‌شود و مهندس نرم‌افزار در ایجاد کدهای آموزشی بهینه کمک می‌کند. مدل‌ها با استفاده از پارامترهای مختلف به صورت تعاملی آموزش و اعتبارسنجی می‌شوند. این فرآیند تکراری است و تا زمانی که مدل به عملکرد مطلوبی برسد، ادامه می‌یابد. هدف این مرحله شناسایی بهترین الگوریتم و پارامترهای بهینه است.

- استخراج مدل و ثبت کد: پس از شناسایی و انتخاب بهترین مدل، دانشمند داده مدل نهایی را استخراج کرده و کدهای مربوطه را در مخزن کد منبع قرار می‌دهد. این کدها شامل تمامی اسکریپتها و مستنداتی است که برای تولید، آموزش و ارزیابی مدل استفاده شده‌اند. در همین زمان، مهندس DevOps یا مهندس یادگیری ماشین کدهای مربوط به خط لوله یادگیری ماشین را آماده و در مخزن قرار می‌دهد. این خط لوله شامل اسکریپتها و تنظیماتی است که برای خودکارسازی فرآیندهای مختلف یادگیری ماشین مانند آموزش، ارزیابی و استقرار مدل مورد نیاز است. با انجام این کار، سیستم CI/CD به صورت خودکار تغییرات را تشخیص داده و فرآیند ساخت، آزمون و تحويل مدل را آغاز می‌کند. در مرحله ساخت، مصنوعات مدل<sup>۳۱</sup> و کدهای مرتبط ایجاد می‌شوند. در مرحله آزمون، صحت و عملکرد مدل بررسی می‌شود و در نهایت، در مرحله تحويل مدل نهایی به مخزن مصنوعات ارسال می‌شود تا برای استفاده در محیط عملیاتی آماده باشد.

در مرحله آزمایش، ابزارهای مبتنی بر Notebook Jupyter [۴۰] به طور گسترده استفاده می‌شوند. این ابزارها به دانشمندان داده اجازه می‌دهند تا داده‌ها را آماده، مدل‌ها را آموزش، ارزیابی و بهینه‌سازی کنند. همچنین برای پیگیری و مدیریت آزمایش‌ها از ابزارهایی مانند MLflow و TensorBoard استفاده می‌شود.

### خودکارسازی جریان کاری یادگیری ماشین

خودکارسازی جریان کاری یادگیری ماشین شامل مجموعه‌ای از فرآیندهای پیچیده و حیاتی است که توسط مهندس DevOps و مهندس یادگیری ماشین مدیریت می‌شود. این فرآیندها شامل مدیریت محیط‌های اجرایی و زیرساخت‌های لازم برای آموزش مدل‌ها است که از منابع سخت‌افزاری و فریمورک‌های محاسباتی نظری کوبرنتیز استفاده می‌کنند. در این سیستم، یک مولفه ارکستراسیون وظایف مختلف را در جریان کاری خودکار یادگیری ماشین هماهنگ می‌کند. این مولفه وظایف را به محیط‌های مجزا (مانند کانتینرها) تخصیص داده و فراداده‌های هر وظیفه را در قالب لاگ‌ها، و سایر اطلاعات جمع‌آوری می‌کند. مراحل

اجرای این فرآیند که به قسمت قبل خیلی شباهت دارد به صورت زیر است:

- استخراج داده‌ها: اولین مرحله در این فرآیند، استخراج داده‌ها از سیستم‌های انبار ویژگی‌ها است. این داده‌ها می‌توانند از پایگاه‌های داده آنلاین یا آفلاین استخراج شوند. بسته به نیاز مورد استفاده، داده‌ها از منابع مختلفی استخراج شده و برای مراحل بعدی آماده می‌شوند.
  - آماده‌سازی و اعتبارسنجی داده‌ها: در این مرحله، داده‌ها به صورت خودکار آماده‌سازی و اعتبارسنجی می‌شوند. همچنین، تقسیم‌بندی داده‌ها به مجموعه‌های آموزش و تست نیز به صورت خودکار انجام می‌گیرد. این فرآیند تضمین می‌کند که داده‌های ورودی به مدل‌ها با کیفیت و قابل اعتماد باشند.
  - آموزش مدل نهایی: پس از آماده‌سازی داده‌ها، مدل نهایی بر روی داده‌های جدید و نادیده آموزش داده می‌شود. الگوریتم‌ها و ابرپارامترها بر اساس تنظیمات مراحل آزمایشی قبلی از پیش تعریف شده‌اند. در این مرحله، مدل آموزش داده شده و بهینه‌سازی می‌شود تا بهترین عملکرد ممکن را ارائه دهد.
  - ارزیابی و تنظیم مدل: مدل آموزش‌دیده شده به صورت خودکار ارزیابی می‌شود و در صورت نیاز، ابرپارامترها تغییر می‌کنند. این فرآیند به صورت تکراری انجام می‌شود تا زمانی که معیارهای عملکرد نشان‌دهنده نتایج مطلوب باشند. این تکرارها تا دستیابی به یک مدل با عملکرد بهینه ادامه می‌یابند.
  - ثبت و ذخیره مدل: مدل نهایی آموزش‌دیده شده سپس ذخیره شده و به یک مخزن مدل منتقل می‌شود. این مخزن مدل، مدل‌ها را به صورت کد یا کانتینر همراه با فایل‌های تنظیمات و محیط ذخیره می‌کند. این امر تضمین می‌کند که مدل‌ها به راحتی قابل دسترسی و استفاده مجدد باشند.
- برای هر بار آموزش مدل، مخزن فراداده‌ها پارامترهای مورد نیاز برای آموزش مدل و معیارهای عملکرد حاصل را ثبت می‌کند. این شامل ثبت جزئیات هر دوره آموزش مدل، مانند تاریخ و زمان آموزش، مدت زمان، پارامترهای استفاده شده و معیارهای عملکرد مدل می‌باشد. همچنین نسخه و وضعیت مدل (مثلاً آماده برای تولید یا در حال توسعه) نیز ثبت می‌شود. پس از انتقال مدل با عملکرد بالا از مرحله آزمایش به تولید، این مدل به طور خودکار به مهندس DevOps یا مهندس یادگیری ماشین برای استقرار مدل تحویل داده می‌شود. در این مرحله، ابزار مدیریت CI/CD مانند ArgoCD، خط لوله CD را اجرا می‌کند. مدل آماده و کدهای استقرار مدل که توسط مهندس نرم‌افزار تهیه شده‌اند، فراخوانی می‌شوند. خط لوله CD وظیفه ساخت و آزمایش مدل و کدهای استقرار مدل برای استقرار در محیط عملیاتی را بر عهده دارد. مؤلفه استقرار مدل مانند Knative پیش‌بینی‌ها را بر اساس داده‌های جدید و دیده نشده از سیستم انبار ویژگی‌ها انجام می‌دهد. این مؤلفه می‌تواند توسط مهندس نرم‌افزار به صورت آنلاین برای پیش‌بینی‌های زمان واقعی یا دسته‌ای برای داده‌های کلان طراحی شود. برای پیش

بینی‌های زمان واقعی، ویژگی‌ها باید از پایگاه داده آنلاین با تأخیر کم دریافت شوند، در حالی که برای پیش‌بینی‌های دسته‌ای، ویژگی‌ها می‌توانند از پایگاه داده آفلاین با تأخیر معمولی دریافت شوند. برنامه‌های استقرار مدل اغلب با استفاده از یک کانتینر پیاده‌سازی و تنظیم می‌شوند و درخواست‌های پیش‌بینی را از طریق REST API پاسخ می‌دهند. هنگام استقرار یک برنامه یادگیری ماشین، استفاده از آزمایش B/A به عنوان یک استراتژی تست خوب توصیه می‌شود تا در یک سناریوی واقعی مشخص شود که کدام مدل بهتر عمل می‌کند.

مؤلفه نظارتی به صورت پیوسته عملکرد مدل و زیرساخت‌ها را پایش می‌کند. زمانی که یک آستانه خاص مانند کاهش دقیق پیش‌بینی‌ها تشخیص داده شود، اطلاعات از طریق حلقه بازخورد ارسال می‌شود. این حلقه امکان آموزش و بازآموخته مداوم<sup>۳۲</sup> و بهبود مستمر را فراهم می‌کند. اطلاعات از مؤلفه نظارتی مدل به چندین نقطه مانند مرحله آزمایش، مرحله تولید ویژگی و مهندسی داده منتقل می‌شود. بازخورد به مرحله آزمایش توسط دانشمند داده برای بهبود بیشتر مدل‌ها مورد استفاده قرار می‌گیرد. بازخورد به مرحله تولید ویژگی نیز امکان تغییر در تولید ویژگی‌های برای سیستم انبار ویژگی‌ها را فراهم می‌کند. تشخیص رانش داده به عنوان یک مکانیزم بازخورد نیز می‌تواند آموزش مستمر را فعال کند. رانش داده به تغییرات تدریجی یا ناگهانی در توزیع داده‌های ورودی مدل‌های یادگیری ماشین گفته می‌شود که می‌تواند باعث کاهش دقیق و کارایی مدل‌ها شود. این تغییرات ممکن است به دلیل عوامل مختلفی مانند تغییر در رفتار کاربران، تغییر در شرایط محیطی، خرابی سنسورها و یا تغییرات سیستمی رخ دهنده. رانش داده به دو نوع اصلی تقسیم می‌شود:

**رانش مفهوم<sup>۳۳</sup>**: تغییر در توزیع برچسب‌ها یا خروجی‌ها که نشان دهنده تغییر در الگوهای زیرین داده‌هاست.

**رانش ویژگی<sup>۳۴</sup>**: تغییر در توزیع ویژگی‌ها یا ورودی‌های مدل که می‌تواند به دلیل تغییر در محیط یا منابع داده‌ها باشد.

تشخیص رانش داده اهمیت زیادی دارد زیرا به مدل‌ها کمک می‌کند تا با تغییرات جدید سازگار شوند و از کاهش کارایی جلوگیری کنند. این تشخیص می‌تواند از طریق مقایسه توزیع‌های آماری قدیم و جدید داده‌ها و استفاده از الگوریتم‌های مختلف انجام شود. هنگامی که رانش داده تشخیص داده شود، مدل‌ها می‌توانند مجدد آموزش داده شوند تا با شرایط جدید سازگار شوند و کارایی مطلوب خود را حفظ کنند.

تکنولوژی‌ها و ابزار برای پیاده‌سازی خط لوله خودکار یادگیری ماشین شامل Kubeflow، Apache Airflow، AWS SageMaker Pipelines و AWS Airflow هستند. یک مثال از کاربرد صنعتی یک خط لوله خودکار یادگیری ماشین با استفاده از Airflow در زمینه تبلیغات آنلاین است [۴۱]. این شرکت از Airflow برای خودکارسازی فرآیند آموزش و استقرار مدل‌های یادگیری ماشین برای هدف‌گذاری و بهینه‌سازی تبلیغات استفاده می‌کند. در این خط لوله، داده‌های بزرگی از منابع مختلف

Continuous Training (CT)<sup>۳۲</sup>

Concept Drift<sup>۳۳</sup>

Feature Drift<sup>۳۴</sup>

مانند داده‌های کلیک استریم و بسایت، جمعیت‌شناسی کاربران و داده‌های عملکرد کمپین استخراج، تبدیل و بارگذاری می‌شوند. این داده‌ها سپس از یک سری مراحل پیش‌پردازش و مهندسی ویژگی عبور می‌کنند که به عنوان اپراتورهای Airflow پیاده‌سازی شده‌اند. در مرحله بعد، مدل‌های مختلف یادگیری ماشین بر روی داده‌های پردازش شده آموزش داده و ارزیابی می‌شوند. در نهایت، مدل با بهترین عملکرد برای تصمیم‌گیری‌های هدف‌گذاری تبلیغات بی‌درنگ به محیط تولید منتقل می‌شود. در این مثال، برای خودکارسازی کل فرآیند از جمله زمان‌بندی، نظارت و اجرای مجدد وظایف شکست‌خورده از Airflow استفاده می‌شود.

## فصل ۱۴

# طراحی یک پلتفرم MLOps

### ۱-۴ مقدمه

در این بخش می خواهیم مقدمه ای از طراحی و هدف آن بنویسیم

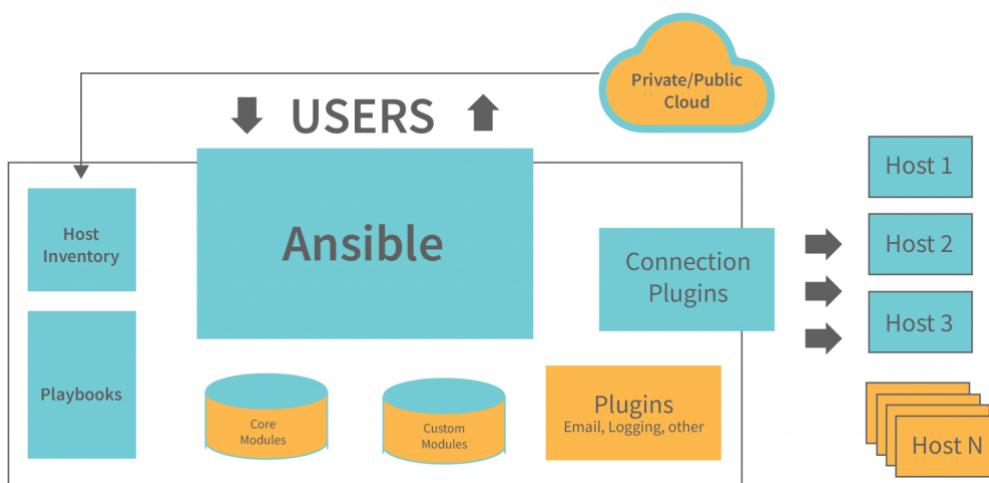
### ۲-۴ سیستم مدیریت پلتفرم

#### ۱-۲-۴ مدیریت پیکربندی و فراهم سازی زیرساخت

در دنیای فناوری اطلاعات، زیرساخت های تغییرناپذیر<sup>۱</sup> و تغییرپذیر<sup>۲</sup> دو رویکرد مهم در مدیریت و نگهداری سیستم ها هستند. زیرساخت های تغییرناپذیر به سیستم هایی اشاره دارند که پس از ایجاد، بدون تغییر باقی میمانند و در صورت نیاز به تغییر، سیستم های جدید جایگزین آنها می شوند. این رویکرد با مزایایی همچون کاهش پیچیدگی های مدیریتی، افزایش قابلیت پیش بینی و کاهش ریسک های مرتبط با تغییرات ناخواسته همراه است [۹]. به کمک ابزارهایی مانند داکر و کوبرتیز، پیاده سازی زیرساخت های تغییرناپذیر امکان پذیر است و از قابلیت مقیاس پذیری بالایی برخوردارند. سیستم های ابری غالباً از روش تغییرناپذیر استفاده کرده تا از مزایای آن بهره مند شوند. در مقابل، زیرساخت های تغییرپذیر به سیستم هایی اشاره دارند که می توانند به طور پویا تغییر کنند و تنظیمات و پیکربندی های جدید را پذیرند. این رویکرد، انعطاف پذیری بیشتری را فراهم می کند و برای محیط هایی که نیاز به تغییرات مکرر دارند، مناسب تر است. با این حال، مدیریت تغییرات در زیرساخت های تغییرپذیر ممکن است چالش های بیشتری از جمله افزایش ریسک خطاهای و نیاز به نظارت مداوم به همراه داشته باشد. انتخاب بین این دو رویکرد به نیازها و اولویت های سازمان بستگی دارد. در حالی که زیرساخت های تغییرناپذیر برای محیط های تولید با

Immutable Infrastructure<sup>۱</sup>

Mutable Infrastructure<sup>۲</sup>



شکل ۱-۴: معماری Ansible

نیاز به ثبات و قابلیت پیش‌بینی بالا مناسب‌ترند، زیرساخت‌های تغییرپذیر برای محیط‌های توسعه و آزمایش که نیاز به انعطاف‌پذیری دارند، کاربرد بیشتری دارند [۸]. این دو مفهوم به صورت مستقیم با مدیریت پیکربندی و فراهم سازی زیرساخت مرتبط هستند.

#### مدیریت پیکربندی

مدیریت پیکربندی فرآیندی است که بر روی نگهداری و کنترل پیکربندی سیستم‌ها و نرم‌افزارها تمرکز دارد. هدف اصلی این فرآیند، اطمینان از سازگاری و پایداری محیط‌های IT در طول زمان است. مدیریت پیکربندی شامل فعالیت‌هایی مانند نگهداری نسخه‌های مختلف نرم‌افزار، مستندسازی تغییرات و اطمینان از تطابق سیستم‌ها با استانداردهای تعیین شده می‌باشد. ابزارهای مدیریت پیکربندی مانند Ansible و Puppet به سازمان‌ها کمک می‌کنند تا فرآیندهای خودکارسازی پیکربندی را پیاده‌سازی کنند. این ابزارها از فایل‌های متنی (مانند Playbook‌ها در Ansible) برای تعریف وضعیت مطلوب سیستم‌ها استفاده می‌کنند. [۴۲] به دلیل سادگی و عدم نیاز به نصب عامل<sup>۳</sup> بر روی سیستم‌های مقصد، یکی از محبوب‌ترین ابزارهای مدیریت پیکربندی است. این ابزار از پروتکل SSH برای ارتباط با ماشین‌ها استفاده می‌کند و از زبان YAML برای نوشتن اسکریپت‌ها بهره می‌برد، که خوانایی و قابل فهم بودن آن را تضمین می‌کند. از ابزارهای مدیریت پیکربندی در زیرساخت‌های تغییرپذیر غالباً استفاده می‌شود.

<sup>۳</sup>Agent

## فراهم سازی زیرساخت

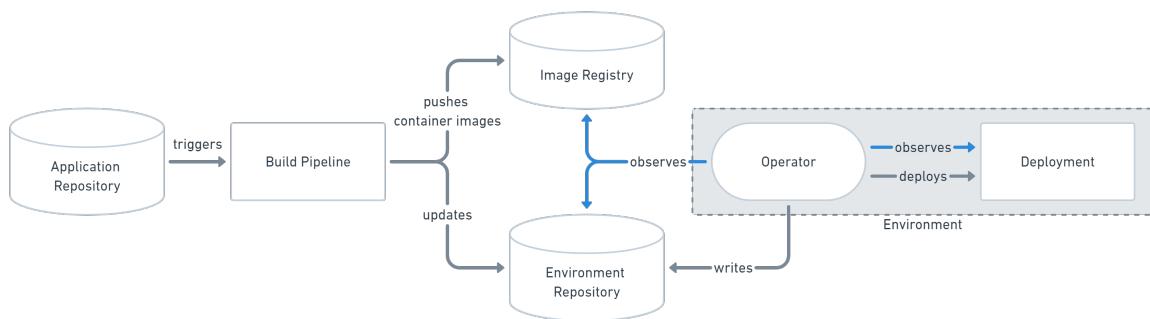
فراهم سازی زیرساخت فرآیندی است که به راه اندازی و پیکربندی اولیه زیرساخت های IT اختصاص دارد. این فرآیند شامل ایجاد و مدیریت منابع مانند سرورها، پایگاه داده ها، شبکه ها و سایر اجزای زیرساختی است. فراهم سازی زیرساخت به صورت سنتی فرآیندی دستی و زمان برد بود، اما با ظهور ابزارهای نوین این فرآیند به شدت خودکار و ساده شده است. ابزارهای متون بازی مانند Terraform برای این کار استفاده می شوند. این ابزارها به کاربران امکان می دهند تا زیرساخت های خود را به صورت کد<sup>۴</sup> تعریف کنند [۸]. این رویکرد به ایجاد و مدیریت منابع زیرساختی به صورت قابل تکرار و پایدار کمک می کند. Terraform، یکی از پرکاربردترین ابزارهای فراهم سازی زیرساخت، از زبان HCL برای تعریف زیرساخت ها استفاده می کند. یکی از ویژگی های برجسته Terraform مدیریت وابستگی ها بین منابع است که امکان بازگردانی<sup>۵</sup> به وضعیت های قبلی را نیز فراهم می کند [۴۳]. از این ابزار ها غالبا برای زیرساخت ها تغییرناپذیر استفاده می شود.

در زیرساخت طراحی شده که از OpenStack برای ساخت و مدیریت ماشین های مجازی استفاده می شود، استفاده از Ansible به عنوان ابزار مدیریت پیکربندی به دلایل متعددی مناسب است. اولاً، Ansible با استفاده از Playbook های YAML امکان خودکارسازی مراحل پیکربندی را فراهم می کند، از جمله نصب نرم افزارهای مورد نیاز، تنظیمات شبکه و پیکربندی سرویس ها. این ویژگی باعث می شود که پیکربندی ها به صورت دقیق و بدون خطأ انجام شود. ثانیاً، Ansible بدون نیاز به نصب عامل بر روی ماشین های مجازی کار می کند و از پروتکل SSH برای ارتباط استفاده می کند که این امر فرآیند پیکربندی را ساده تر و سریع تر می سازد. همچنین، تمامی مراحل پیکربندی به صورت کد تعریف می شوند که امکان اجرای مجدد و دقیق همان تنظیمات را بر روی ماشین های جدید فراهم می کند. به علاوه، Ansible دارای ماژول های متعددی برای تعامل با OpenStack است که می تواند فرآیند ایجاد و مدیریت ماشین های مجازی را بهینه تر کند. پس از پیکربندی اولیه VVM ها، Ansible می تواند خوش کوبرنیز را به صورت خودکار راه اندازی و پیکربندی کند. این شامل نصب ابزارهای مورد نیاز، تنظیمات شبکه و پیکربندی سرویس های کوبرنیز است.

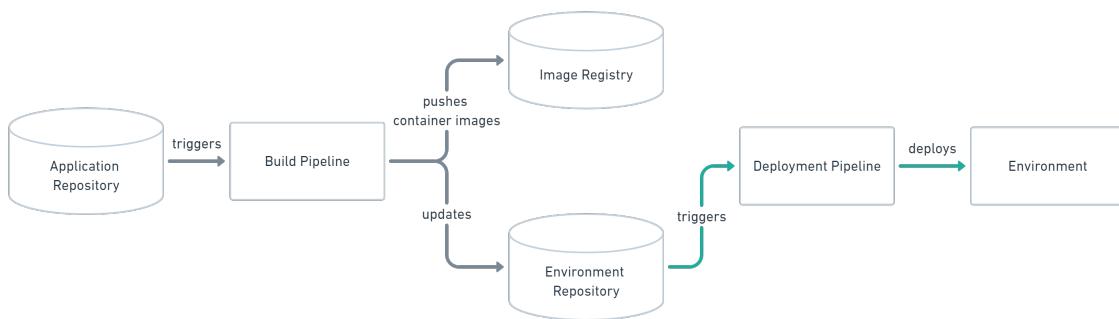
## ۲-۲-۴ خط لوله CI/CD

با افزایش استفاده از سیستم های ابری و رویکرد تغییرناپذیر، مفهومی با عنوان GitOps معرفی شد که از گیت برای مدیریت زیرساخت و پیکربندی بهره می برد. GitOps در سال ۲۰۱۷ توسط Weaveworks معرفی شد که رویکردنی مدرن برای پیاده سازی خط لوله CD بر روی سیستم های ابری است. در حالی که ابزارهای سنتی تحویل مدادوم عمده ای از مدل Push استفاده

Infrastructure as Code<sup>۴</sup>  
Rollback<sup>۵</sup>



شکل ۲-۴: استقرار مبتنی بر Pull



شکل ۳-۴: استقرار مبتنی بر Push

می‌کنند، GitOps مدل Pull را معرفی می‌کند که به خصوص با کانتینرها و پیکربندی‌های اعلامی به خوبی کار می‌کند و آن را به یک روند محبوب در اکوسیستم بومی ابر تبدیل کرده است [۱۲]. از معروف‌ترین ابزار کلیدی که فرآیندهای GitOps را تسهیل می‌کند می‌توان به ArgoCD اشاره کرد.

همان طور که گفته شد دو رویکرد در پیاده‌سازی خط لوله CD وجود دارد. در مدل Pull (شکل ۲-۴) مانند GitOps، توسعه‌دهندگان حالت مطلوب را در مخزن گیت قرار می‌دهند. ابزاری نظیر ArgoCD در محیط تولید به صورت خودکار این تغییرات را شناسایی کرده و اعمال می‌کنند. این مدل امنیت را افزایش می‌دهد زیرا نیازی به اعتبارنامه‌های دسترسی مستقیم برای توسعه‌دهندگان نیست. هم چنین این مدل مشکل استقرارهای مبتنی بر Push را حل می‌کند، که در آن محیط تنها زمانی به روز می‌شود که مخزن محیط به روز شود. در مقابل، در مدل Push (شکل ۳-۴)، استقرار در محیط تولید شامل خطوط لوله CI/CD با اسکرپت‌هایی است که با هر تغییر در گیت فعال می‌شوند. این اسکرپت‌ها معمولاً ساخت، تست و در نهایت استقرار برنامه‌ها یا تنظیم پیکربندی‌های جدید در محیط تولید را با استفاده از ابزارهای خط فرمان و اعتبارنامه‌های ارائه شده انجام می‌دهند. این مدل کنترل دقیق‌تر بر فرآیند استقرار، اعمال سریع تغییرات، انعطاف‌پذیری بالا در مدیریت سناریوهای پیچیده و پشتیبانی بهتر از تغییرات جزئی را فراهم می‌کند، که در محیط‌های متنوع و پویا بسیار مفید است [۱۲].

به منظور پیاده‌سازی یک ابزار متن‌باز برای مدیریت خط لوله‌های CI/CD که برای سیستم‌های ابری نیز مناسب باشد، رویکرد تغییرپذیر به همراه استراتژی استقرار مبتنی بر Push انتخاب شده است. انتخاب رویکرد تغییرپذیر به دلیل نیاز به انعطاف‌پذیری بیشتر در محیط‌هایی که تغییرات مکرر و بهروزرسانی‌های سریع دارند، انجام شده است. زیرساخت‌های تغییرپذیر به ما امکان می‌دهند تا به سرعت به تغییرات نیازمندی‌ها، پاسخ دهیم و تنظیمات و پیکربندی‌های جدید را به راحتی اعمال کنیم. این ویژگی در محیط‌های توسعه و آزمایش بسیار حیاتی است، زیرا تغییرات مداوم و آزمایش‌های متعدد بخشی از فرآیند توسعه نرم‌افزار هستند. هم چنین روش Push نیز به دلیل سادگی و کارایی در اعمال بهروزرسانی‌ها انتخاب شده است. با استفاده از این روش، می‌توانیم بهروزرسانی‌ها را مستقیماً به سرورها ارسال کنیم و اطمینان حاصل کنیم که تمام سیستم‌ها به سرعت و بدون نیاز به مداخله دستی به‌روز می‌شوند. این رویکرد همچنین به کاهش زمان مورد نیاز برای انتشار تغییرات کمک می‌کند. در این راستا، Jenkins به عنوان ابزار پیاده‌سازی و مدیریت خط لوله CI/CD انتخاب شده است. جنکینز به دلیل متن‌باز بودن و دارا بودن تعداد زیادی پلاگین، انعطاف‌پذیری بسیار بالایی دارد و می‌تواند با انواع سیستم‌های ابری و رویکردهای زیرساختی سازگار شود. جنکینز همچنین با Ansible که به عنوان ابزار مدیریت پیکربندی انتخاب شد، به خوبی سازگار است. این ترکیب به ما اجازه می‌دهد تا پیکربندی‌های پیچیده را به سادگی مدیریت کنیم و اطمینان حاصل کنیم که تمام زیرساخت‌ها به صورت هماهنگ عمل می‌کنند.

## طراحی خط لوله

??????????

### ۳-۲-۴ مخزن کد منبع

مخزن کد منبع<sup>۶</sup> یک سیستم ذخیره‌سازی و مدیریت کد است که به توسعه‌دهندگان این امکان را می‌دهد تا به صورت مشترک و هماهنگ بر روی پروژه‌های نرم‌افزاری کار کنند. این مخازن ابزارهای متعددی را برای تسهیل و بهبود فرآیند توسعه نرم‌افزار فراهم می‌کنند. یکی از اصلی‌ترین ویژگی‌های مخزن کد منبع، کنترل نسخه است که به توسعه‌دهندگان این امکان را می‌دهد تا تغییرات کد را پیگیری کرده و به نسخه‌های قبلی بازگردند. این ابزارها با ثبت تاریخچه تغییرات و شاخه‌بندی، امکان مدیریت همزمان چندین ویژگی یا رفع اشکال را فراهم می‌کنند بدون اینکه تغییرات یکدیگر را تحت تأثیر قرار دهند.

raig ترین و پرکاربردترین این مخازن، گیت است که با ابزارهای مختلفی مانند GitHub، GitLab و Bitbucket یکپارچه می‌شود. از آنجایی که یکی از شرط‌های پیاده‌سازی پلتفرم، متن باز بودن ابزارهای آن می‌باشد، GitLab برای

مدیریت مخزن کد منبع استفاده شده است. در این طراحی Jenkins به عنوان مخزن کد متصل شده و هر تغییر در کد منبع باعث اجرا شدن یک خط لوله CI/CD مشخص توسط Jenkins می‌گردد.

#### ۴-۲-۴ مخزن مؤلفه‌ها

یک مخزن مؤلفه<sup>۷</sup> یک سیستم متمرکز برای ذخیره‌سازی، مدیریت و انتشار مؤلفه‌های نرم‌افزاری است. این مؤلفه‌ها شامل هر نوع فایل باپنری، کتابخانه، ماژول، پکیج، پلاگین یا حتی مستنداتی می‌شود که در طول چرخه عمر توسعه نرم‌افزار تولید می‌شود. هدف اصلی این مخازن این است که به تیم‌های توسعه اجازه دهد تا به راحتی نسخه‌های مختلفی از مؤلفه‌ها را مدیریت و به اشتراک بگذارند، فرآیندهای ساخت و انتشار را ساده کنند و وابستگی‌ها را طور موثرتری مدیریت کنند. همچنین، از انتشار مؤلفه‌هایی که هنوز تست نشده‌اند یا از نظر امنیتی مشکلاتی دارند جلوگیری می‌کنند. یکی از ابزارهای محبوب و متن باز برای مدیریت مخازن مؤلفه‌ها، Nexus است. از فرمتهای مختلف مؤلفه‌ها مانند Helm، apt، PyPI و Docker پشتیبانی می‌کند، که این امر آن را به یک ابزار چندمنظوره برای انواع پروژه‌های نرم‌افزاری تبدیل می‌کند. مخازن مؤلفه موردنیاز برای پیاده‌سازی پلتفرم در ۴ نوع raw، apt، PyPI و Docker می‌باشد.

#### مخازن APT

یک سیستم مدیریت بسته در سیستم عامل‌های مبتنی بر دیبان است که به کاربران اجازه می‌دهد تا بسته‌های نرم‌افزاری را به راحتی نصب، بهروزرسانی و حذف کنند. از آنجایی بسته‌های استفاده شده در سرور‌ها غالباً پکسان می‌باشد، به منظور افزایش سرعت پیاده‌سازی و اعمال تغییرات و پیکربندی تمامی بسته‌های مورد استفاده و نصب نشده در محیط، در Nexus ذخیره خواهند شد. این امر با استفاده از مخازنی از نوع Proxy انجام خواهد شد. در پیاده‌سازی سیستم علاوه بر بسته‌های موجود در APT رسمی Ubuntu، از مخازن Containerd و Kubernetes نیز برای نصب و پیاده‌سازی کوبرنتیز نیز استفاده شده است. علاوه بر این، یک مخزن هم برای نصب Nvidia CUDA Toolkit و Nvidia Driver برای استفاده از واحد پردازنده گرافیکی ایجاد خواهد شد.

#### مخزن PyPI

یک مخزن عمومی برای بسته‌های نرم‌افزاری پایتون است که به توسعه‌دهنگان اجازه می‌دهد تا کتابخانه‌ها و ابزارهای خود را منتشر، بهروزرسانی و مدیریت کنند. کاربران می‌توانند این بسته‌ها را به راحتی با استفاده از ابزار pip نصب کنند. همانند APT،

به منظور ذخیره سازی تمامی بسته های استفاده شده در محیط تولید ساخته شده اند. این امر باعث افزایش سرعت در نصب مجدد بسته ها و پایداری سیستم در زمان های قطعی یا خرابی مخازن رسمی می شود.

مخزن Docker

یک سرویس برای Docker Images است که به توسعه‌دهندگان اجرازه می‌دهد تا تصاویر خود را ذخیره، مدیریت و به اشتراک بگذارند. با توجه به تحریم استفاده از DockerHub در ایران و هم چنین کند بودن راه‌های جایگزین در گرفتن تصاویر موردنظر از مخازن رسمی این مخزن به وجود آمده که به مخزن رسمی docker.io پراکسی شده است. علاوه بر این تصاویر لازم برای پیاده‌سازی و پیکربندی محیط که با خط لوله CI/CD ساخته شده اند نیز برای استفاده مجدد در این مخازن قرار می‌گیرند.

raw مخزن

برای ذخیره‌سازی و مدیریت فایل‌ها و داده‌هایی استفاده می‌شود که فرمت خاصی ندارند. این نوع مخزن به توسعه دهنگان اجازه می‌دهد تا انواع مختلف فایل‌ها، مانند اسکریپت‌ها، تصاویر، و مستندات را بدون نیاز به ساختاردهی خاصی نگهداری کنند.

شکل از نكسوس بگذار

۳-۴ معماری خوشہ کوپرنیتیز

در طراحی یک پلتفرم MLOps جامع و کارآمد که تمامی ابزارهای مورد نیاز را در بر می‌گیرد، هدف اصلی ایجاد یک بستر یکپارچه، مقیاس پذیر و انعطاف‌پذیر برای مدیریت چرخه حیات مدل‌های یادگیری ماشین است. این پلتفرم شامل مجموعه‌ای از ابزارها و تکنولوژی‌های متن باز است که همگی روی خوشة کوبرنتیز مستقر می‌شوند. استفاده از کوبرنتیز در پلتفرم‌های MLOps به دلیل قابلیت‌های منحصر به فرد آن در مدیریت خودکار، مقیاس پذیری و کارایی منابع است. کوبرنتیز امکان استقرار مدل‌های یادگیری ماشین در کانتینرها را به صورت پویا و قابل اطمینان فراهم می‌کند، که این امر منجر به بهبود فرایندهای استقرار و به روزرسانی مدل‌ها می‌شود. همچنین، کوبرنتیز با ارائه قابلیت‌های مانیتورینگ و لاگینگ پیشرفته، به تشخیص و رفع سریع مشکلات کمک می‌کند و با ابزارهایی مانند Kubeflow، مدیریت چرخه عمر مدل‌ها را تسهیل می‌کند. این ویژگی‌ها باعث می‌شوند تا سازمان‌ها بتوانند مدل‌های خود را به طور مداوم بهبود داده و به صورت موثر در محیط‌های تولیدی مستقر کنند. در ادامه با الهام از اصول، اجزا و معماری جامع بیان شده در فصل سوم، معماری اصلی پلتفرم MLOps را که شامل تمام ابزارهایی که بر روی خوشة کوبرنتیز پیاده سازی می‌شوند را طراحی کرده و برای هر بخش یک ابزار مناسب معرفی می‌کنیم.

### ۱-۳-۴ مدیریت داده

داده ها در پلتفرم MLOps نقش مهمی دارند. دانشمندان داده به منظور پیاده سازی یک مدل یادگیری ماشین نیاز به آموزش این مدل ها با استفاده از داده های از پیش آماده دارند. این داده ها می توانند به صورت متن، تصویر یا صوت باشد. لذا وجود یک محل ذخیره سازی داده برای نگه داری داده ها در این پلتفرم اساسی است. در کوبرنیز، چندین روش و نوع ذخیره سازی داده وجود دارد که یکی از مهم ترین آن ها PVC می باشد که از PV برای ذخیره سازی داده ها استفاده می کند.

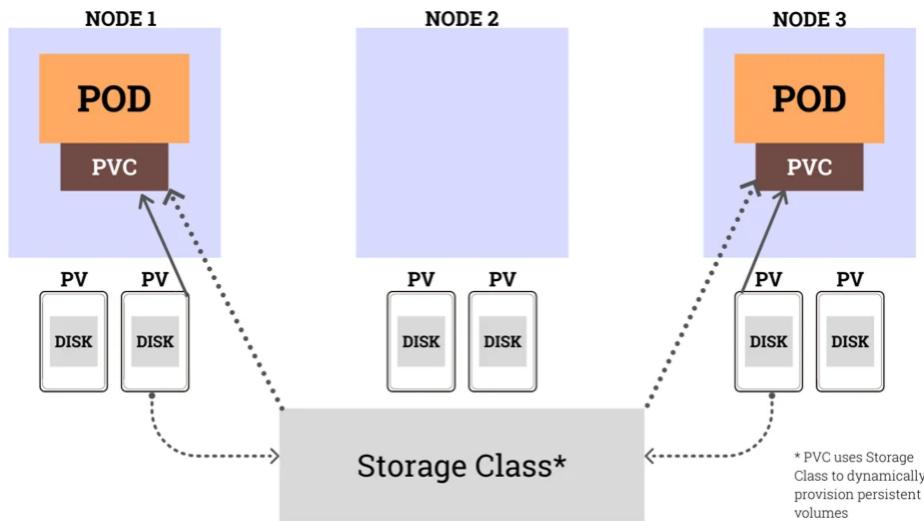
#### حجم پایدار و فراهم سازهای پویا

در کوبرنیز PV به عنوان منابع ذخیره سازی مستقل از چرخه حیات پادها عمل می کنند، به این معنا که داده ها پس از حذف یا بازسازی پادها همچنان حفظ می شوند. PV ها توسط مدیر خوشه به صورت ایستا یا پویا ایجاد می شوند و می توانند به PVC متصل شوند. PVC یک درخواست برای ذخیره سازی است که توسط کاربران ایجاد می شود و پس از تخصیص، به یک PV مرتبط می شود. این مکانیزم باعث می شود که مدیریت ذخیره سازی در خوشه کوبرنیز ساده تر و کارآمدتر شود. PV ها می توانند از انواع مختلف ذخیره سازی مانند دیسک های محلی، شبکه های ذخیره سازی<sup>۸</sup> یا راه حل های ابری استفاده کنند. به علاوه، استفاده از PV و PVC امکان استفاده مجدد از منابع ذخیره سازی را بدون نیاز به تنظیمات دستی پیچیده، برای پادهای مختلف فراهم می کند [۴۴، ۴۵].

یکی از قابلیت های مهم کوبرنیز، فراهم سازی پویا<sup>۹</sup> است که به طور خودکار PV ها را براساس نیازهای PVC ها و کلاس های ذخیره سازی<sup>۱۰</sup> ایجاد می کند. این ویژگی، نیاز به ایجاد و مدیریت دستی PV را توسط مدیران خوشه از بین می برد و مدیریت ذخیره سازی را ساده تر می کند. با تعریف کلاس های ذخیره سازی، می توان انواع مختلفی از ذخیره سازی را با ویژگی های مورد نظر فراهم کرد. هنگامی که یک درخواست ذخیره سازی PVC با کلاس ذخیره سازی مشخص ایجاد می شود، کوبرنیز به طور خودکار یک PV که متناسب با درخواست است را ایجاد و به درخواست متصل می کند [۴۴]. این فرآیند خودکار، نه تنها کارایی و بهره وری را افزایش می دهد بلکه اطمینان می دهد که منابع ذخیره سازی به صورت بهینه و کارآمد تخصیص داده می شوند. ابزار متن بازی که در این پلتفرم برای مدیریت و ساخت PV ها استفاده شده است، OpenEBS می باشد. با استفاده از این ابزار ما مورد نیاز برای ذخیره سازی داده های پایگاه داده و ذخیره سازی شیء مانند MinIO را ایجاد می کنیم.

---

Network File System<sup>۸</sup>  
Dynamic Provisioning<sup>۹</sup>  
Storage Class<sup>۱۰</sup>



شکل ۴-۴: نحوه کار PV و PVC در خوشه کوبرتیز

### ذخیره سازی داده

برای پلتفرم‌های MLOps که نیاز به ذخیره‌سازی حجم زیادی از داده‌ها دارند، استفاده از فضای ذخیره‌سازی ضروری است.

ذخیره‌سازی شیء<sup>۱۱</sup> یک مدل ذخیره‌سازی داده است که برای مدیریت و دسترسی به داده‌های بدون ساختار مانند فایل‌های متنی،

تصویری و صوتی استفاده می‌شود. در این مدل، داده‌ها به عنوان اشیاء با شناسه منحصر به فرد به همراه فراداده‌ها ذخیره می‌شوند.

مزایای اصلی ذخیره‌سازی شیء شامل مقیاس‌پذیری بالا، هزینه کمتر و انعطاف‌پذیری در مدیریت داده‌ها است. این سیستم‌ها به

راحتی می‌توانند به میلیارد‌ها شیء افزایش یابند و برای استفاده در محیط‌های ابری، پشتیبان‌گیری و آرشیو داده‌ها مناسب هستند.

همچنین، مدیریت ساده‌تر فراداده‌ها امکان جستجو و دسترسی سریع‌تر به داده‌ها را فراهم می‌کند. MinIO [۴۶] یک نرم‌افزار

متن‌باز است که به منظور ارائه سرویس ذخیره‌سازی داده طراحی شده است. این نرم‌افزار به دلیل عملکرد بالا و پایداری که

دارد، در محیط‌های مختلف از جمله سیستم‌های ابری به کار گرفته می‌شود. MinIO به عنوان جایگزینی برای Amazon S3

مطرح شده و سازگاری کامل با API‌های S3 را داراست، که این امر مهاجرت بین این دو سیستم را تسهیل می‌کند.

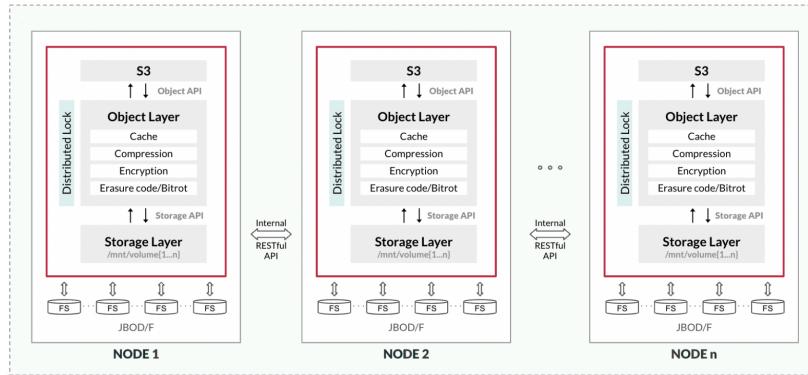
معماری MinIO به صورت توزیع‌شده طراحی شده است که این امکان را فراهم می‌کند تا داده‌ها به صورت افقی

مقیاس‌پذیر باشند. این معماری به گونه‌ای است که می‌توان با اضافه کردن گره‌های جدید به خوشه، ظرفیت و عملکرد سیستم را

به سادگی افزایش داد. در خوشه MinIO، داده‌ها به صورت خودکار توزیع و تکرار<sup>۱۲</sup> می‌شوند تا از دسترس پذیری بالا و تحمل

خطا اطمینان حاصل شود. یکی از مهم‌ترین تکنیک‌هایی که MinIO برای ذخیره‌سازی داده‌ها به کار می‌گیرد، کدگذاری

Object Storage<sup>۱۱</sup>  
Replication<sup>۱۲</sup>



شکل ۵-۴: معماری MinIO

پاکسازی<sup>۱۳</sup> است. این تکنیک به MinIO اجازه می‌دهد تا داده‌ها را به بلوک‌های کوچک‌تر تقسیم کرده و آنها را به صورت توزیع شده در چندین گره ذخیره کند. در صورت خرابی یک یا چند گره، MinIO می‌تواند داده‌ها را از بلوک‌های باقی‌مانده بازیابی کند، بدون اینکه داده‌ای از دست ببرد. این روش نه تنها فضای ذخیره‌سازی را بهینه می‌کند بلکه تحمل خطا سیستم را نیز افزایش می‌دهد. این ویژگی‌ها MinIO را به انتخابی مناسب برای ذخیره‌سازی داده‌های حجمی و پشتیبان‌گیری از آن تبدیل کرده‌اند. در کنار این‌ها یکی از ویژگی‌های مهم MinIO، سادگی و کاربرپسندی آن است. نصب و راهاندازی این نرم‌افزار بسیار ساده بوده و با چند فرمان ساده قابل انجام است. رابط کاربری وب و خط فرمان (mc) نیز به کاربران اجازه می‌دهند تا مدیریت و مانیتورینگ سرورها و داده‌ها را به سادگی انجام دهند.

در معماری طراحی شده برای این پلتفرم، داده‌ها ابتدا در MinIO و در باکت‌های مجزا ذخیره می‌شوند. دانشمندان داده به همراه مهندسان داده با استفاده از کتابخانه‌های پایتون از این داده‌ها استفاده کرد و پیش‌پردازش‌های موردنظر را روی داده‌ها انجام داده و ویژگی‌های موردنظر را استخراج می‌کنند. در نهایت این ویژگی‌ها را می‌توانند در همان MinIO و یا در پایگاه داده‌هایی که به همین منظور طراحی شده ذخیره نمایند.

### پایگاه داده

به منظور ذخیره سازی داده‌های ساختار یافته<sup>۱۴</sup> مانند داده‌های جدولی و یا ویژگی‌های بدست آمده در خط لوله مهندسی ویژگی می‌توان از پایگاه‌های داده استفاده نمود. در این راستا، از PostgreSQL و Redis به عنوان انباره‌های داده آنلاین و آفلاین استفاده شده است.

Erasure Coding<sup>۱۳</sup>  
Structured<sup>۱۴</sup>

PostgreSQL به عنوان انباره داده آفلاین مورد استفاده قرار می‌گیرد. این سیستم مدیریت پایگاه داده رابطه‌ای، به دلیل پشتیبانی از تراکنش‌های ACID، قابلیت اطمینان بالا و توانایی پشتیبانی از انواع داده‌های پیچیده، انتخاب مناسبی برای ذخیره‌سازی داده‌های آموزشی و ویژگی‌های بدست آمده از آن، لگ‌ها و اطلاعات تحلیلی است. PostgreSQL با قابلیت‌های تحلیلی قوی و مقیاس‌پذیری مناسب، امکان تجزیه و تحلیل عمیق داده‌ها و مدیریت متاداده‌های مدل‌ها را فراهم می‌کند.

در مقابل، Redis یک انباره داده در حافظه<sup>۱۵</sup> است که برای کاربردهای آنلاین در معماری MLOps بسیار مناسب است. Redis به دلیل سرعت بالای خواندن و نوشتن داده‌ها و پشتیبانی از ساختارهای داده متنوع، برای ذخیره‌سازی نتایج پیش‌بینی مدل‌ها، کش کردن داده‌های موقت و مدیریت صفحه‌ها و تراکنش‌های سریع استفاده می‌شود. این امر به بهبود کارایی و کاهش زمان پاسخ‌دهی سیستم کمک می‌کند.

ترکیب PostgreSQL و Redis در این معماری، یک راهکار جامع و کارآمد برای مدیریت داده‌ها فراهم می‌کند. PostgreSQL با امکانات پیشرفته‌اش به عنوان انباره داده آفلاین، و Redis با سرعت بالایش به عنوان انباره داده آنلاین می‌تواند نیاز مختلف سیستم را فراهم سازد.

## ۲-۳-۴ شبکه

بسیاری از برنامه‌های مدرن با استفاده از معماری میکروسرویس توزیع شده ساخته می‌شوند که باعث می‌شود هر سرویس ساده و دارای مسئولیت مشخص باشد. هر میکروسرویس API‌های خود را تعریف کرده و سرویس‌ها برای پاسخگویی به درخواست‌های کاربران نهایی از این API‌ها برای تعامل با یکدیگر استفاده می‌کنند. در کوبرنتیز، به منظور شبکه‌سازی برای ارتباط بین پادها و سرویس‌ها، به هر پاد یک آدرس IP منحصر به فرد اختصاص داده می‌شود، که این امکان را فراهم می‌کند تا پادها بدون نیاز به NAT به صورت مستقیم با یکدیگر ارتباط برقرار کنند. با افزایش تعداد این میکروسرویس‌ها، مدیریت ارتباطات، امنیت، و پایش این سرویس‌ها به چالشی بزرگ تبدیل می‌شود که می‌توان با Service Mesh آن را مدیریت کرد.

[۴۷]

سرویس Mesh یک لایه زیرساختی است که مدیریت ارتباط بین سرویس‌ها در معماری میکروسرویس‌ها را بر عهده دارد. این لایه قابلیت‌هایی مانند مشاهده‌پذیری، مدیریت ترافیک و امنیت را بدون تغییر کدهای برنامه اضافه می‌کند. Istio یک سیستم متن‌باز برای مدیریت اتصال، امنیت و مشاهده‌پذیری در معماری‌های میکروسرویس‌ها است که به عنوان سرویس Mesh شناخته می‌شود. این ابزار با افزودن یک لایه مستقل بین میکروسرویس‌ها و شبکه، توانایی‌هایی مانند مسیریابی هوشمند،

In-memory<sup>۱۵</sup>

ترافیک مدیریت شده، نظارت، و امنیت را بهبود می‌بخشد. این سیستم از پروکسی‌های جانبی<sup>۱۶</sup> برای کنترل ارتباطات بین میکروسرویس‌ها استفاده می‌کند، که این پروکسی‌ها معمولاً از Envoy، یک پروکسی سریع و سبک، بهره می‌برند [۴۸]. از

ویژگی‌های مهم Istio می‌توان به سه مورد زیر اشاره کرد:

- مدیریت ترافیک: به کاربران اجازه می‌دهد تا ترافیک بین سرویس‌ها را به صورت دقیق کنترل و مدیریت کنند. با استفاده

از قابلیت‌های مسیریابی پیشفرته، کاربران می‌توانند قولنین پیچیده‌ای برای مسیریابی ترافیک تعریف کنند. این قولنین

شامل تقسیم بار<sup>۱۷</sup>، مسیریابی مبتنی بر نسخه (برای پیاده‌سازی به روزرسانی‌های متوالی)، و مدیریت ترافیک‌های خط<sup>۱۸</sup>

می‌شوند. این ویژگی‌ها به توسعه‌دهندگان کمک می‌کنند تا با اطمینان بیشتری به روزرسانی‌ها و تغییرات را در سیستم‌های

خود اعمال کنند [۴۸].

- امنیت: امکانات امنیتی جامعی برای ارتباطات سرویس به سرویس فراهم می‌کند. این امکانات شامل احراز هویت<sup>۱۹</sup> و

مجوزدهی<sup>۲۰</sup> مبتنی بر سیاست‌های امنیتی است. Istio با استفاده از MTLS ارتباطات بین سرویس‌ها را رمزنگاری

می‌کند و اطمینان حاصل می‌کند که فقط سرویس‌های معتبر می‌توانند با یکدیگر ارتباط برقرار کنند. این قابلیت‌ها به

افزایش امنیت سیستم‌های میکروسرویس کمک شایانی می‌کنند.

- مشاهده‌پذیری و نظارت: قابلیت‌های گسترده‌ای شامل جمع‌آوری و نمایش لاغ‌ها، متريک‌ها و ترييس‌ها<sup>۲۱</sup> برای

مشاهده‌پذیری و نظارت ارتباطات بین سرویس‌ها فراهم می‌کند. با استفاده از ابزارهای یکپارچه‌سازی شده مانند

Grafana و Prometheus کاربران می‌توانند به صورت جامع عملکرد و سلامت سیستم‌های خود را نظارت کنند.

همان طور که معماری این سیستم را در شکل ۴-۶ می‌بینید، Istio به دو بخش اصلی سطح داده<sup>۲۲</sup> و سطح کنترل<sup>۲۳</sup>

تقسیم می‌شود.

## سطح داده

سطح داده مدیریت ارتباط بین سرویس‌ها را بر عهده دارد. در یک شبکه سنتی بدون سرویس مش، شبکه نمی‌تواند ترافیک را

فهمد و بنابراین نمی‌تواند تصمیمات مبتنی بر نوع ترافیک یا منبع و مقصد آن بگیرد. با استفاده از این سیستم، هر ترافیک را

<sup>۱۶</sup> Sidecar proxies

<sup>۱۷</sup> Load balancing

<sup>۱۸</sup> Fault injection

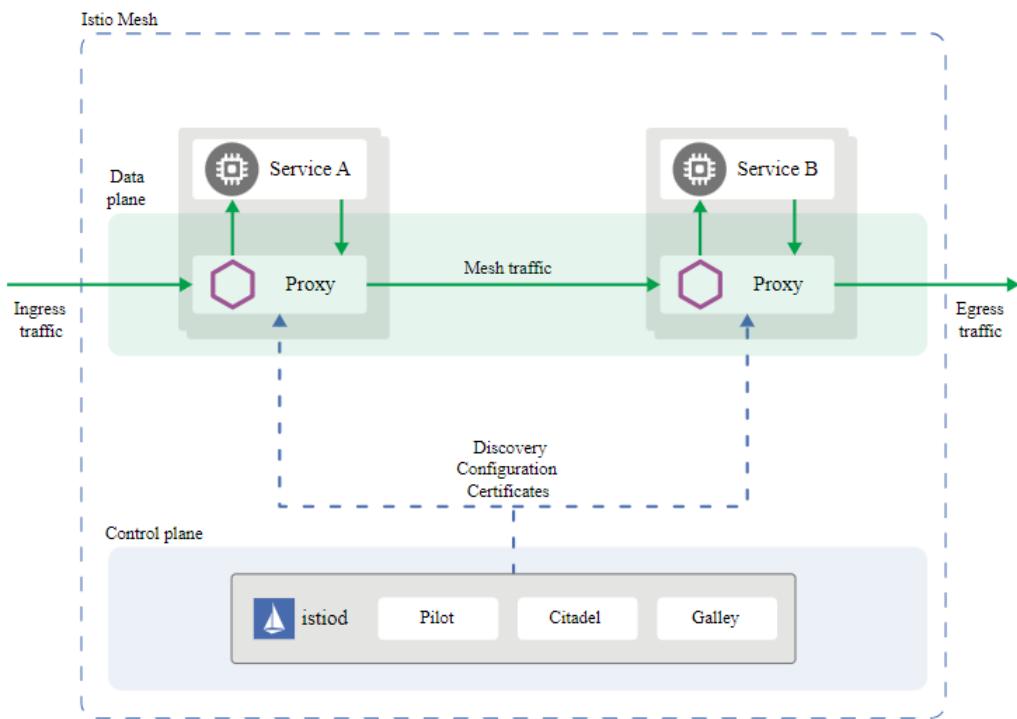
<sup>۱۹</sup> authentication

<sup>۲۰</sup> authorization

<sup>۲۱</sup> Trace

<sup>۲۲</sup> Data plane

<sup>۲۳</sup> Control plane



شکل ۴-۶: معماری Istio

شبکه‌ای که از سرویس‌ها خارج یا به آن‌ها وارد می‌شود توسط یک پروکسی رهگیری می‌شود. سطح داده شامل مجموعه‌ای از پروکسی‌های هوشمند به نام Envoy است که به صورت Sidecar به هر سرویس در مش اضافه می‌شوند. این پروکسی‌ها وظیفه میانجی‌گری و کنترل تمامی ارتباطات شبکه‌ای بین میکروسرویس‌ها را بر عهده دارند [۴۸].

Envoy پراکسی، به عنوان یک پروکسی با عملکرد بالا، قابلیت‌های گستره‌ای را برای مدیریت ترافیک میکروسرویس‌ها در سرویس مش فراهم می‌کند. این قابلیت‌ها شامل کشف سرویس پویا است که به طور خودکار سرویس‌ها را شناسایی کرده و به تغییرات در توپولوژی پاسخ می‌دهد. تقسیم بار ترافیک را بهینه‌سازی می‌کند [۴۸]. این ابزار از پروتکل‌های HTTP/2 و gRPC برای بهبود کارایی پشتیبانی می‌کند و با استفاده از قطع کننده‌های مدار<sup>۲۴</sup> از بارگذاری بیش از حد سرویس‌ها جلوگیری می‌کند. این پروکسی همچنین قابلیت بررسی سلامت سرویس‌ها، تزریق خطاب برای شبیه‌سازی خرابی‌ها، و جمع‌آوری تلمتری غنی را دارد.

## سطح کنترل

سطح کنترل مسئول مدیریت و پیکربندی پروکسی‌های تشکیل دهنده سطح داده است. این سطح، پیکربندی مورد نظر شما را که از طریق سیاست‌ها و قوانین تعریف می‌شود، دریافت می‌کند و با استفاده از دید خود نسبت به سرویس‌ها در داخل مش،

Circuit Breakers<sup>۲۴</sup>

پروکسی‌ها را به صورت پویا برنامه‌ریزی می‌کند. هنگامی که قوانین یا محیط تغییر می‌کنند، سطح کنترل پروکسی‌ها را به روزرسانی می‌کند [۴۸]. این پیکربندی پویا به مدیریت ترافیک و سیاست‌ها به صورت بلاذرگ این امکان را می‌دهد تا سرویس مش به سرعت با تغییرات نیازهای برنامه یا زیرساخت‌ها سازگار شود.

اصلی‌ترین جزء صفحه کنترل Istiod نام دارد که مسئول کشف سرویس، مدیریت پیکربندی و مدیریت گواهی‌ها است. این ابزار، قواعد مسیریابی را به پیکربندی‌های Envoy تبدیل کرده و به سایدکارها ارسال می‌کند. Istiod به عنوان مرجع صدور گواهی<sup>۲۵</sup> عمل کرده و ارتباطات امن MTLS را در صفحه داده تضمین می‌کند. همچنین، با مدیریت هویت و اعتبارنامه‌ها، احراز هویت قوی و اجرای سیاست‌های امنیتی را فراهم می‌کند.

### ۳-۳-۴ مدیریت کاربران و چندمستاجری

پستیبانی از چندین کاربر و چندمستاجری<sup>۲۶</sup> در پلتفرم ابری یکی از ویژگی‌های کلیدی است که به کاربران مختلف اجازه می‌دهد به صورت امن و مستقل بر روی همان پلتفرم کار کنند. این قابلیت با استفاده از مفاهیم ایزوله‌سازی، احراز هویت و مجوزدهی پیاده‌سازی شده است. در ادامه به جزئیات این فرآیندها می‌پردازیم.

#### احراز هویت

احراز هویت در پلتفرم از طریق ترکیبی از پروتکل OIDC<sup>۲۷</sup> و Istio، به همراه ابزار Dex برای مدیریت هویت<sup>۲۸</sup> و یکپارچگی با سیستم‌های احراز هویت خارجی، انجام می‌شود. پروتکل OIDC یک لایه احراز هویت بر روی OAuth 2.0 است که امکان تأیید هویت کاربران و دریافت اطلاعات پروفایل آنها را فراهم می‌کند [۴۹]. Dex نیز یک سرویس منبع باز است که به عنوان یک ارائه‌دهنده هویت OIDC عمل می‌کند و می‌تواند با سیستم‌های هویتی مختلفی مانند LDAP و Active Directory یکپارچه شود.

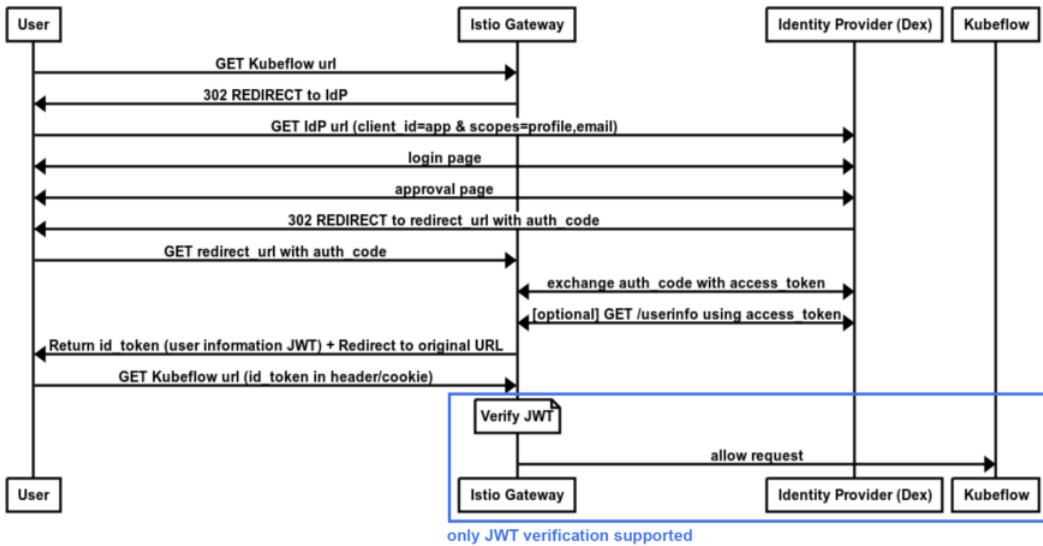
شکل ۷-۴ روند احراز هویت یک کاربر با استفاده از پروتکل OIDC را نشان می‌دهد. کاربران ابتدا به رابط کاربری Dex پلتفرم ابری وارد می‌شوند. در این مرحله، Dex به عنوان ارائه‌دهنده هویت، صفحه ورود را به کاربر نشان می‌دهد. سپس اطلاعات کاربر را از سیستم‌های احراز هویت خارجی می‌گیرد و پس از تأیید هویت، یک توکن OIDC صادر می‌کند. پس از احراز هویت موفقیت‌آمیز، توکن OIDC به کاربر بازگردانده می‌شود و در هر درخواست HTTP به پلتفرم ابری، به عنوان هدر

Certificate Authority<sup>۲۵</sup>

Multi-Tenancy<sup>۲۶</sup>

OpenID Connect<sup>۲۷</sup>

Identity Provider<sup>۲۸</sup>



شکل ۷-۴: روند احراز هویت

ارسال می‌شود [۴۹]. Istio به عنوان یک پروکسی معکوس عمل کرده و تمامی درخواست‌های ورودی را بررسی می‌کند. سرویس مش با استفاده از توکن OIDC ارسال شده توسط کاربر، هویت وی را تأیید می‌کند. پس از تأیید هویت توسط Istio، درخواست به سرور API پلتفرم ابری ارسال می‌شود. سرور API نیز هدرهای مربوط به اطلاعات هویتی را بررسی و پردازش می‌کند.

### ایزوله‌سازی

ایزوله‌سازی در این پلتفرم با استفاده از namespaces کوئربنیز انجام می‌شود. هر namespace به یک یا چند کاربر اختصاص داده می‌شود و منابع هر کاربر مانند خط لوله‌ها و داده‌ها در namespace مخصوص به خود قرار می‌گیرند. این روش تضمین می‌کند که کاربران تنها به منابع خود دسترسی دارند و نمی‌توانند به منابع سایر کاربران دسترسی پیدا کنند.

### مجوزدهی

مجوزدهی در پلتفرم ابری با استفاده از RBAC کوئربنیز انجام می‌شود. مجوزها به صورت نقش‌ها تعریف شده و از طریق RoleBinding به کاربران یا گروههای کاربران اختصاص داده می‌شوند [۴۴]. این روش به مدیران سیستم اجازه می‌دهد تا

دسترسی‌های دقیقی برای کاربران تعیین کنند، مثلاً کاربری تنها بتواند خط لوله‌ها را مشاهده کند اما نتواند آنها را اجرا کند.

#### ۴-۳-۴ ناظارت

ناظارت در پلتفرم MLOps برای اطمینان از عملکرد بهینه و پایداری مدل‌های یادگیری ماشین از اهمیت ویژه‌ای برخوردار است. متريک‌ها در MLOps به سه دسته اصلی متريک‌های سистем، متريک‌های مدل و متريک‌های داده تقسیم می‌شوند.

##### متريک‌های سیستم

متريک‌های سیستم اطلاعاتی درباره مصرف منابع مانند CPU، حافظه، استفاده از دیسک و ترافیک شبکه را شامل می‌شوند. اين متريک‌ها به شناسايي مشكلات زيرساختی کمک می‌کنند که ممکن است بر عملکرد کلی سیستم تأثير بگذارند. مثلاً افزایش مصرف CPU یا حافظه می‌تواند نشان‌دهنده بار غیرعادی یا مشكلات در کد مدل باشد.

##### متريک‌های مدل

متريک‌های مدل برای ارزیابی عملکرد مدل‌های یادگیری ماشین استفاده می‌شوند و شامل پaramترهایی مانند مدت زمان پيش‌بینی، دقت، F1-score و نرخ خطا هستند. مدت زمان پيش‌بینی نشان‌دهنده مدت زمان لازم برای انجام یک پيش‌بینی است و افزایش غیرعادی آن می‌تواند نشان‌دهنده مشكلات کارایی باشد. دقت مدل به ارزیابی کیفیت پيش‌بینی‌ها کمک می‌کنند و کاهش در اين متريک‌ها ممکن است نشان‌دهنده نياز به بازآموزی مدل<sup>۳۱</sup> باشد. نرخ خطا نيز به شناسايي مشكلات احتمالي در داده‌ها يا الگوريتم‌ها کمک می‌کند.

##### متريک‌های داده

متريک‌های داده شامل کیفیت داده‌ها، تغييرات در توزيع داده‌ها<sup>۳۲</sup> و نرخ داده‌های مفقود می‌باشند. اين متريک‌ها برای تضمين کیفیت داده‌های ورودی و جلوگيري از بروز مشكلات ناشی از داده‌های نادرست یا ناكافی ضروري هستند. مثلاً تغييرات ناگهانی در توزيع داده‌ها می‌تواند نشان‌دهنده تغييرات در رفتار کاربران یا نقص در فرآيند جمع‌آوری داده‌ها باشد. نرخ داده‌های مفقود نيز به شناسايي مشكلات در جريان داده‌ها کمک می‌کند و از تأثيرگذاري منفي بر عملکرد مدل جلوگيري می‌کند. يکی از ابزارهای کلیدی برای جمع‌آوری اين متريک‌ها Prometheus است که برای جمع‌آوری، ذخیره‌سازی و مدیريت متريک‌ها به کار می‌رود. Prometheus از يك مدل داده مبتنی بر سري‌های زمانی و يك زبان پرس‌وجوی قدرتمند به

<sup>۳۰</sup> Model Retraining  
<sup>۳۱</sup> Data Drift

نام PromQL استفاده می‌کند. Prometheus متریک‌ها را از طریق scraping از endpoint‌های مشخص شده جمع‌آوری می‌کند. این endpoint‌ها می‌توانند توسط سرویس‌ها، اپلیکیشن‌ها و مدل‌های مختلف ارائه شوند که در آن‌ها متریک‌های مختلف به صورت فرمتهای مشخص مانند JSON قرار دارند. هر متریک می‌تواند دارای چندین برچسب باشد که به فیلتر کردن و گروه‌بندی داده‌ها کمک می‌کند. این برچسب‌ها می‌توانند شامل نام سرویس، نسخه مدل، نام مدل و دیگر اطلاعات مرتبط باشند [۵۰].

برای جمع‌آوری متریک‌ها، Prometheus به طور دوره‌ای به endpoint‌های مشخص شده مراجعه کرده و داده‌ها را دریافت می‌کند. این داده‌ها سپس در یک پایگاه داده زمان-سری ذخیره می‌شوند که امکان اجرای پرس‌وجوهای پیچیده و ایجاد هشدارهای مختلف را فراهم می‌کند. با تعریف آستانه‌های مختلف، Prometheus می‌تواند در صورت بروز شرایط بحرانی مانند افزایش غیرعادی زمان پیش‌بینی یا مصرف بیش از حد منابع، به تیم‌ها هشدار دهد [۵۰]. از Alertmanager نیز در کنار Prometheus برای مدیریت هشدارها استفاده می‌شود. هنگامی که یک قانون هشدار در Prometheus فعال می‌شود، هشدار به Alertmanager ارسال می‌شود. Alertmanager بر اساس پیکربندی‌های تعریف‌شده، هشدار را به گیرنده‌گان مناسب ارسال می‌کند. این گیرنده‌گان می‌توانند شامل ایمیل‌ها، سرویس‌های پیام‌رسانی (مانند Slack) و یا حتی runbooks برای اجرای خودکار اقدامات باشند. در نهایت، با استفاده از داشبوردهای تعاملی و قابل سفارشی‌سازی Grafana، تیم‌ها می‌توانند متریک‌های جمع‌آوری شده توسط Prometheus را به صورت بصری مشاهده و تحلیل کنند و با استفاده از فیلترهای مختلف، تحلیل‌های دقیقی از عملکرد مدل‌ها و سیستم‌ها ارائه دهند [۵۱].

#### ۴-۳-۵ استقرار مدل

## فصل ۱۰

# پیاده سازی و نتایج

## ۱-۵ مقدمه

در این فصل به بررسی پیاده سازی پلتفرم و نتایج حاصل از آن می پردازیم. ابتدا به شرح سیستم مدیریت پلتفرم می پردازیم که نقش حیاتی در هماهنگی و یکپارچگی اجزای مختلف دارد و شامل استفاده از ابزارهای خودکارسازی و نظارت پیشرفته، مدیریت منابع سخت افزاری، بهروزرسانی مستمر، می باشد. همچنین، فرآیند پیاده سازی خوش کوبرنیز برای پلتفرم MLOps و نصب مولفه های مختلف پروژه با استفاده از Helm شرح داده خواهد شد. در نهایت، نتایج حاصل از پیاده سازی پلتفرم و ارزیابی دو مسئله مختلف بررسی می شود: مسئله تشخیص ارقام و مسئله تحلیل احساسات در بازار سهام. این ارزیابی ها شامل بررسی عملکرد پلتفرم در شرایط مختلف و استفاده از ابزارهای متفاوت برای مدیریت و اجرای مدل های یادگیری ماشین به صورت خودکار و پیوسته است. در ارزیابی مسئله تشخیص ارقام نیز، نتایج با یک مقاله علمی مقایسه شده است تا عملکرد و کارایی پلتفرم در شرایط مختلف به طور دقیق تری مورد بررسی قرار گیرد.

## ۲-۵ پیاده سازی پلتفرم

### ۱-۲-۵ سیستم مدیریت

در پلتفرم های بزرگ، نیاز به سیستمی برای مدیریت پلتفرم به وضوح احساس می شود. این سیستم باید قابلیت هماهنگی و یکپارچگی بین اجزای مختلف را داشته باشد تا اطمینان حاصل شود که همه بخش ها به درستی و بدون مشکل عمل می کنند. ویژگی های حیاتی این سیستم شامل استفاده از ابزارهای خودکارسازی و نظارت پیشرفته، مدیریت بهینه منابع سخت افزاری، پیاده سازی فرآیندهای مستمر بهبود و بهروزرسانی، مدیریت دسترسی ها و امنیت و مستندسازی فرآیندها و تغییرات است.

جدول ۱-۵: مشخصات سخت افزاری ماشین های مدیریت

CPU	RAM	Storage	OS
4 Core	8 GB	512 GB	Ubuntu 18.04

سیستم مدیریت شامل تمامی ابزارهای مدیریتی مانند مدیریت مخازن مولفه‌ها، کد و خط لوله CI/CD، مانیتورینگ کل سیستم و جمع آوری لاغ است. علاوه بر این، استراتژی استقرار پروژه، اعمال مهاجرت‌ها<sup>۱</sup>، پیکربندی پروژه‌ها، مدیریت سرورهای DNS و NTP<sup>۲</sup> و استفاده از ابزارهایی مانند Foreman برای نصب سیستم عامل به صورت PXE نیز توسط همین سیستم مدیریت می‌شود.

به منظور پیاده سازی این سیستم، ما دو ماشین مجزا برای مدیریت پلتفرم به منظور ایجاد قابلیت تحمل خطا<sup>۳</sup> و دسترسی پذیری بالا<sup>۴</sup> قرار می‌دهیم. از آنجایی که فرآیند و پروسه سنگینی روی این ماشین‌ها انجام نمی‌شود مشخصات کمتری می‌تواند به نسبت ماشین‌های پروژه داشته باشد. مشخصات سخت افزاری هرکدام از این ماشین‌ها در جدول ۱-۵ قرار دارد. این ماشین‌ها به صورت ماشین مجازی با استفاده از OpenStack ساخته می‌شود. ماشین‌های مدیریت باید برای نصب و راهاندازی ابزارهای مدیریت پلتفرم پیکربندی شوند و این کار با استفاده از ابزار Ansible انجام می‌گیرد. به این منظور Role‌های مشخصی برای هر بخش نوشته شده است تا بتوان بدون هیچ کار دستی و به صورت کاملاً خودکار سیستم‌ها را پیکربندی کرد. این Role‌های انسیبلی با استفاده از قاعده نسخه گذاری Semantic Nexus raw موجود در Nexus که یک ابزار مدیریت مخازن مولفه می‌باشد نگه داری خواهند شد. در نهایت برای پیکربندی سیستم، Role موردنظر با نسخه مشخص از Nexus گرفته شده و با استفاده از Ansible ماشین‌ها پیکربندی می‌شوند. از آنجایی که این پیکربندی در محیط‌های مختلف مانند توسعه و عملیات می‌تواند متفاوت باشد، ما با استفاده از قابلیت Overriding در این ابزار مقادیر پیش فرض را برای هر محیط تغییر خواهیم داد. به همین منظور اسکریپتی طراحی شده که در لینک گیت هاب<sup>۵</sup> قابل مشاهده است. پروسه پیکربندی و نصب ابزار در ماشین‌های مدیریت به صورت زیر انجام می‌گردد:

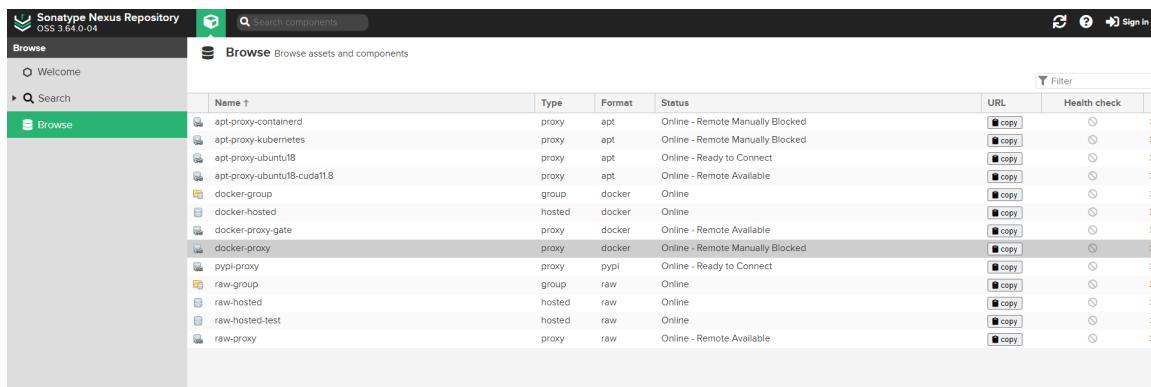
۱. پیکربندی ماشین‌ها: این قسمت شامل نصب و پیکربندی ابزارهایی نظیر BIND برای سرور DNS، APT برای

مدیریت ابزار در سیستم عامل Ubuntu، pip برای مدیریت کتابخانه‌ها پایتون، chrony برای سرور NTP،

برای مدیریت کاربران و ... می‌باشد.

۲. نصب و پیکربندی Docker: از آنجایی که مدیریت ابزارها به صورت کانتینر مناسب‌تر است، برای انجام مراحل بعدی

Migrations<sup>۱</sup>  
Network Time Protocol<sup>۲</sup>  
Fault Tolerance<sup>۳</sup>  
High Availability<sup>۴</sup>  
<https://github.com/abolfazlyarian/mllops.git><sup>۵</sup>



شکل ۵-۱: مخازن مولفه در Nexus

The screenshot shows the Jenkins interface. On the left, there's a sidebar with links like New Item, People, Build History, Project Relationship, Check File Fingerprint, Manage Jenkins, My Views, and Open Blue Ocean. The main area shows a table of build history for projects like lightgcnServe, lightgcnTrain, sentimentServe, and sentimentTrain. It includes columns for Status, Last Success, Last Failure, Last Duration, and a star icon. Below this, there's a 'Build Queue' section indicating 'No builds in the queue.' At the bottom, there's a 'Build Executor Status' section showing one idle node named 'mlops'. A legend at the bottom right explains icons for Atom feed for all, failures, and latest builds.

شکل ۵-۲: خط لوله ها در CI/CD

نیاز به نصب Docker می باشد. پس از نصب به منظور ذخیره سازی تمام مولفه ها مورد استفاده به مخزن ساخته شده

در Nexus مدیریت متصل خواهد شد.

۳. Nexus: از این ابزار به منظور مدیریت مخازن مولفه ها استفاده شده است. مخازن مورد استفاده ما pip، APT،

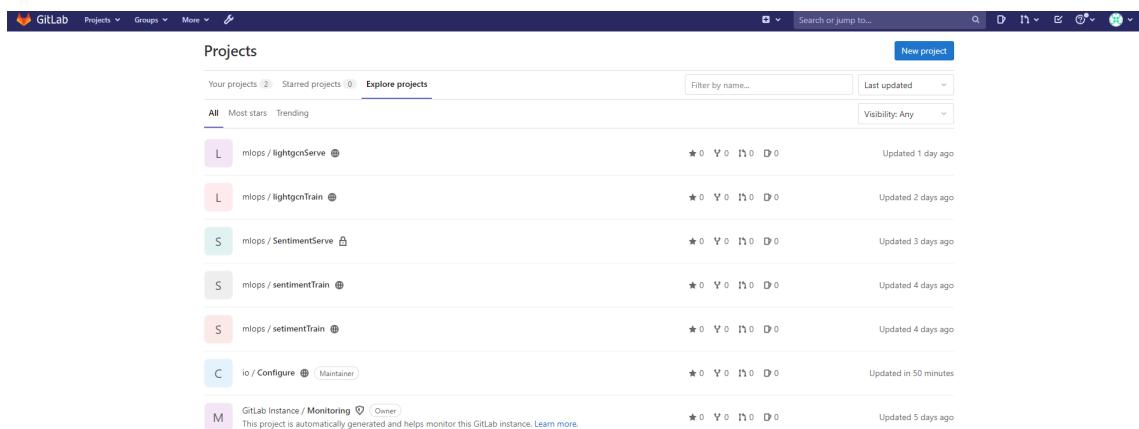
Docker و raw می باشد (شکل ۱-۵).

۴. Jenkins: از این ابزار به منظور اجرا و مدیریت خط لوله های CI/CD پروژها و هم چنین پیکربندی آن ها توسط مدیران

سیستم استفاده می شود (شکل ۲-۵).

۵. GitLab: به منظور مدیریت کد در پروژه ها و هم چنین مدیریت Role های انسیبلی برای پیکربندی پروژها استفاده می

شود (شکل ۳-۵).



شکل ۳-۵: مخازن کد در Gitlab

جدول ۲-۵: مشخصات سخت افزاری ماشین های خوشه کوبرنتیز

CPU	RAM	Storage	OS
40 Core	128 GB	2 TB	Ubuntu 18.04

## ۲-۲-۵ خوشه کوبرنتیز

در طراحی یک پلتفرم MLOps جامع و کارآمد که تمامی ابزارهای مورد نیاز را در بر می‌گیرد، هدف اصلی ایجاد یک بستر یکپارچه، مقیاس‌پذیر و انعطاف‌پذیر برای مدیریت چرخه حیات مدل‌های یادگیری ماشین است. این پلتفرم شامل مجموعه‌ای از ابزارها و تکنولوژی‌های متن‌باز است که همگی روی خوشه کوبرنتیز مستقر می‌شوند. استفاده از کوبرنتیز در پلتفرم‌های MLOps به دلیل قابلیت‌های منحصر به فرد آن در مدیریت خودکار، مقیاس‌پذیری و کارایی منابع است.

برای نصب خوشه کوبرنتیز و انجام تست‌های اولیه پروژه MLOps، ۴ ماشین مجازی با مشخصات ذکر شده در جدول ۲-۵ استفاده شده است. در این پیاده سازی سه ماشین اول به عنوان گره اصلی و ماشین چهارم به عنوان گره کاری انتخاب شده است. همانند سیستم‌های مدیریت، ابتدا ماشین‌های مجازی که توسط OpenStack ساخته خواهد شد پیکربندی می‌شوند. پس از آن با استفاده از ابزار Kubeadm خوشه کوبرنتیز پیاده سازی خواهد شد.

### پیاده سازی خوشه کوبرنتیز

برای نصب و پیاده سازی کوبرنتیز با استفاده از kubeadm، ابتدا پیش‌نیازهایی مانند Containerd و بسته‌های کوبرنتیز شامل kubelet و kubeadm و kubectl آماده می‌شوند. پس از پیکربندی سیستم و نصب Containerd، بسته‌های مورد نیاز نصب شده و Swap غیرفعال می‌گردد، چرا که کوبرنتیز برای عملکرد بهینه نیاز به غیرفعال بودن Swap دارد. راهاندازی خوشه با اجرای

دستور kubeadm init بروی گره اصلی آغاز می‌گردد. این دستور تنظیمات اولیه را انجام داده و فایل پیکربندی برای kubectl ایجاد می‌کند که باید برای دسترسی به خوشه تنظیم گردد. پس از آن، نصب رابط شبکه کانتینر<sup>۶</sup> انجام می‌شود و در این مورد، ابزار Calico مورد استفاده قرار می‌گیرد. نصب Calico امکان برقراری ارتباط بین پادها در داخل خوشه را فراهم می‌سازد. در مرحله بعد، گره‌های کارگر به خوشه اضافه می‌شوند. دستورات لازم برای پیوستن نودهای کارگر به خوشه که از دستور قبل به دست آمده‌اند، بروی هر گره کارگر اجرا می‌گردد تا این گره‌ها به گره اصلی متصل شوند. در نهایت، وضعیت گره‌ها و صحت پیوستن آن‌ها به خوشه با استفاده از kubectl get nodes بررسی می‌گردد و اطمینان حاصل می‌شود که همه گره‌ها به درستی اضافه شده و آماده به کار هستند. این روش نصب، راهی سریع و مؤثر برای راه‌اندازی خوشه کوبرنتیز فراهم می‌آورد که امکان اضافه کردن گره‌های جدید و مدیریت بهتر و مقیاس‌پذیری را به سهولت فراهم می‌سازد. تمامی این فرآیند با استفاده از Role‌های انسیبلی روی ماشین‌های پروژه انجام می‌گردد.

### پیاده سازی مولفه‌های پروژه

تمامی مولفه‌ها انتخاب شده در طراحی معماری فصل قبل با استفاده از Helm که وظیفه مدیریت مولفه‌ها را دارد انجام می‌گیرد. Helm یک ابزار قدرتمند برای مدیریت بسته‌های نرم‌افزاری کوبرنتیز است که فرآیند استقرار، بروزرسانی و مدیریت برنامه‌ها را ساده‌تر می‌کند. نصب یک چارت با استفاده از Helm این امکان را می‌دهد که برنامه‌ها و سرویس‌ها با کمترین تلاش ممکن و به صورت اتوماتیک در خوشه کوبرنتیز مستقر شوند. چارت مورد نظر با استفاده از دستور helm install به راحتی نصب می‌گردد. این دستور، چارت مورد نظر را از مخازن موجود در Nexus دانلود کرده و آن را در خوشه کوبرنتیز مستقر می‌کند. این کار نیز با استفاده از یک Role انسیبلی که نوشته شده است انجام می‌گیرد.

یکی از مزایای استفاده از Helm، قابلیت تنظیم پارامترهای چارت‌ها در زمان نصب است. این قابلیت امکان سفارشی‌سازی چارت‌ها را براساس نیازهای خاص پروژه فراهم می‌کند. با استفاده از این ویژگی و قابلیت مشابه در انسیبل، همانند قبل برای هر محیط مقادیر خاص آن محیط را پیکربندی می‌کنیم. علاوه بر این، Helm با ارائه قابلیت بازگشت پذیری، امکان بازگشت به نسخه‌های قبلی چارت‌ها را نیز فراهم می‌سازد که این ویژگی برای مدیریت نسخه‌ها و رفع مشکلات بسیار مفید است. تمامی مولفه‌های اصلی نصب شده روی خوشه کوبرنتیز به منظور پیاده سازی پلتفرم MLOps در شکل ۴-۵ نشان داده شده است. نکته‌ای که راجع به این مولفه‌ها لازم به ذکر است، به منظور افزایش قابلیت اطمینان و تحمل خطأ، استفاده بیش از یک replica برای هر مولفه ضروری است. این امر باعث می‌شود تا در صورت خرابی یکی از نمونه‌ها، مولفه مربوطه به کار خود ادامه دهد و سرویس دهی دچار اختلال نشود. در شکل ۵-۵ نیز میزان مصرف منابع سخت افزاری سیستم

<sup>۶</sup> Container Network Interface (CNI)

NAMESPACE	NAME	READY	STATUS
auth	dex-6597dd7949-7lln6	1/1	Running
cert-manager	cert-manager-5dfdbefdf6b-4qw26	1/1	Running
cert-manager	cert-manager-cainjector-8944dc75f-brbgz	1/1	Running
cert-manager	cert-manager-webhook-6985f5b7d-6b95r	1/1	Running
granite	granite-alarmmanager-0	2/2	Running
granite	granite-elastic-monitoring-io-10-657f5f657d-nm8kf	1/1	Running
granite	granite-elastic-monitoring-io-11-9cd6d857b-gqmkk	1/1	Running
granite	granite-elastic-monitoring-io-9-77bb785878-245m9	1/1	Running
granite	granite-filebeat-9b5x6	2/2	Running
granite	granite-filebeat-gxvf6	2/2	Running
granite	granite-filebeat-hsxx6	2/2	Running
granite	granite-filebeat-lh7mc	2/2	Running
granite	granite-grafana-add-objects-job-fbd2c	0/1	Succeeded
granite	granite-grafana-deploy-568fc5856-n5tzh	3/3	Running
granite	granite-kube-state-metrics-deploy-7bdbf4974f-xmdtr	1/1	Running
granite	granite-minio-0	1/1	Running
granite	granite-minio-1	1/1	Running
granite	granite-minio-2	1/1	Running
granite	granite-minio-3	1/1	Running
granite	granite-node-exporter-5wntx	1/1	Running
granite	granite-node-exporter-6cm99	1/1	Running
granite	granite-node-exporter-qmbz	1/1	Running
granite	granite-node-exporter-tdqcm	1/1	Running
granite	granite-ohab-6c7bf4f45d-wxsx6	1/1	Running
granite	granite-openeps-localpv-7776f556bb-mkpqx	1/1	Running
granite	granite-postgresql-0	2/2	Running
granite	granite-postgresql-1	2/2	Running
granite	granite-postgresql-2	2/2	Running
granite	granite-postgresql-operator-c9b64fbb-b4rbx	1/1	Running
granite	granite-postgresql-0	1/1	Running
granite	granite-postgresql-1	1/1	Running
granite	granite-postgresql-2	1/1	Running
granite	granite-prometheus-0	2/2	Running
granite	granite-prometheus-1	2/2	Running
granite	granite-redis-595c897554-8955x	2/2	Running
granite	sms-gateway-deploy-56575fb9d-n9lzt	1/1	Running
istio-system	authservice-0	1/1	Running
istio-system	cluster-local-gateway-5c44b4f6b7-z9v8k	1/1	Running
istio-system	istio-ingressgateway-7b5c8644b4-9gmdp	1/1	Running
istio-system	istiod-77c5984b95-zw9bn	1/1	Running
knative-serving	activator-5d9f58896d-96t92	1/1	Running
knative-serving	autoscaler-594f86cb56-4jzmn	1/1	Running
knative-serving	controller-548bd754-l8b9x	1/1	Running
kserve	kserve-controller-manager-0	2/2	Running
kube-system	calico-kube-controllers-577f77cb5c-gfrgt	2/2	Running
kube-system	calico-node-4tf5z	1/1	Running
kube-system	calico-node-c79k8	1/1	Running
kube-system	calico-node-lwj6w	1/1	Running
kube-system	calico-node-sp2jx	1/1	Running
kube-system	calico-typha-7487b564bd-5wf46	1/1	Running
kube-system	calico-typha-7487b564bd-grt48	1/1	Running
kube-system	etcd-io-10	1/1	Running
kube-system	etcd-io-11	1/1	Running
kube-system	etcd-io-9	1/1	Running
kube-system	granite-coredns-57755dcc7-rccrl	1/1	Running
kube-system	granite-coredns-57755dcc7-rp2kk	1/1	Running
kube-system	granite-metrics-server-77988b6d66-8gfnn	1/1	Running
kube-system	kube-apiserver-io-10	1/1	Running
kube-system	kube-apiserver-io-11	1/1	Running
kube-system	kube-apiserver-io-9	1/1	Running
kube-system	kube-controller-manager-io-10	1/1	Running
kube-system	kube-controller-manager-io-11	1/1	Running
kube-system	kube-controller-manager-io-9	1/1	Running
kube-system	kube-proxy-56fjs	1/1	Running
kube-system	kube-proxy-gbxjf	1/1	Running
kube-system	kube-proxy-lzfhf	1/1	Running
kube-system	kube-proxy-xzklw	1/1	Running
kube-system	kube-scheduler-io-10	1/1	Running
kube-system	kube-scheduler-io-11	1/1	Running
kube-system	kube-scheduler-io-9	1/1	Running
kubeflow-user-example-com	digits-recognizer-0	2/2	Running
kubeflow-user-example-com	ml-pipeline-ui-artifact-6bcd5db8c4-s8pn1	2/2	Running
kubeflow-user-example-com	ml-pipeline-visualizationserver-58f98f845-jz9jv	2/2	Running
kubeflow-user-example-com	stock-lstm-predictor-default-00001-deployment-85cd5d54f8-jl7th	2/2	Running
kubeflow	admission-webhook-deployment-67b69f9f6f-65cpk	1/1	Running
kubeflow	cache-server-8698946867-tmwzk	2/2	Running
kubeflow	centraldashboard-659996b95f-5nljq	2/2	Running
kubeflow	jupyter-web-app-deployment-7b78b6b8b9-b8clw	1/1	Running
kubeflow	katib-controller-789b7b87d-c19wm	1/1	Running
kubeflow	katib-db-manager-6ff7d6d45d-sqjb5	1/1	Running
kubeflow	katib-mysql-5488655f77-4n836	1/1	Running
kubeflow	katib-ui-5f675fdc8-sh2f4	1/1	Running
kubeflow	kserve-models-web-app-77c898cc4c-kxwll	2/2	Running
kubeflow	kubeflow-pipelines-profile-controller-6db748cf8b-k4wjh	1/1	Running
kubeflow	metacontroller-0	1/1	Running
kubeflow	metadata-envoy-deployment-7df947d668-nhrjr	1/1	Running
kubeflow	metadata-gRPC-deployment-8bbbbbfb8c-zb2kr	2/2	Running
kubeflow	metadata-writer-6fdccfb6-gf58d	2/2	Running
kubeflow	minio-75d7f88454-sj4lt	2/2	Running
kubeflow	ml-pipeline-7cf9c4f6d5-9x6kn	2/2	Running
kubeflow	ml-pipeline-persistenceagent-cff6bd654-6crnk	2/2	Running
kubeflow	ml-pipeline-scheduledworkflow-848cb4c7fc-6vvvcz	2/2	Running
kubeflow	ml-pipeline-ui-6fbb699cb6-gl77c	2/2	Running
kubeflow	ml-pipeline-viewer-crd-578699d8fb-wt9pr	2/2	Running
kubeflow	ml-pipeline-visualizationserver-6696c655c9-n47rv	2/2	Running
kubeflow	mysql-5f554874bf-x16gj	2/2	Running
kubeflow	notebook-controller-deployment-66b9f45ffb-hfbzb	2/2	Running
kubeflow	profiles-deployment-bdfb879fc-gsrsv	3/3	Running
kubeflow	tensorboard-controller-controller-manager-74dd6467c8-mrg95	3/3	Running
kubeflow	tensorboards-web-app-deployment-7c6fc9bc4c-vq7hw	1/1	Running
kubeflow	training-operator-65c69fc75-6w4qn	1/1	Running
kubeflow	volumes-web-app-deployment-7474c6d7-r4h9b	1/1	Running
kubeflow	workflow-controller-58796bfd74-rkmdd	2/2	Running

شکل ۴-۵: وضعیت مولفه ها در خوشه کوبرتینز

NAME	CPU(cores)	CPU%	MEMORY(bytes)	MEMORY%
io-10	875m	2%	15024Mi	15%
io-11	918m	2%	14920Mi	15%
io-12	415m	1%	13491Mi	14%
io-9	1087m	2%	17167Mi	17%

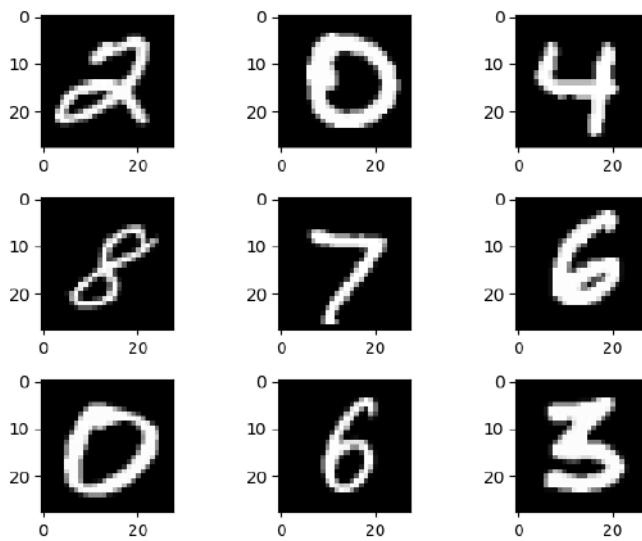
شکل ۵: میزان مصرف منابع سخت افزاری پلتفرم بدون بار

شکل ۶: داشبورد پلتفرم MLOps

زمانی که پلتفرم زیر بار نیست نشان داده شده است. همان طور که می بینید میزان مصرف منابع سخت افزاری به صورت یکنواخت به خوبی توزیع شده است که منجر به استفاده بهینه از منابع سخت افزاری می گردد. در شکل ۵-۶ نیز داشبورد پلتفرم نشان داده شده است. در این داشبورد ما سرویس های Notebooks برای مدیریت جوپیتر نوت بوک های کاربر، Models برای مشاهده و تحلیل نتایج مدل های یادگیری عمیق، Tensorboard به منظور مشاهده و تحلیل نتایج مدل های یادگیری عمیق، Runs به منظور مدیریت چرخه های کاری یادگیری ماشین لحاظ شده است.

### ۳-۵ حل مسئله و نتایج

پس از پیاده سازی پلتفرم MLOps نیاز به ارزیابی آن داریم. هدف از این کار، بررسی قابلیت ها و عملکرد این پلتفرم در مدیریت و اجرای مدل های یادگیری ماشین به صورت خودکار و پیوسته است. به منظور ارزیابی و تست پلتفرم، دو مسئله مختلف با دو رویکرد متفاوت مورد بررسی قرار می گیرند. در مسئله اول، از قابلیت Notebooks در این پلتفرم استفاده شده است و در مسئله دیگر که به صورت کدهای پایتون نوشته شده است با بهره گیری از CI/CD، روی پلتفرم پیاده سازی و اجرا می شوند. این رویکرد، به ما امکان می دهد تا عملکرد پلتفرم را در شرایط مختلف و با استفاده از ابزارهای متفاوت بررسی و ارزیابی کنیم.



شکل ۷-۵: نمونه داده مجموعه دادگان MNIST

### ۱-۳-۵ مسئله تشخیص ارقام

مسئله تشخیص ارقام دستنویس یکی از مسائل پایه‌ای در حوزه یادگیری عمیق و بینایی ماشین است. این مسئله با استفاده از مجموعه دادگان MNIST شامل ۶۰۰۰۰ تصویر آموزشی و ۱۰۰۰۰ تصویر آزمایشی از ارقام ۰ تا ۹ حل شده است. هر تصویر دارای ابعاد ۲۸×۲۸ پیکسل و سیاه و سفید می‌باشد (شکل ۷-۵). برای تشخیص این ارقام، معمولاً از مدل‌های شبکه عصبی پیچشی<sup>۷</sup> استفاده می‌شود که با بهره‌گیری از لایه‌های کانولوشن و پولینگ، ویژگی‌های مکانی تصاویر را استخراج می‌کنند. این شبکه‌ها با استفاده از فیلترهای قابل یادگیری، ویژگی‌های محلی و پیچیده‌ای مانند لبه‌ها، گوش‌ها و الگوهای خاص را شناسایی می‌کنند. پس از چندین لایه کانولوشن و پولینگ، شبکه به یک لایه کاملاً متصل<sup>۸</sup> یا چند لایه می‌رسد که وظیفه دسته‌بندی نهایی را بر عهده دارند.

### چرخه کاری آموزش

رویکرد حل مسئله ما در این بخش، استفاده از قابلیت Notebooks در پلتفرم می‌باشد. لذا از خط لوله‌های CI/CD برای این منظور استفاده نشده است. در ابتدا مجموعه دادگان MNIST در یک باکت مجزا در MinIO ذخیره‌سازی می‌شود. با استفاده از کتابخانه‌های پایتونی به محل ذخیره‌سازی متصل و داده‌ها گرفته و در کانتینری که به همین منظور به کاربر داده می‌شود ذخیره‌سازی می‌شود. پس از مرحله پیش‌پردازش، داده‌ها برای آموزش مدل کانولوشنی مورد استفاده قرار می‌گیرند. از آنجایی

<sup>7</sup>Convolutional neural network (CNN)

<sup>8</sup>Fully Connected

جدول ۳-۵: زمان اجرا چرخه یادگیری ماشین در مسئله تشخیص ارقام

خط لوله	زمان (ثانیه)
چرخه کاری آموزش	98
چرخه کاری استقرار	69

که برای مقایسه زمان ها با مقاله [۵۲] نیاز داریم که ساختار مدل و هم چنین ابرپارامتر ها مشترک باشد، لذا از یک مدل کانولوشنی ۴ لایه با یک لایه کاملا متصل استفاده شده است. پس از آموزش، مدل نهایی را در MinIO ذخیره سازی می کنیم.

### چرخه کاری استقرار

همانند گذشته، از قابلیت نوت بوک در پلتفرم برای استقرار مدل بهره برده ایم. در اینجا با استفاده از استقراردهنده های مخصوص KServe برای استقرار مدل بهره برده ایم. با توجه به اینکه چارچوب TensorFlow برای مدل استفاده شده است، از استقراردهنده TensorFlow Serving بهره گرفته می شود. به منظور استقرار مدل، تنها کافی است که آدرس ذخیره سازی مدل که همان آدرس MinIO آن است را به همراه نوع استقراردهنده مورد نظر مشخص کنید.

### نتایج

از آنجا که دقت و کارایی مدل هدف پیاده سازی مسئله نبوده و صرفا هدف ما تست عملکردی پلتفرم می باشد، ملاک ارزیابی ما زمان اجرا خط لوله ها و چرخه یادگیری ماشین، مدت زمان پاسخ و میزان مصرف منابع می باشد. در جدول ۳-۵ زمان اجرای هر بخش را برای اجرای یک تغییر نشان داده شده است. کل مدت زمان آموزش تا استقرار مدل مجموعاً ۱۶۷ ثانیه می باشد. توجه داشته باشید که این زمان بدون لحاظ زمان کش می باشد. در صورتی که تغییر در یک جزء صورت می گیرد تنها آن جزء اجرا شده و بقیه اجزا از حافظه نهان برای اجرا آن استفاده می کنند.

به منظور تست مدل استقرار یافته، به صورت همزمان به آن درخواست داده و زمان پاسخ را گزارش کرده ایم. نتایج این تست در جدول ۴-۵ گزارش شده است. برای یک درخواست ارسال شده به مدل، مدت زمان استنتاج مدل تقریباً بین ۳ تا ۸ میلی ثانیه و بقیه زمان ارسال و دریافت درخواست از طریق Istio gateway می باشد (شکل ۸-۵).

### مقایسه

مقاله [۵۲] به بررسی و ارزیابی فرآیند استقرار مدل های یادگیری ماشین بر روی زیرساخت های کوبرنتیز با استفاده از ابزار متن باز Kubeflow پرداخته است. این مقاله با تمرکز بر دو بستر ابری IBM Cloud و Google Cloud Platform (GCP) می باز

جدول ۴-۵: تست استنتاج مدل مسئله تشخیص ارقام

تعداد	زمان پاسخ (ثانیه)
1	4.03
4	4.04
10	4.07
16	4.1
32	4.18
64	4.34
100	4.43
128	4.66
256	5.12
512	6.36

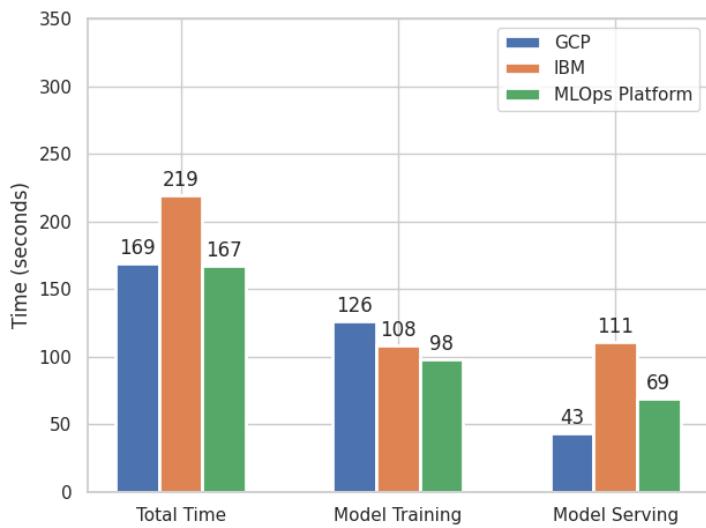


شکل ۸-۵: گراف استنتاج مدل در مسئله تشخیص ارقام (داشبورد Grafana)

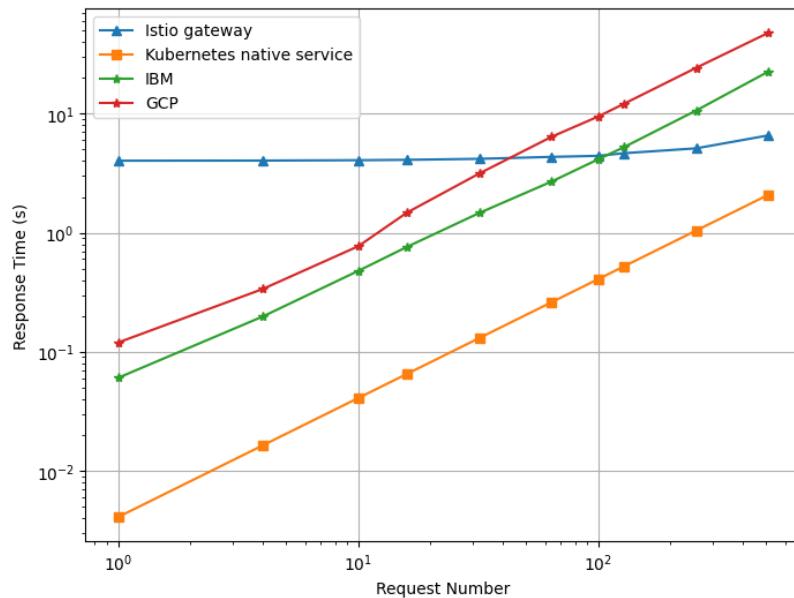
مقایسه عملکرد و کارایی پلتفرم MLOps در این دو محیط پرداخته است.

نویسندهان با استفاده از مجموعه داده MNIST و ایجاد پایپلاین‌های کامل از مرحله پیش‌پردازش داده‌ها تا مرحله استنتاج مدل، عملکرد Kubeflow را در هر دو بستر ارزیابی کردند. این نتایج با نتایج گرفته شده از پلتفرم پیاده‌سازی شده در شکل‌های ۹-۵ و ۱۰-۵ مقایسه شده‌اند. نتایج نشان می‌دهند که پلتفرم GCP بهترین عملکرد را استقرار مدل و پلتفرم پیاده‌سازی شده بهترین عملکرد را در آموزش مدل و در مجموع دو مرحله دارد.

در شکل ۱۰-۵ رفتار نمودار در سه پلتفرم تقریباً شبیه به هم می‌باشد با این تفاوت که در پلتفرم پیاده‌سازی شده این زمان‌ها بهتر است. نکته مهم این نمودار استفاده از تکنیک مقیاس‌پذیری خودکار در پلتفرم ما می‌باشد. نتایج در تعداد درخواست‌ها بالا به دلیل استفاده از تکنیک مقیاس‌پذیری خودکار در پلتفرم با استفاده از ابزارهای Istio و Knative مناسب



شکل ۹-۵: زمان چرخه های کاری یادگیری ماشین در مسئله تشخیص ارقام



شکل ۱۰-۵: زمان استنتاج مدل در مسئله تشخیص ارقام

است ولی در تعداد درخواست های پایین مناسب نمی باشد. به منظور رفع این مشکل از سرویس LoadBalancer در خوشه کوبرنطیز استفاده شده است. در این روش به دلیل استفاده نکردن از تکنیک مقیاس پذیری خودکار، زمان درخواست ها در سناریوهایی که تعداد درخواست های همزمان زیاد می باشد، مناسب نمی باشد.

به منظور تست دسترسی نوت بوک به پردازنده گرافیکی به صورت تستی یک بار چرخه کاری آموزش با فعال کردن قابلیت آموزش بر روی پردازنده گرافیکی انجام شده است. نتایج استفاده از پردازنده گرافیکی نیز در شکل ۱۱-۵ نشان داده شده است.



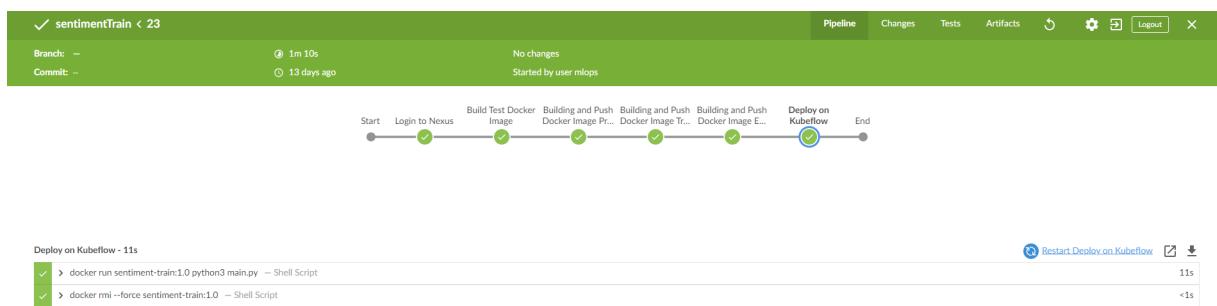
شکل ۱۱-۵: گراف نظارت بر پردازنده گرافیکی در مسئله تشخیص ارقام (داشبورد Grafana)

## ۲-۳-۵ مسئله تحلیل احساسات در بازار سهام

مسئله اصلی این پروژه تحلیل احساسات در بازار سهام است. هدف این است که با استفاده از نظرات و اخبار اقتصادی، احساسات مثبت و منفی موجود در بازار شناسایی شود و تأثیر آن بر رفتار بازار تحلیل گردد. داده‌های دادگان این مسئله به تجربیات احساس بازار سهام مربوط می‌شود که از حساب‌های مختلف توئیتر، شامل ۵۷۹۱ توئیت مرتبط با اخبار اقتصادی پیامون سهام، با دسته‌بندی احساس مثبت و منفی جمع‌آوری شده‌اند. این مجموعه داده به دو بخش مثبت و منفی تقسیم می‌شوند که تعداد موارد منفی ۲۱۰۶ و تعداد موارد مثبت ۳۶۸۵ است. در شکل ۱۲-۵ ده سطر اول از این داده‌ها به عنوان نمونه نشان داده شده است. راه حل ارائه شده برای حل این مسئله استفاده از شبکه‌های LSTM می‌باشد. به منظور کنترل و مدیریت این مسئله از دو خط لوله مجزا برای آموزش و استقرار استفاده شده است.

index	text	sentiment
1	Kickers on my watchlist XIDE TIT SQQ PNK CPW BPZ AJ trade method 1 or method 2, see prev posts	1
2	user: AAP MOVIE. 55% return for the FEA/GEED indicator just 15 trades for the year. AWESOME.	1
3	user I'd be afraid to short AMZN - they are looking like a near-monopoly in eBooks and infrastructure-as-a-service	1
4	MNTA Over 12.00	1
5	OI Over 21.37	1
6	PGNX Over 3.04	1
7	AAP - user if so then the current downtrend will break. Otherwise just a short-term correction in med-term downtrend.	-1
8	Monday's relative weakness. NYX WIN TIE TAP ICE INT BMC AON C CHK BIIB	-1
9	GOOG - over trend line channel test & volume support.	1
10	AAP will watch tomorrow for ONG entry.	1

شکل ۱۲-۵: مجموعه داده احساسات در بازار سهام



شکل ۵-۱۳: خط لوله آموزش مسئله تحلیل احساسات در بازار سهام

### خط لوله آموزش

در این خط لوله از قابلیت کانتینر برای استقرار آسان استفاده شده است و شامل آزمون هایی برای اطمینان از عملکرد و دقت راه حل های پیاده سازی شده است که هر کانتینر با ساخت و اجرای فایل و تصویر داکر مربوطه اجرا خواهد شد. هم چنین، برای ساخت خط لوله در بستر پلتفرم لازم است که در ابتدا بخش های مختلف پروژه را به مولفه های مجزا تقسیم کرد، به طوری که هر مولفه دارای یک فایل داکر بوده و به صورت مجزا به آن نگاه خواهد شد. در اینجا ما با سه مولفه سروکار خواهیم داشت که مراحل پیش پردازش، آموزش و آزمایش چرخه‌ی یادگیری ماشین ما خواهند بود. همچنین برای ساخت خط لوله نیاز است تا اسکریپت جداگانه‌ای مربوط با کدهای این بخش که با کتابخانه kfp است نوشته شود، تا بتوان با استفاده از تصاویر داکری ساخته شده در هر مولفه، پایپلاین مورد نظر را روی بستر پلتفرم MLOps ساخت. در شکل ۵-۱۳ یکی از اجراهای خط لوله CI/CD برای مرحله آموزش را مشاهده می کنید.

همان طور که می بینید این خط لوله شامل چندین بخش از جمله پیش پردازش، آموزش، ارزیابی و پیاده سازی روی بستر پلتفرم MLOps با استفاده از Kubeflow Pipeline می باشد.

پیش پردازش شامل چندین مرحله کلیدی است که داده ها را برای مدل سازی آماده می کند. این مراحل شامل تغییر برچسب ها به مقادیر دسته ای، تمیز کردن متن از کاراکترها و کلمات بی معنی، تقسیم داده ها به دو بخش آموزش و ارزیابی، و تبدیل متن به دنباله هایی از کلمات است. همچنین، واژگان با استفاده از تعبیه گرهای پیش آموزش داده شده GloVe به بردارهایی تبدیل می شوند که حاوی اطلاعات معنایی و ارتباطی کلمات هستند. فایل های تعبیه گر GloVe از MinIO دانلود شده و بردارهای تعبیه برای واژگان موجود در داده های آموزش ساخته می شود. این بردارها سپس برای ایجاد یک ماتریس تعبیه جهت استفاده در شبکه عصبی به کار می روند. داده های تعبیه شده و سایر داده های پردازش شده نیز در MinIO ذخیره می شوند تا در مراحل بعدی مورد استفاده قرار گیرند. برای ذخیره و بازیابی داده ها، از دو ابزار اصلی MinIO و PostgreSQL استفاده



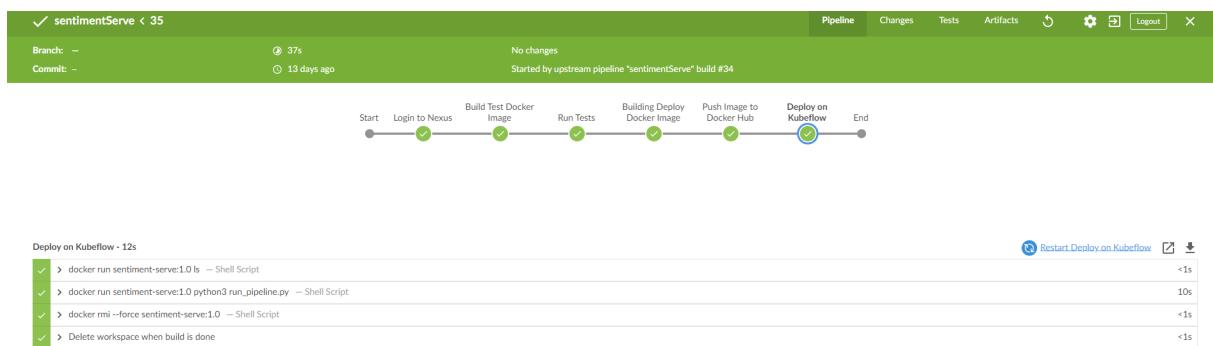
شکل ۱۴-۵: چرخه کاری آموزش مسئله تحلیل احساسات در بازار سهام

می شود. در کلاس پیش پردازش، فایل های تعبیه گر GloVe را از MinIO دانلود و بردارهای تعبیه برای واژگان موجود در داده های آموزش ساخته می شود. همچنین، داده های پردازش شده نیز در MinIO ذخیره می شوند. PostgreSQL نیز برای بازیابی مجموعه داده اولیه به کار می رود، به طوری که داده ها از پایگاه داده خوانده شده و برای پردازش و آماده سازی بیشتر به کلاس پیش پردازش منتقل می شوند.

در بخش آموزش از شبکه های حافظه کوتاه مدت بلند<sup>۹</sup> به دلیل توانایی شان در درک و پردازش توالی های زمانی طولانی مدت، برای تحلیل احساسات متنی استفاده شده است. برخلاف مدل های سنتی که ممکن است نتوانند ارتباطات طولانی مدت بین کلمات را به خوبی درک کنند، LSTM با استفاده از سلول های حافظه و مکانیزم های دروازه ای خود، قادر است اطلاعات مهم را حفظ و اطلاعات غیر ضروری را فراموش کند. برای استفاده از LSTM در تحلیل احساسات، از داده های پیش پردازش شده که در MinIO ذخیره سازی شده بود استفاده می شود. پس از آماده سازی داده ها، مدل LSTM با تعریف لایه های مختلف از جمله لایه های تعبیه گر، لایه های LSTM دو طرفه و لایه های چگال ساخته می شود. این لایه ها به مدل امکان می دهند تا وابستگی های معنایی و زمانی بین کلمات را بهتر درک کند. علاوه بر این، به منظور جلوگیری از بیش برآذش از لایه های Dropout با نرخ 0.2 استفاده شده است.

در انتها پس از آموزش، مدل با استفاده از مجموعه دادگان ارزیابی، بررسی می شود. معیارهای ارزیابی مدل نیز دقت آن می باشد. در صورتی که بررسی های انجام شده از دقت مدل های گذشته بیشتر بود، مدل در MinIO ذخیره سازی می شود. به منظور اجرا چرخه یادگیری ماشین گفته شده این چرخه با استفاده از کتابخانه kfp روی بستر پلتفرم اعمال شده تا فرآیند پیش پردازش، آموزش و ارزیابی مدل را روی پلتفرم انجام دهد (شکل ۱۴-۵).

<sup>۹</sup> Long short-term memory (LSTM)



شکل ۱۵-۵: خط لوله استقرار مسئله تحلیل احساسات در بازار سهام

### خط لوله استقرار

همان طور که در شکل ۱۵-۵ مشاهده می کنید، اجرای خط لوله استنتاج مدل در پلتفرم با استفاده از Kserve شامل چند مرحله کلیدی است. ابتدا، یک فایل پیکربندی برای Kserve ایجاد می شود که جزئیات مدل، مسیر مدل ذخیره شده و هرگونه مراحل پیش پردازش یا پس پردازش لازم را مشخص می کند. سپس، یک جزء<sup>۱۰</sup> Kserve با استفاده از کتابخانه kfp ایجاد می شود که از فایل پیکربندی YAML استفاده می کند. این جزء باید شامل منطق لازم برای استقرار مدل، مدیریت درخواست های ورودی و ارائه پیش بینی ها باشد. پس از ایجاد جزء، با استفاده از Kubeflow Pipeline روی بستر پلتفرم پیاده سازی می شود. این شامل تعریف وابستگی ها بین اجزا است تا اطمینان حاصل شود که جزء استقرار مدل پس از اجزا آموخته مدل و ارزیابی اجرا می شود. در نهایت، ارتباط با Endpoint از طریق REST API انجام می شود. این فرآیند به تحلیلگران اجازه می دهد تا مدل های یادگیری ماشین را به طور مؤثر استقرار و مدیریت کنند و از ویژگی های پیشرفته مانند مقیاس پذیری خودکار، تعادل بار و پایش عملکرد بهره مند شوند.

### نتایج

از آنجا که دقت و کارایی مدل هدف پیاده سازی مسئله نبوده و صرفا هدف ما تست عملکردی پلتفرم می باشد، ملاک ارزیابی ما زمان اجرا خط لوله ها و چرخه یادگیری ماشین، مدت زمان پاسخ و میزان مصرف منابع می باشد. در جدول ۱۵-۵ زمان اجرای هر بخش را برای اجرای یک تغییر نشان داده شده است. کل مدت زمان آموخته تا استقرار مدل مجموعاً ۳۹۲ ثانیه می باشد. توجه داشته باشید که این زمان بدون لحاظ زمان کش می باشد. در صورتی که تغییر در یک جزء صورت می گیرد تنها آن جزء اجرا شده و بقیه اجزا از حافظه نهان برای اجرا آن استفاده می کنند.

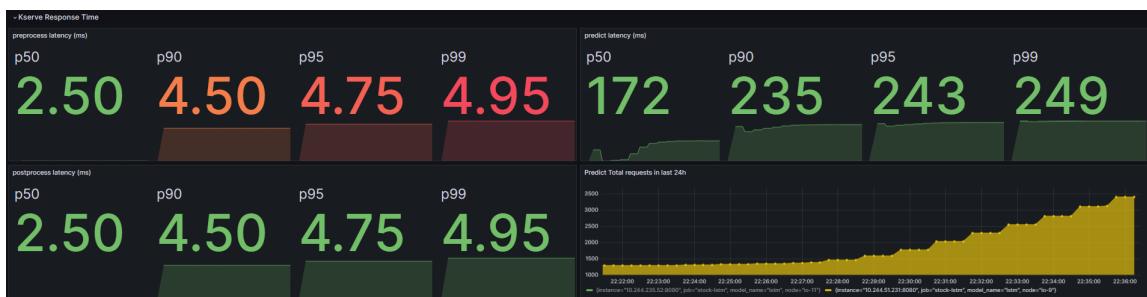
<sup>۱۰</sup> Component

جدول ۵-۵: زمان اجرا در مسئله تحلیل احساسات در بازار سهام

خط لوله	زمان (ثانیه)
آموزش CI/CD	70
چرخه کاری آموزش	187
استقرار CI/CD	37
چرخه کاری استقرار	98

جدول ۵-۶: تست استنتاج مدل مسئله تحلیل احساسات در بازار سهام

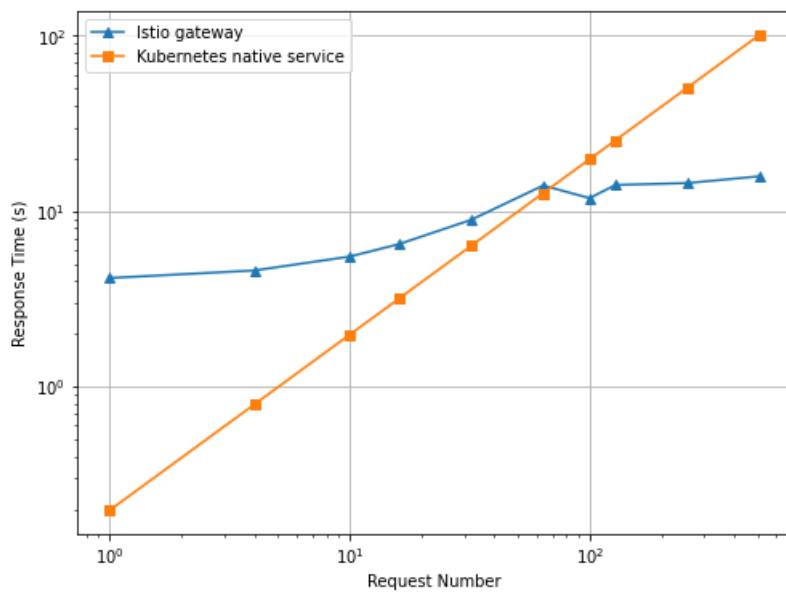
تعداد	زمان پاسخ (ثانیه)	CPU (mili cores)
1	4.16	24
4	4.59	110
10	5.51	290
16	6.48	387
32	8.91	566
64	13.99	845
100	11.86	1142
128	14.09	1338
256	14.45	1689
512	15.8	2090



شکل ۱۶-۵: گراف استنتاج مدل در مسئله تحلیل احساسات در بازار سهام (داشبورد Grafana)

به منظور تست مدل استقرار یافته، به صورت همزمان به آن درخواست داده و زمان پاسخ و میزان مصرف CPU را گزارش کرده ایم. نتایج این تست در جدول ۶-۵ گزارش شده است. برای یک درخواست ارسال شده به مدل، مدت زمان استنتاج مدل تقریباً بین ۱۵۰ تا ۱۷۰ میلی ثانیه و بقیه زمان ارسال و دریافت درخواست از طریق Istio gateway می باشد (۱۶-۵).

نتایج در تعداد درخواست ها بالا به دلیل استفاده از تکنیک مقیاس پذیری خودکار در پلتفرم با استفاده از ابزارهای Istio و Knative مناسب است ولی در تعداد درخواست های پایین مناسب نمی باشد. به منظور رفع این مشکل از سرویس LoadBalancer در خوش کوبرنتیز استفاده شده است که نتایج آن را در شکل ۱۷-۵ مشاهده می کنید. در این روش به دلیل



شکل ۵-۱۷: زمان استنتاچ مدل در مسئله تحلیل احساسات در بازار سهام

استفاده نکردن از تکنیک مقیاس پذیری خودکار، زمان درخواست ها در سناریوهایی که تعداد درخواست های همزمان زیاد می باشد، مناسب نمی باشد.

## فصل ۶

# نتیجه‌گیری و پیشنهادات

با پیشرفت فناوری دیجیتال و گسترش هرچه بیشتر کاربردهای سرویس‌های چندرسانه‌ای دیجیتال، نیازهای امنیتی جدیدی در سطح جهان مطرح گردیده است و لذا با نفوذ دنیای دیجیتال به زندگی مردم، طراحی سیستمهای امنیتی مرتبط به آن اهمیت فراوانی در سالهای اخیر پیدا کرده‌اند. به دنبال این نیاز، نهان‌نگاری به عنوان روشی مؤثر جهت تأمین برخی از این نیازها مورد توجه قرار گرفته و پیشرفت سریعی داشته است.

در این پایان نامه جهت آشنایی و نیل به یک دیدگاه کلی از سیستمهای نهان‌نگاری ابتدا به بیان کاربردهای نهان‌نگاری

پرداختیم. ...

# مراجع

- [1] L Navarro E Hernanchez-sanchez F Rodriguez-Haro, F Freitag, “A summary of virtualization techniques,” .
- [2] Ramtin Jabbari, Nauman bin Ali, Kai Petersen, and Binish Tanveer, “What is devops? a systematic mapping study on definitions and practices,” in *Proceedings of the Scientific Workshop Proceedings of XP2016*. 2016, Association for Computing Machinery.
- [3] Inc. Amazon Web Services, “What is devops?,” URL: <https://aws.amazon.com/devops/what-is-devops/> [Accessed: 2024-05-07].
- [4] Manish Virmani, “Understanding devops and bridging the gap from continuous integration to continuous delivery,” in *Fifth International Conference on the Innovative Computing Technology (INTECH 2015)*, 2015, pp. 78–82.
- [5] A. Van Bennekum A. Cockburn-W. Cunningham M. Fowler J. Grenning J. Highsmith A. Hunt R. Jeffries K. Beck, M. Beedle, “Manifesto for agile software development,” 2001, URL: <https://agilemanifesto.org/> [Accessed: 2024-02-17].
- [6] Jez Humble and David Farley, *Continuous Delivery: Reliable Software Releases through Build, Test, and Deployment Automation*, Addison-Wesley Professional, 2010.
- [7] paul hammant, “Trunk based development,” URL: <https://trunkbaseddevelopment.com/> [Accessed: 2023-11-01].
- [8] M. Huttermann, *DevOps for Developers*, chapter Infrastructure as Code, 2012.
- [9] Matej Artac, Tadej Borovssak, Elisabetta Di Nitto, Michele Guerriero, and Damian Andrew Tamburri, “Devops: introducing infrastructure-as-code,” in *2017 IEEE/ACM 39th International Conference on Software Engineering Companion (ICSE-C)*, May 2017, pp. 497–498.
- [10] Nelly Delgado, Ann Q Gates, and Steve Roach, “A taxonomy and catalog of runtime software-fault monitoring tools,” *IEEE Transactions on software Engineering*, vol. 30, no. 12, pp. 859–872, 2004.
- [11] SAIBS Arachchi and Indika Perera, “Continuous integration and continuous delivery pipeline automation for agile software project management,” in *Moratuwa Engineering Research Conference (MERCon)*, May 2018, pp. 156–161.
- [12] Anja Kammer Florian Beetz and Dr. Simon Harrer, *GitOps Cloud-native Continuous Deployment*, 2021.
- [13] N. Forsgren and J. Humble, “The role of continuous delivery in it and organizational performance,” March 2016.
- [14] “What is virtualization?,” URL: <https://aws.amazon.com/what-is/virtualization/> [Accessed: 2024-05-08].
- [15] Amit M Potdar, DG Narayan, Shivaraj Kengond, and Mohammed Moin Mulla, “Performance evaluation of docker container and virtual machine,” *Procedia Computer Science*, vol. 171, pp. 1419–1428, 2020.
- [16] “Containerization,” URL: <https://www.ibm.com/topics/containerization> [Accessed: 2023-05-21].

- [17] Docker Inc., “Docker,” URL: <https://docs.docker.com/> [Accessed: 2023-05-18].
- [18] Y. Yu Y. Zhou and B. Ding, “Towards mlops: A case study of ml pipeline platform,” October 2020.
- [19] Damian A. Tamburri, “Sustainable mlops: Trends and challenges,” in *2020 22nd International Symposium on Symbolic and Numeric Algorithms for Scientific Computing (SYNASC)*, 2020, pp. 17–23.
- [20] Lucy Ellen Lwakatare, Ivica Crnkovic, Ellinor Rånge, and Jan Bosch, “From a data science driven process to a continuous delivery process for machine learning systems,” in *Product-Focused Software Process Improvement*, Maurizio Morisio, Marco Torchiano, and Andreas Jedlitschka, Eds., Cham, 2020, pp. 185–201, Springer International Publishing.
- [21] Ioannis Karamitsos, Saeed Albarhami, and Charalampos Apostolopoulos, “Applying devops practices of continuous automation for machine learning,” *Information*, vol. 11, no. 7, 2020.
- [22] Lucas Cardoso Silva, Fernando Rezende Zagatti, Bruno Silva Sette, Lucas Nildaimon dos Santos Silva, Daniel Lucrédio, Diego Furtado Silva, and Helena de Medeiros Caseli, “Benchmarking machine learning solutions in production,” in *2020 19th IEEE International Conference on Machine Learning and Applications (ICMLA)*, 2020, pp. 626–633.
- [23] Behrouz Derakhshan, Alireza Rezaei Mahdiraji, Tilmann Rabl, and Volker Markl, “Continuous deployment of machine learning pipelines.,” in *EDBT*, March 2019, pp. 397–408.
- [24] Alexandra Posoldova, “Machine learning pipelines: From research to production,” *IEEE Potentials*, vol. 39, no. 6, pp. 38–42, 2020.
- [25] “Apache airflow,” URL: <https://airflow.apache.org/> [Accessed: 2023-11-02].
- [26] “Kubeflow,” URL: <https://www.kubeflow.org/> [Accessed: 2023-11-02].
- [27] M. Schmitt, “Airflow vs. luigi vs. argo vs. mlflow vs. kubeflow,” URL: <https://www.datarevenue.com/en-blog/airflow-vs-luigi-vs-argo-vs-mlflow-vs-kubeflow> [Accessed: 2023-11-02].
- [28] “Feast,” URL: <https://feast.dev/> [Accessed: 2023-11-05].
- [29] Álvaro López García, Jesús Marco De Lucas, Marica Antonacci, Wolfgang Zu Castell, Mario David, Marcus Hardt, Lara Lloret Iglesias, Germán Moltó, Marcin Plociennik, Viet Tran, Andy S. Alic, Miguel Caballer, Isabel Campos Plasencia, Alessandro Costantini, Stefan Dlugolinsky, Doina Cristina Duma, Giacinto Donvito, Jorge Gomes, Ignacio Heredia Cacha, Keiichi Ito, Valentin Y. Kozlov, Giang Nguyen, Pablo Orviz Fernández, Zděnek Šustr, and Paweł Wolniewicz, “A cloud-based framework for machine learning workloads and applications,” *IEEE Access*, vol. 8, pp. 18681–18692, 2020.
- [30] “Mlflow,” URL: <https://mlflow.org/> [Accessed: 2023-11-21].
- [31] “Apache spark,” URL: <https://spark.apache.org/> [Accessed: 2023-11-29].
- [32] “Knative,” URL: <https://knative.dev/docs/> [Accessed: 2023-11-29].
- [33] Cédric Renggli, Luka Rimanic, Nezihe Merve Gürel, Bojan Karlas, Wentao Wu, and Ce Zhang, “A data quality-driven view of mlops,” *CoRR*, vol. abs/2102.07750, 2021, URL: <https://arxiv.org/abs/2102.07750> [Accessed: 2023-11-30].
- [34] “Gitlab,” URL: <https://about.gitlab.com/> [Accessed: 2024-05-16].
- [35] “Gerritcodereview,” URL: <https://www.gerritcodereview.com/> [Accessed: 2024-05-16].
- [36] “Jenkins,” URL: <https://www.jenkins.io/> [Accessed: 2023-11-01].
- [37] Armin Esmaeilzadeh, Maryam Heidari, Reyhaneh Abdolazimi, Parisa Hajibabaee, and Masoud Malekzadeh, “Efficient large scale nlp feature engineering with apache spark,” in *2022 IEEE 12th Annual Computing and Communication Workshop and Conference (CCWC)*, 2022, pp. 0274–0280.
- [38] Jun Xu, “Mlops in the financial industry: Philosophy, practices, and tools,” in *Future and Fintech, the, Abcdi and Beyond*, p. 451. World Scientific, 2022.
- [39] “Kafka,” URL: <https://kafka.apache.org/> [Accessed: 2023-11-31].

- [40] “Jupyter,” URL: <https://jupyter.org/> [Accessed: 2023-11-31].
- [41] Tao Cui, Ye Wang, and Bassel Namih, “Build an intelligent online marketing system: An overview,” *IEEE Internet Computing*, vol. 23, no. 4, pp. 53–60, 2019.
- [42] “Ansible,” URL: <https://www.ansible.com/> [Accessed: 2023-12-01].
- [43] “Terraform,” URL: <https://www.terraform.io/> [Accessed: 2023-12-01].
- [44] M. Luksa, *Kubernetes in Action*, Manning, 2018.
- [45] K. Hightower, B. Burns, and J. Beda, *Kubernetes: Up and Running: Dive into the Future of Infrastructure*, O'Reilly Media, 2017.
- [46] “Minio,” URL: <https://min.io/> [Accessed: 2023-12-05].
- [47] Wubin Li, Yves Lemieux, Jing Gao, Zhuofeng Zhao, and Yanbo Han, “Service mesh: Challenges, state of the art, and future research opportunities,” in *2019 IEEE International Conference on Service-Oriented System Engineering (SOSE)*, 2019, pp. 122–1225.
- [48] L. Calcote and Z. Butcher, *Istio: Up and Running: Using a Service Mesh to Connect, Secure, Control, and Observe*, O'Reilly Media, 2019.
- [49] Daniel Fett, Ralf Küsters, and Guido Schmitz, “The web sso standard openid connect: In-depth formal security analysis and security guidelines,” in *2017 IEEE 30th Computer Security Foundations Symposium (CSF)*, 2017, pp. 189–202.
- [50] J. Pivotto and B. Brazil, *Prometheus: Up & Running*, O'Reilly Media, 2023.
- [51] Raintank Inc., “Grafana,” URL: <https://grafana.com/> [Accessed: 2023-12-29].
- [52] Aditya Pandey, Maitreya Sonawane, and Sumit Mamtani, “Deployment of ml models using kubeflow on different cloud providers,” 2022.

## **ABSTRACT**

In the digital world today, invisible and robust image watermarking which embeds invisible signals in to the digital images has been proposed as a major solution to the problem of copyright protection of digital images. Several approaches such as exploiting Human Visual System (HVS) and invariant domain watermarking have been proposed to achieve this goal. In this thesis we use the information-theoretic concepts as tools to develop methods for embedding watermark in an optimized way. Also multi-resolution transforms such as wavelet transform and MR-SVD (Multi-Resolution form of the Singular Value Decomposition) are used in the proposed structure, because these transforms resemble the HVS characteristics for an optimized watermarking structure. Entropy concept and entropy masking effects were proposed to use to develop a model in DWT domain to increase the strength and robustness of the watermark, while perceived quality of the electronic image is not altered. Then, the structure similar to the entropy-based proposed structure in DWT domain, is used for watermarking in the MR-SVD transform domain, which is found a new approach to robust image watermarking. Simulation results show that the proposed methods outperform conventional methods in terms of both invisibility and robustness.

## **KEYWORDS**

1. Image Watermarking.
2. Multi-Resolution Transform.
3. Human Visual System (HVS).
4. Wavelet Transform.
5. Singular Value Decomposition (SVD).
6. Entropy.
7. Entropy Masking.



**SHARIF UNIVERSITY OF TECHNOLOGY  
ELECTRICAL ENGINEERING DEPARTMENT**

**M.Sc. THESIS**

*Title:*

**An Information-Theoretic Model for  
Image Watermarking**

*by:*

**AAAAAA BBBBBB**

*Supervisor:*

**Dr. ...**

August 2005